23 avril 2025

OPENFOODFACTS

Vers une meilleure complétion des données alimentaires

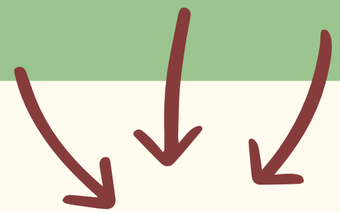
Santé publique France

open FOOD facts

OpenFoodFacts

Base en open source

01. SAISIE MANUELLE



02. ERREUR DE SAISIE



03. DONNEES MANQUANTES

Les objectifs du Projet

Améliorer la base de données d'OpenFoodFact

Proposer des sugestions pour certaines variables

Respecter les grands principes du RGPD



Exploration des données et sélection des variables

Nettoyage des données

Analyses

Exploration des données

320772
produits

106
variables numériques

56
variables catégorielles



Sélection de la variable cible

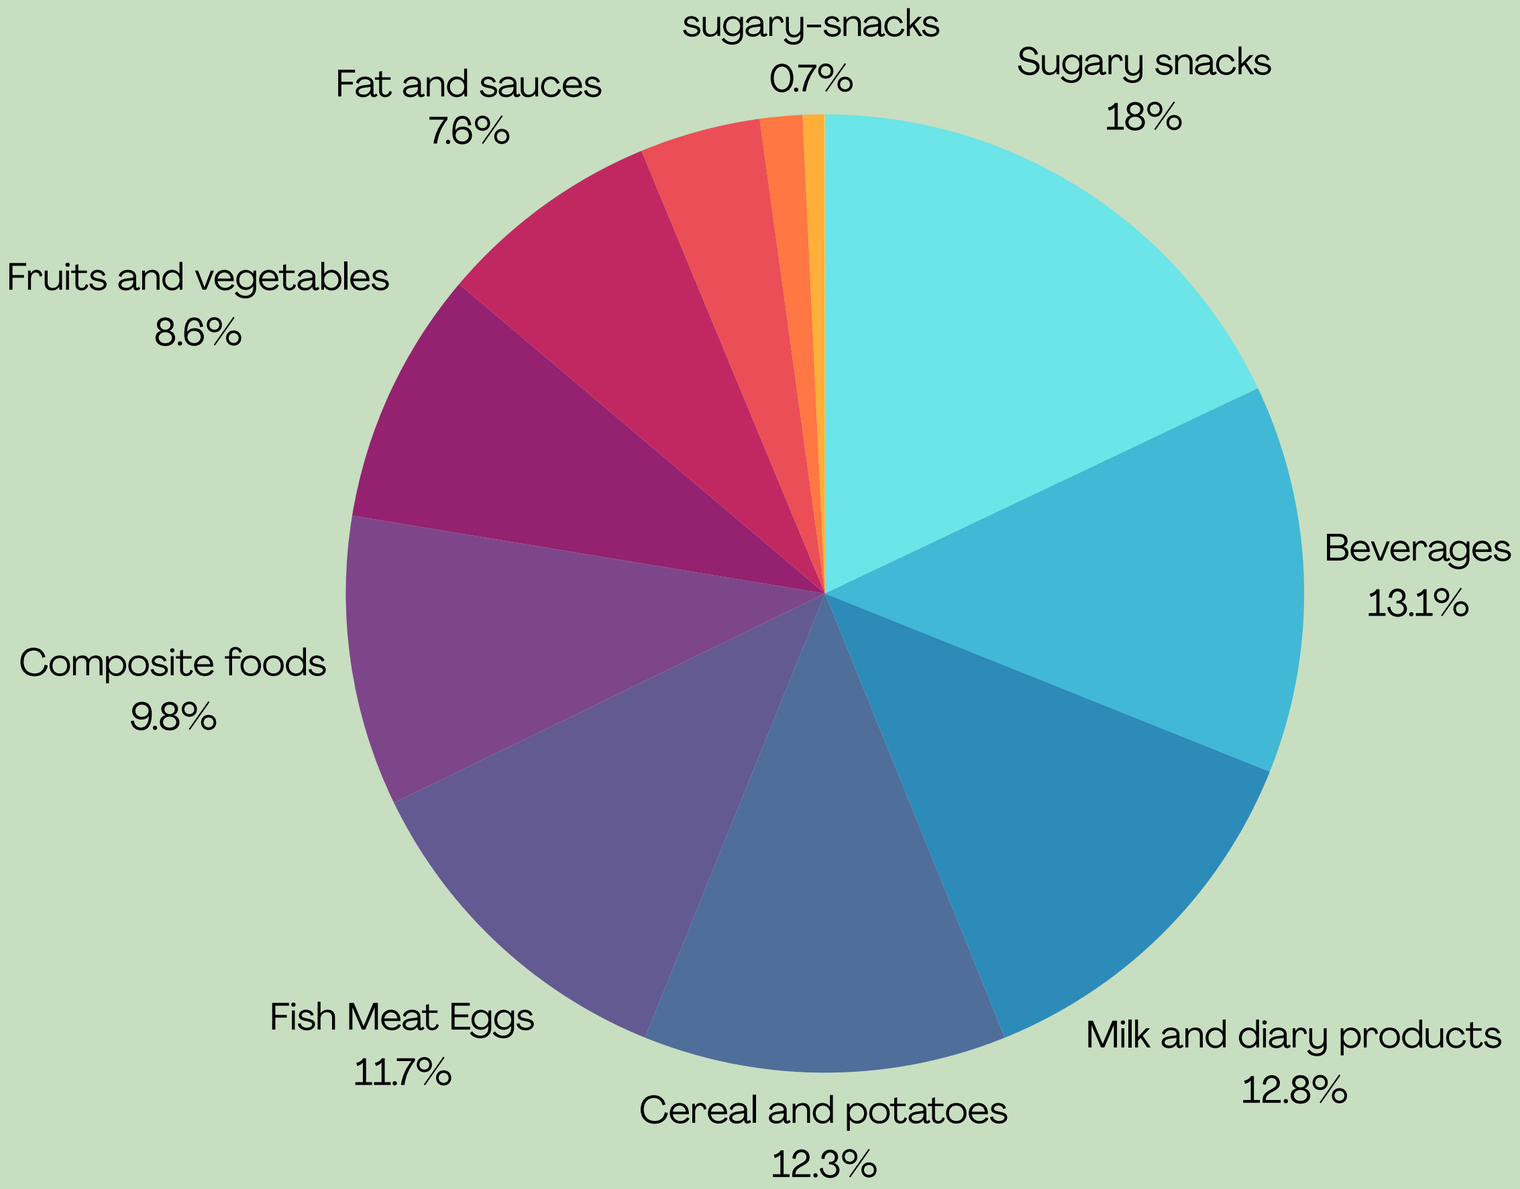
plus de 50% de données manquantes — 128

categorielle — 36

Moins de 20 catégories — 4

pnns_group_1

Sélection de la variable cible



Sélection des variables prédictives

moins de 50% de données manquantes — 34

Potentiellement liées à la variable cible — 14

- nombre d’additifs: 1
- nombre d’éléments dérivant d’huile de palme: 2
- quantité d’élément présent dans 100g de produits: 8
- Score énergétique: 1
- Nutriscore: 2



Exploration des données et sélection des variables

Nettoyage des données
Filtre

Analyses

Filtre du jeu de données

1. Suppression des produits dupliqués

2. Suppression des produits sans valeurs dans la variable cible

3. Suppression des produits contenant que des valeurs manquantes sur l’ensemble des variables retenues



Exploration
des données

Nettoyage
des données

Filtre

Identification des valeurs aberrantes

Analyses

Identification des valeurs aberrantes

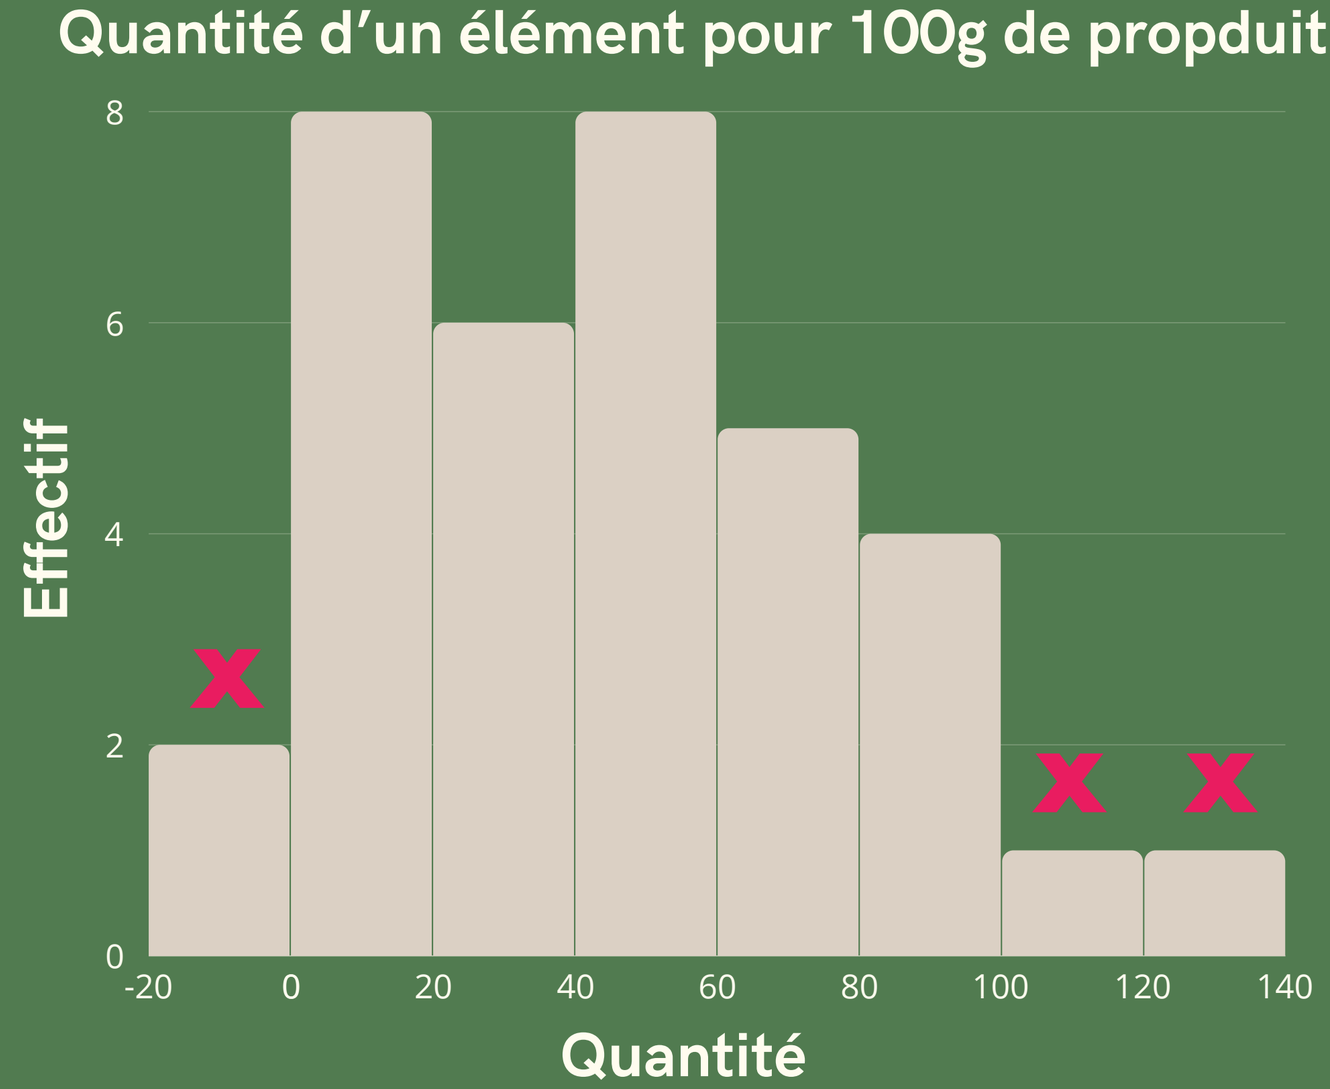
N°1

N°2

N°3

N°4

Approche métier
variables nutritives



Identification des valeurs aberrantes

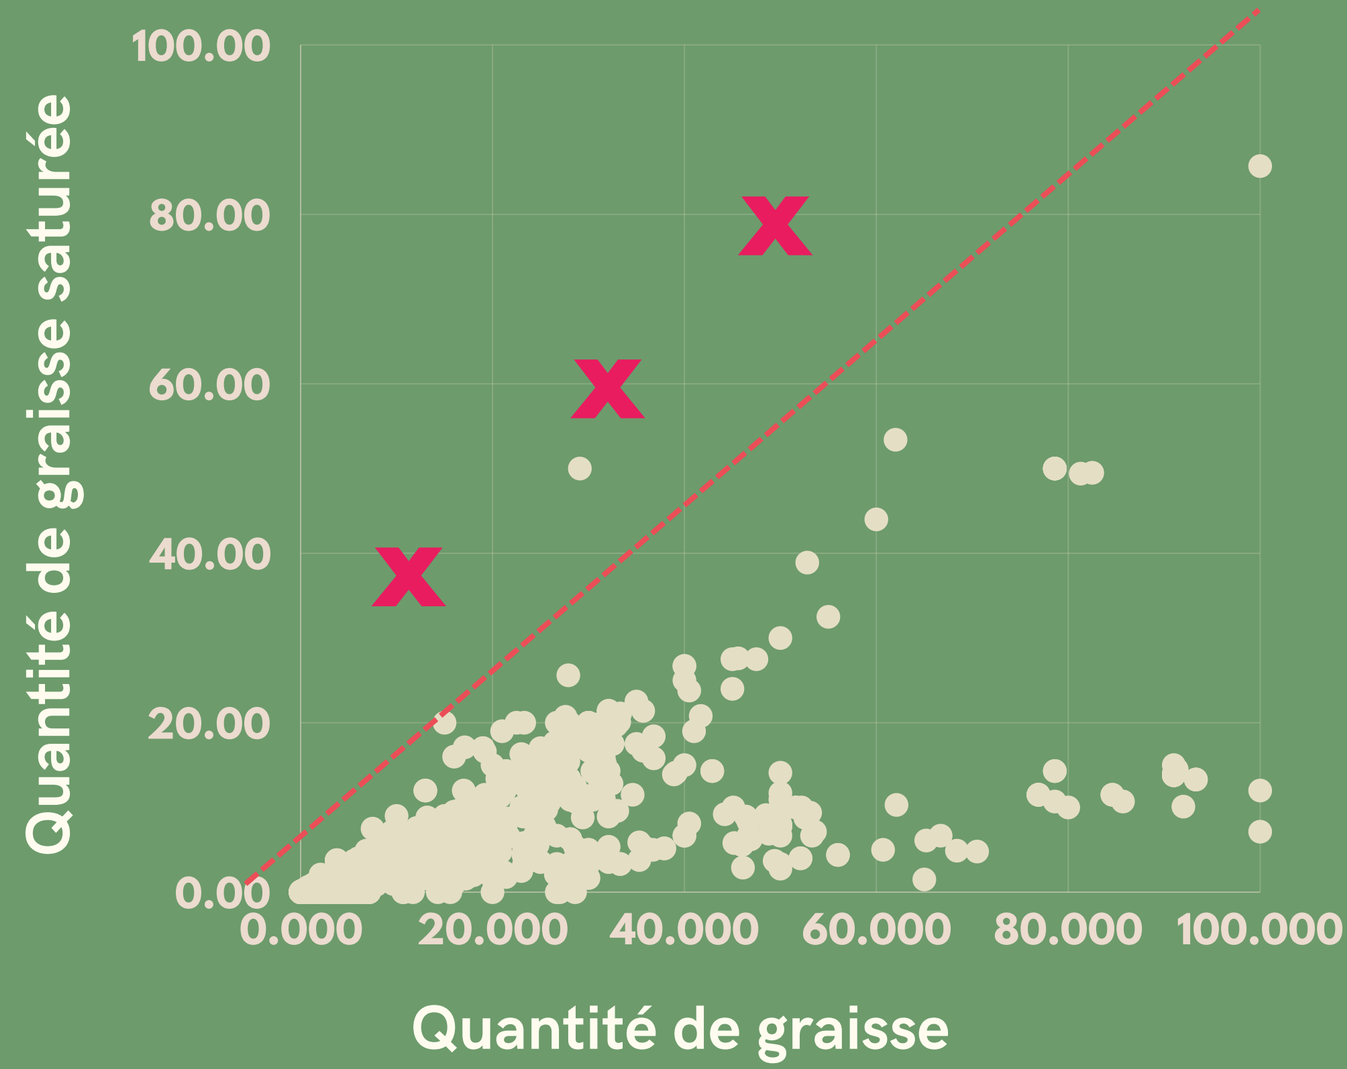
N°1

N°2

N°3

N°4

Approche métier
variables nutritives



Identification des valeurs aberrantes

N°1

N°2

N°3

N°4

Approche métier
variables nutriscore et classe

Boissons			Solides		
score			score		
≠ Eau	X	A	> -1	X	A
> -1	X	B	>2 ou <0	X	B
>9 ou <2	X	C	>10 ou <3	X	C
>19 ou <10	X	D	>18 ou <11	X	D
<20	X	E	<19	X	E

Identification des valeurs aberrantes

N°1

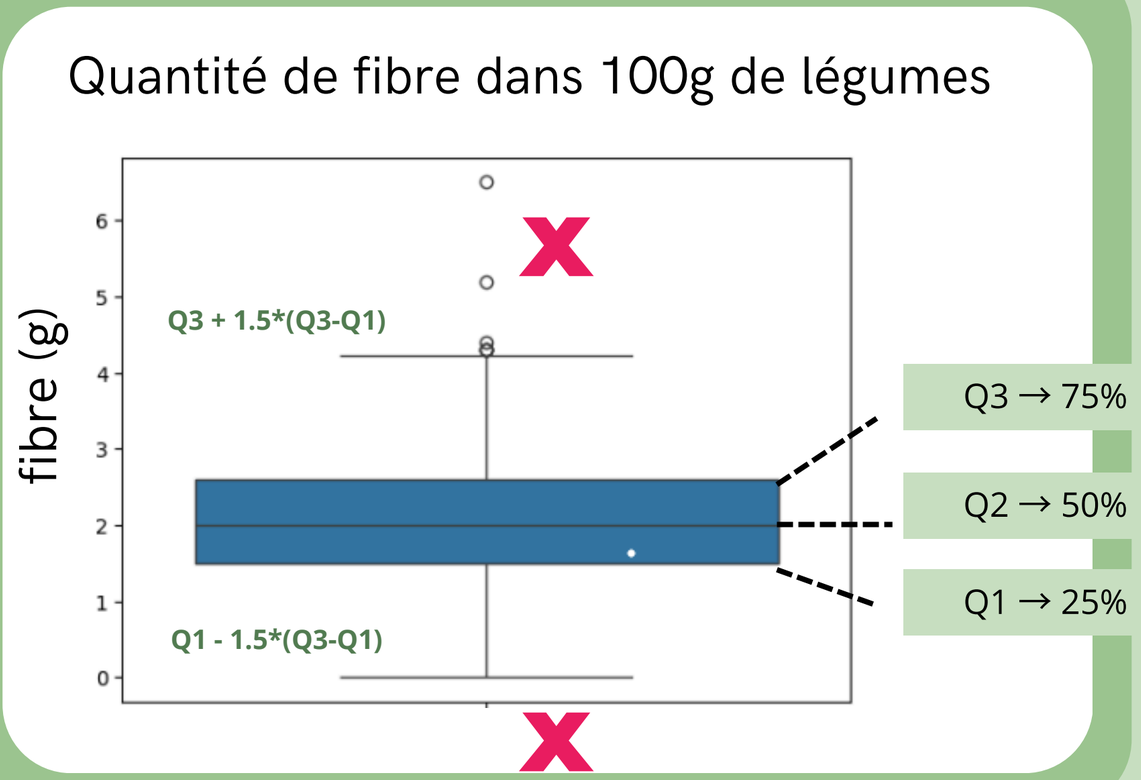
N°2

N°3

N°4

Approche statistiques et métier
variables nutritives

Regroupement par type de produits





Exploration
des données

Nettoyage
des données

Filtre

Identification des valeurs aberrantes

Gestion des valeurs manquantes

Analyses

Imputation des valeurs manquantes

1

Approche métier

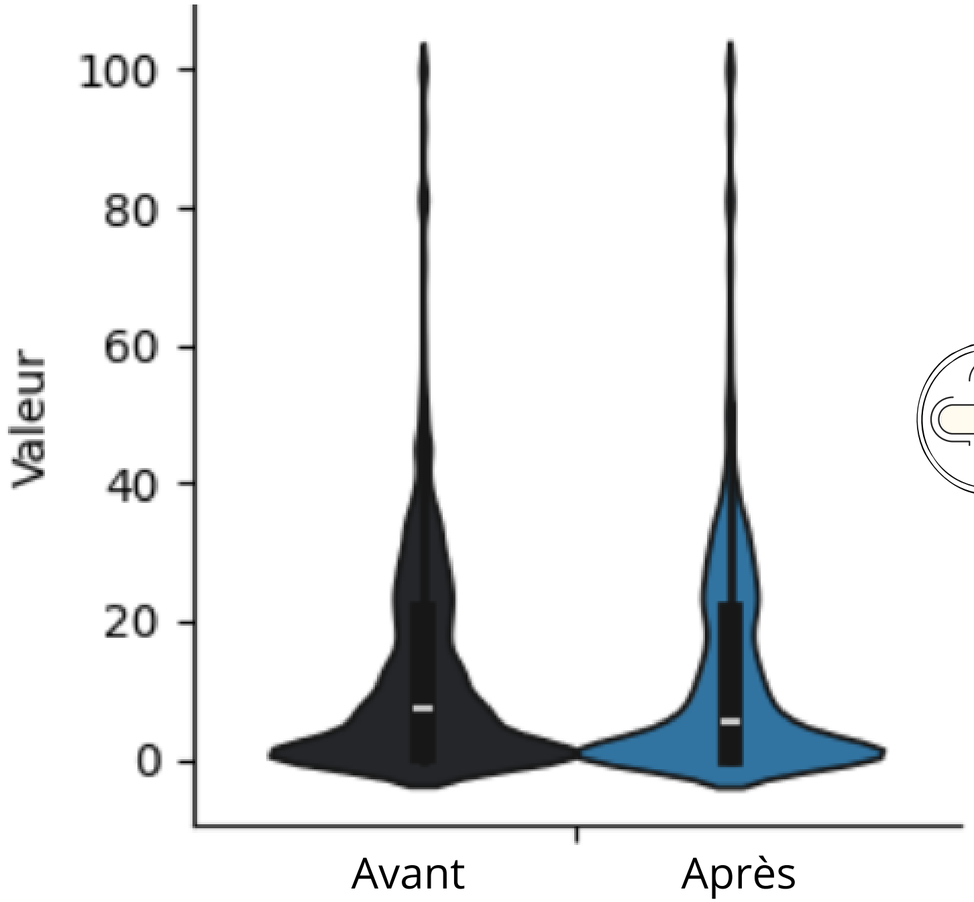
Produits sans fibres

NA → 0 dans la variable fibre

Imputation des valeurs manquantes

Visualisation

Distribution de la variable imputée
avant et après imputation



Test statistique

Test de
Kolmogorov-Smimov

Imputation des valeurs manquantes

1

Approche métier

Produits sans fibres

NA → 0 dans la variable fibre

2

Approche métier + statistique

NA → moyenne calculée par types de produit

3

Approche automatique

NA → imputation par la méthode des plus proches voisins



Exploration des données

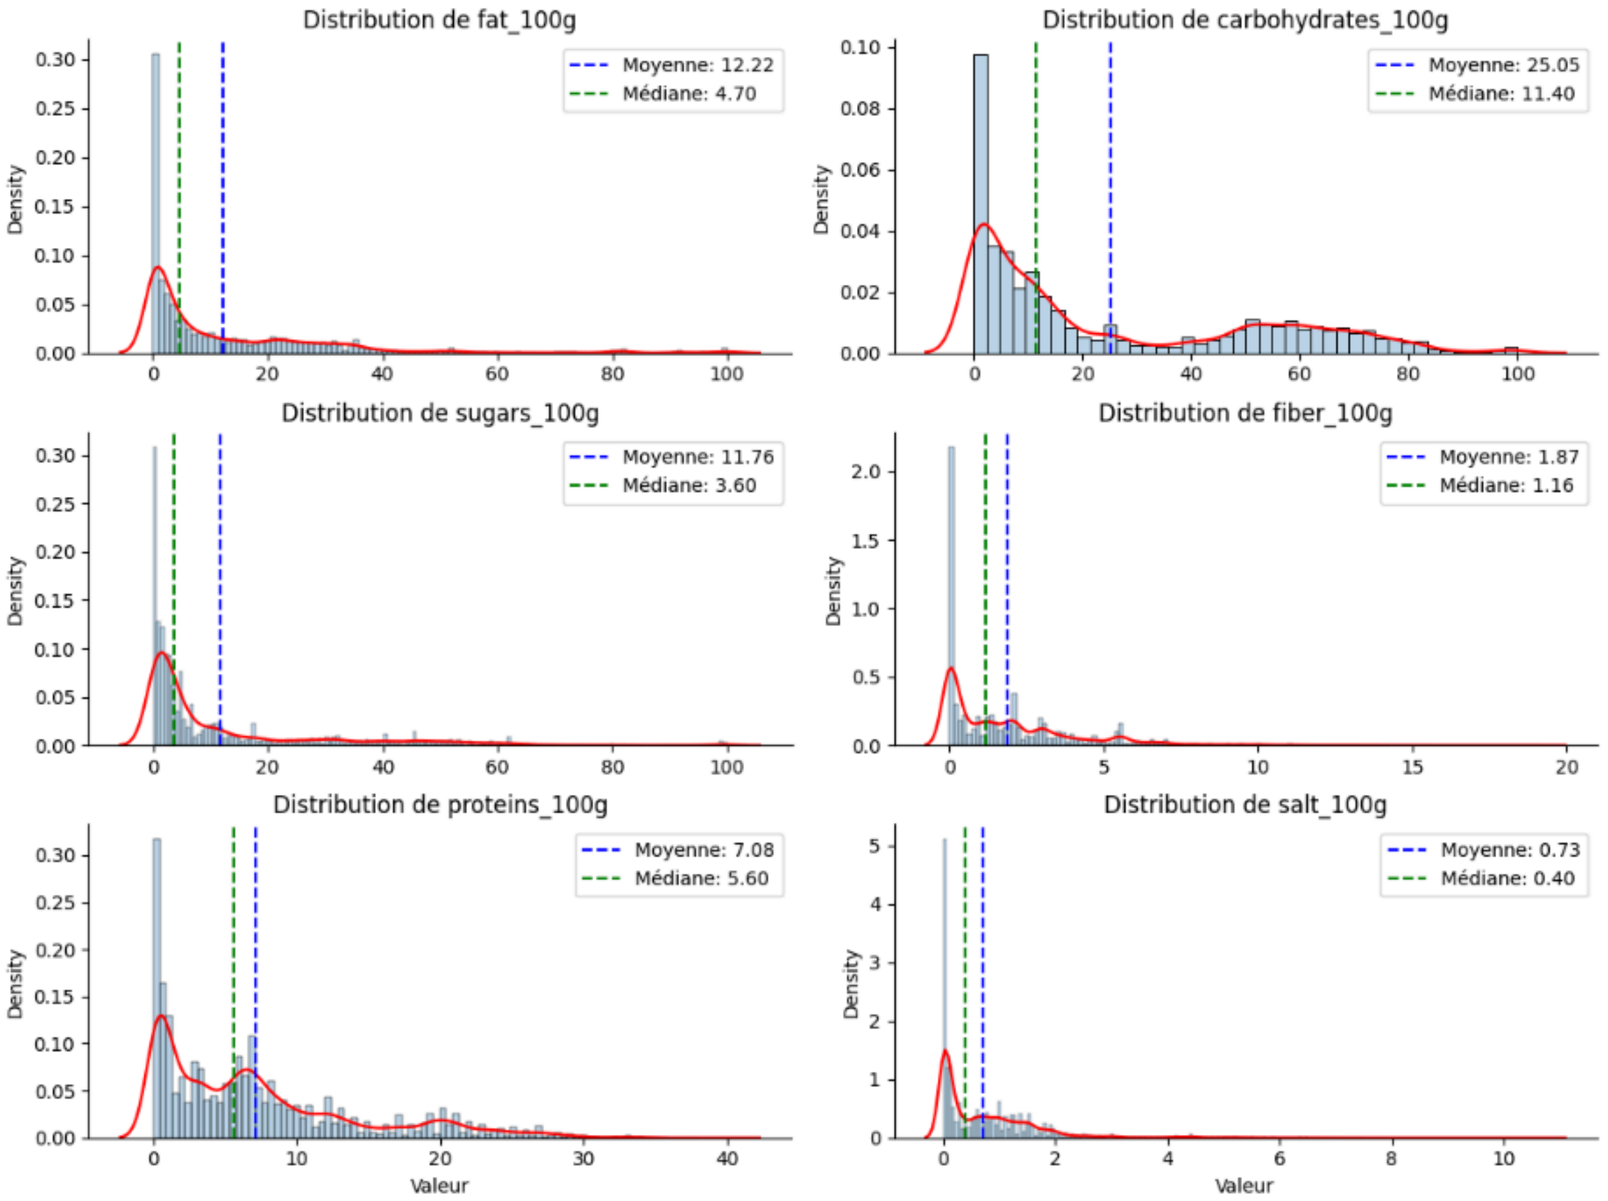
Nettoyage des données

Analyses

Analyses

univariée

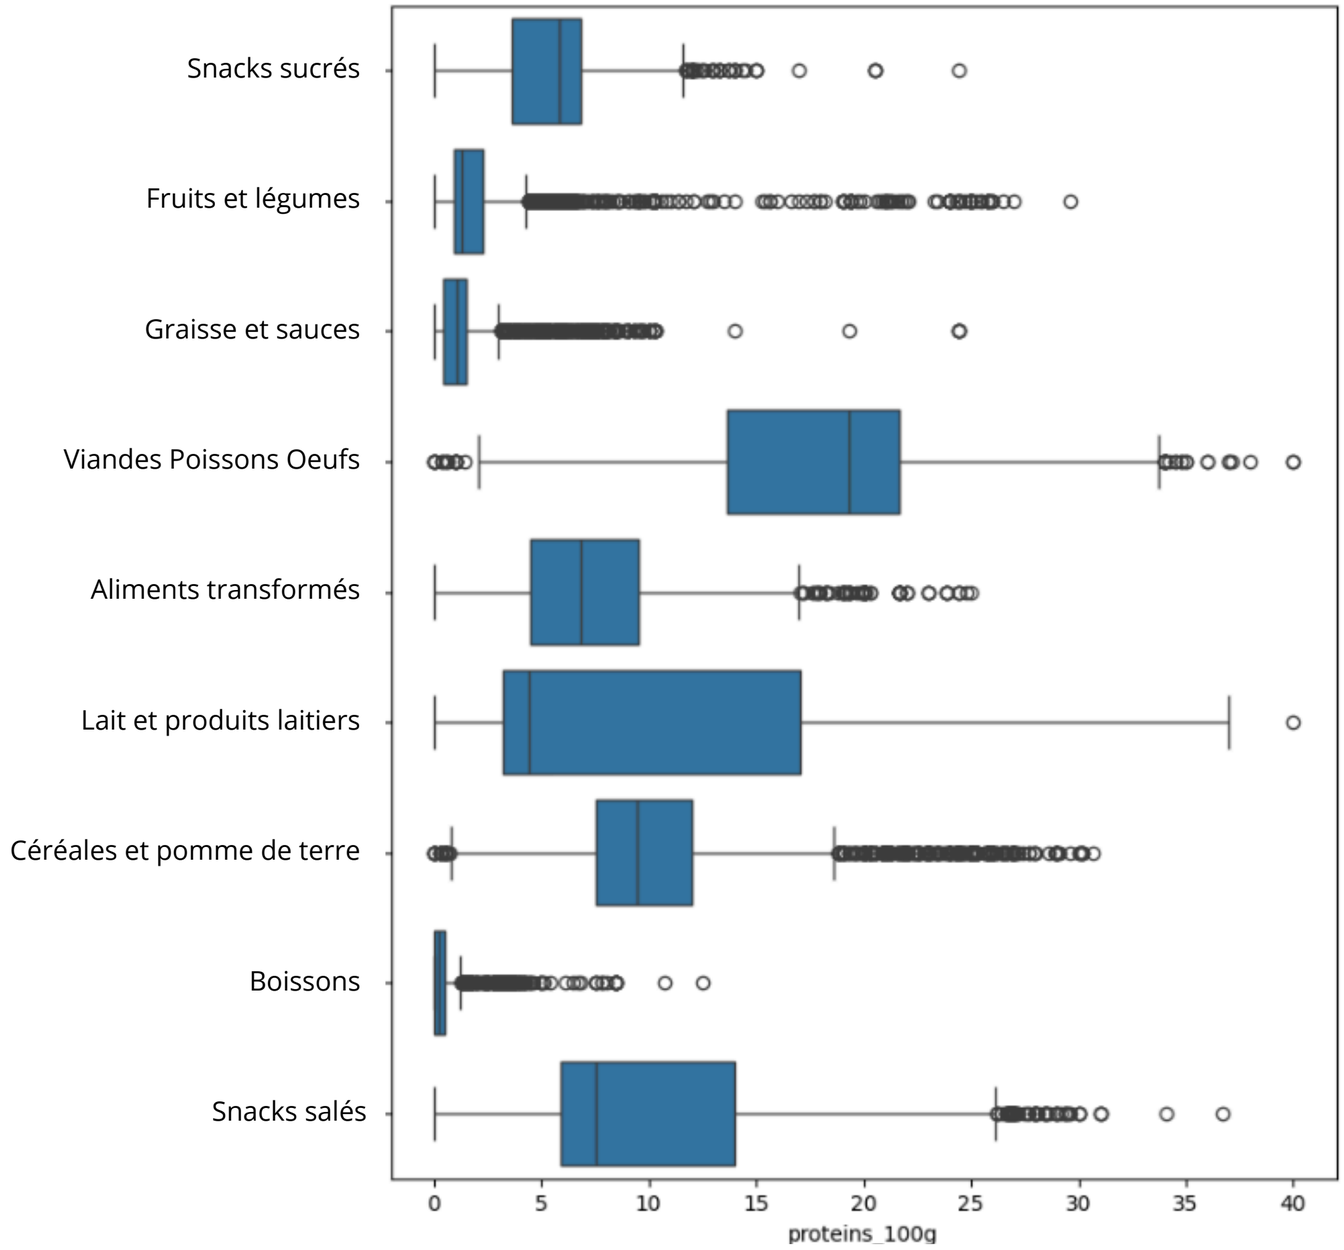
Distribution de la quantité des différents éléments présents dans 100g de produits



Analyses

Relation variables quantitatives et variable cible

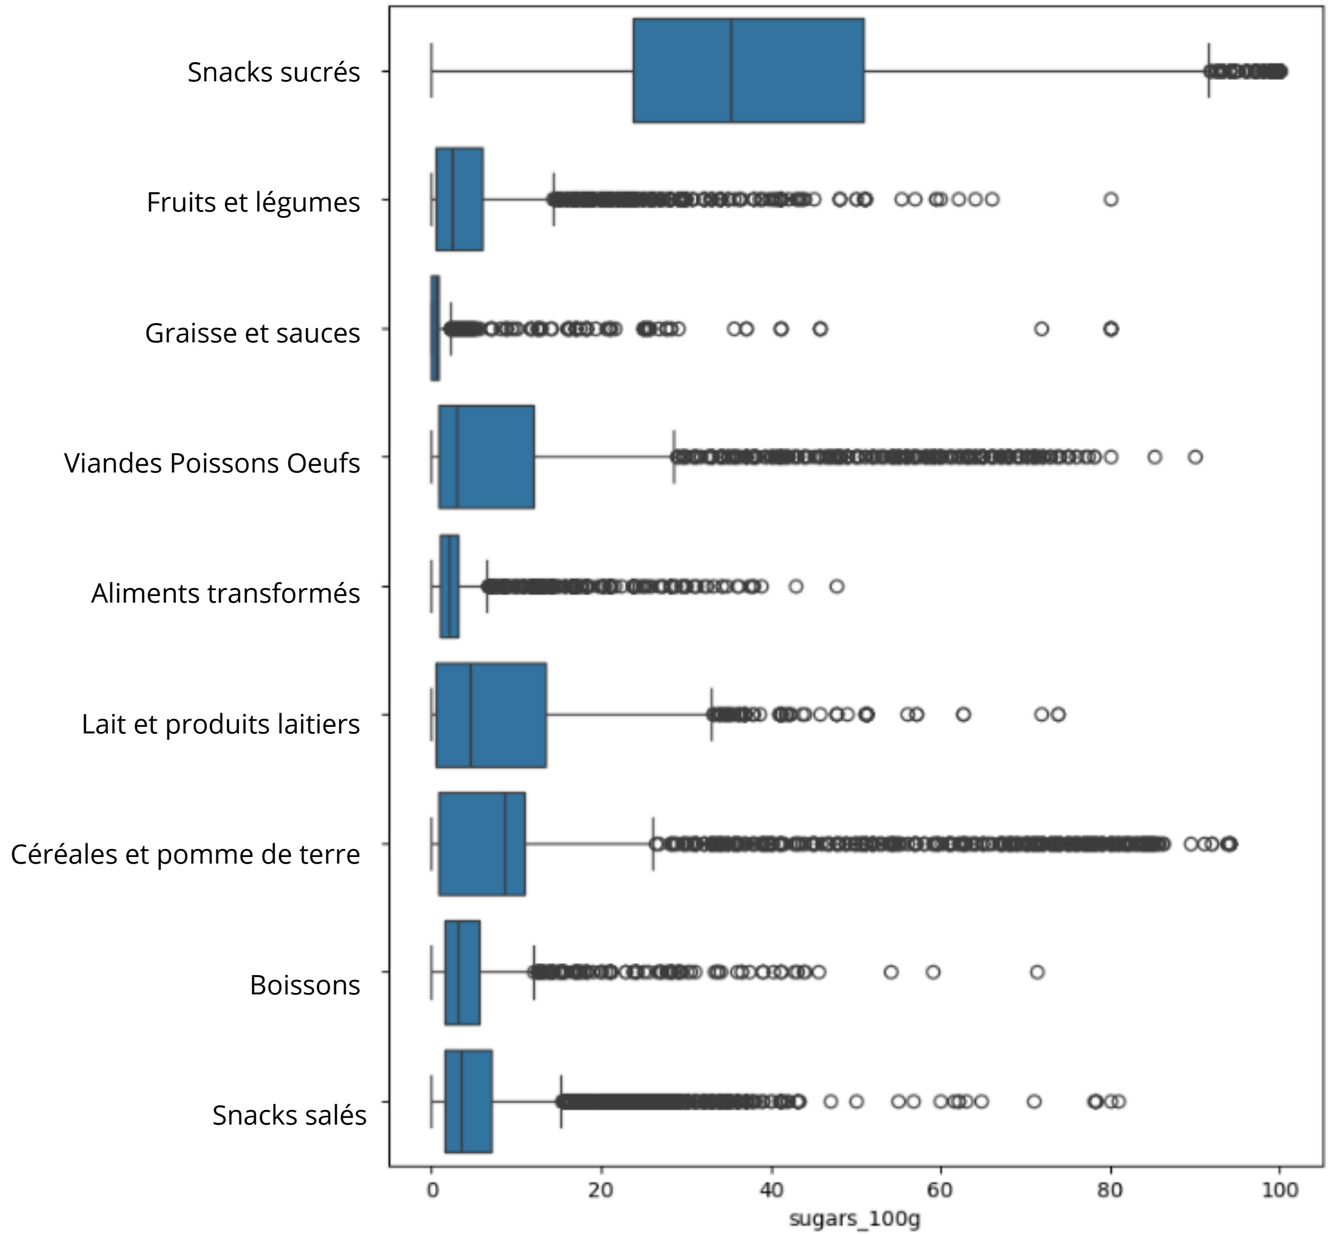
Quantité de protéines pour 100g de produit par groupe de la variable cible



Analyses

Relation variables quantitatives et variable cible

Distribution de la quantité de sucre pour 100g de produit par groupe de la variable cible



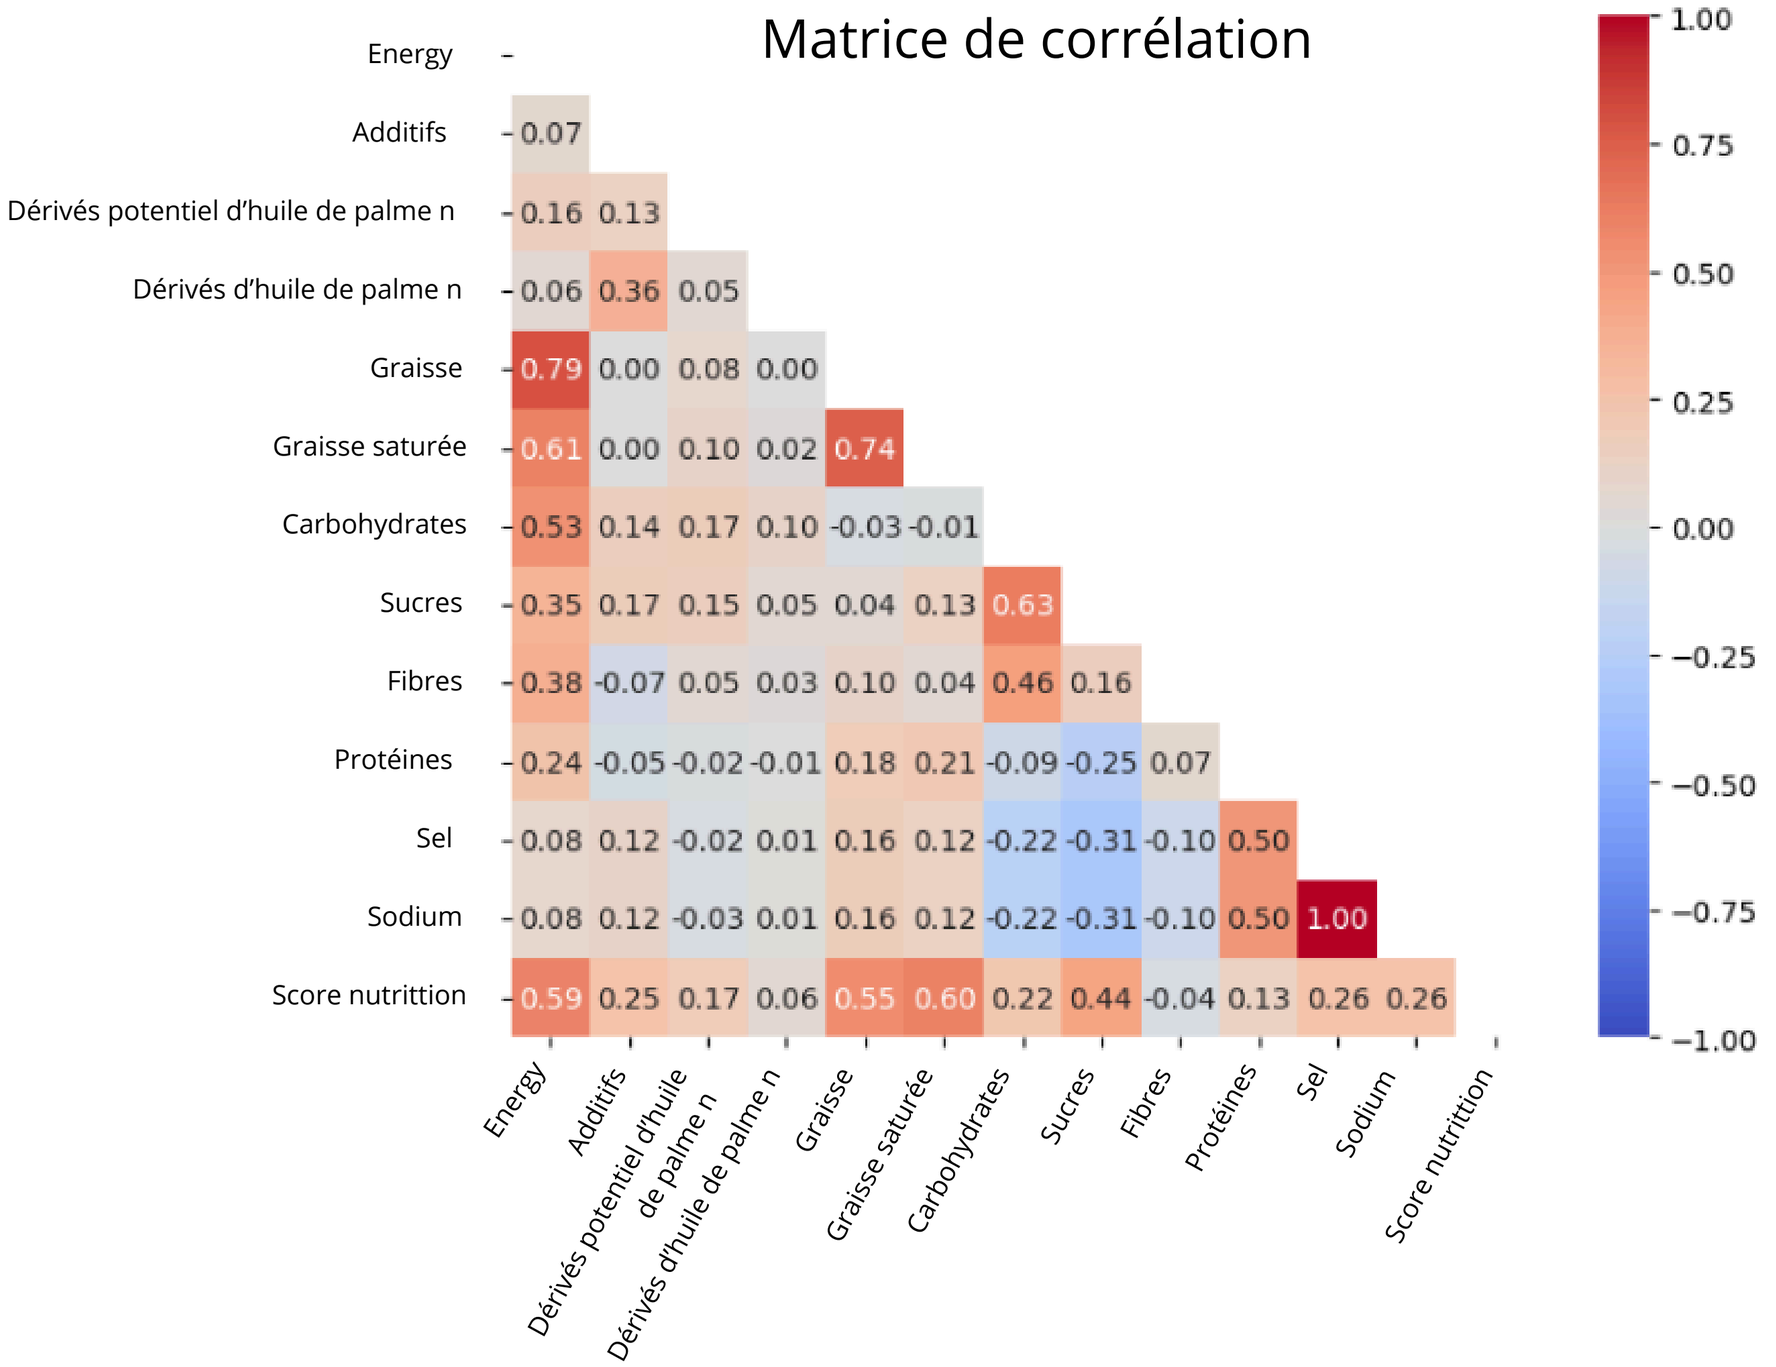
Analyses

Relation variables quantitatives et variable cible

Variable	Significativité du test	Effet
Teneur en sucre, protéine, graisse, sel, sodium, carbohydrate, graisse saturée	✓	**Fort**
Energy	✓	**Fort**
Nutriscore	✓	**Fort**
Additif	✓	**Fort**
Aliment dérivant ou pouvant dérivé de l’huile de palme	✓	**Moyen**

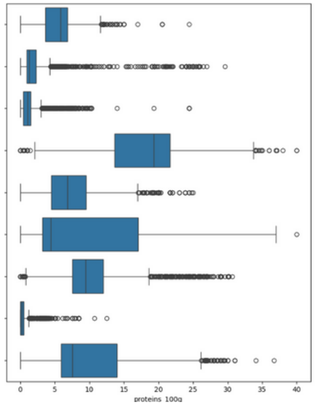
Analyses

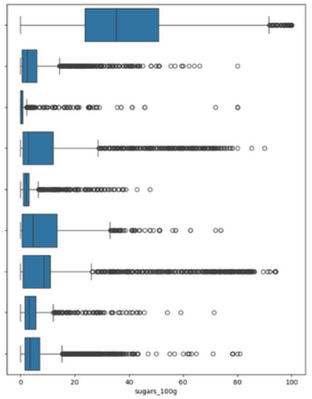
Relation variables quantitatives

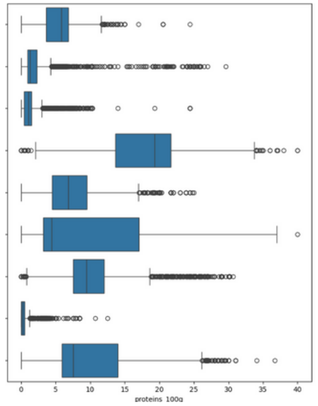


Analyses

Reduction de la dimensionalité des données







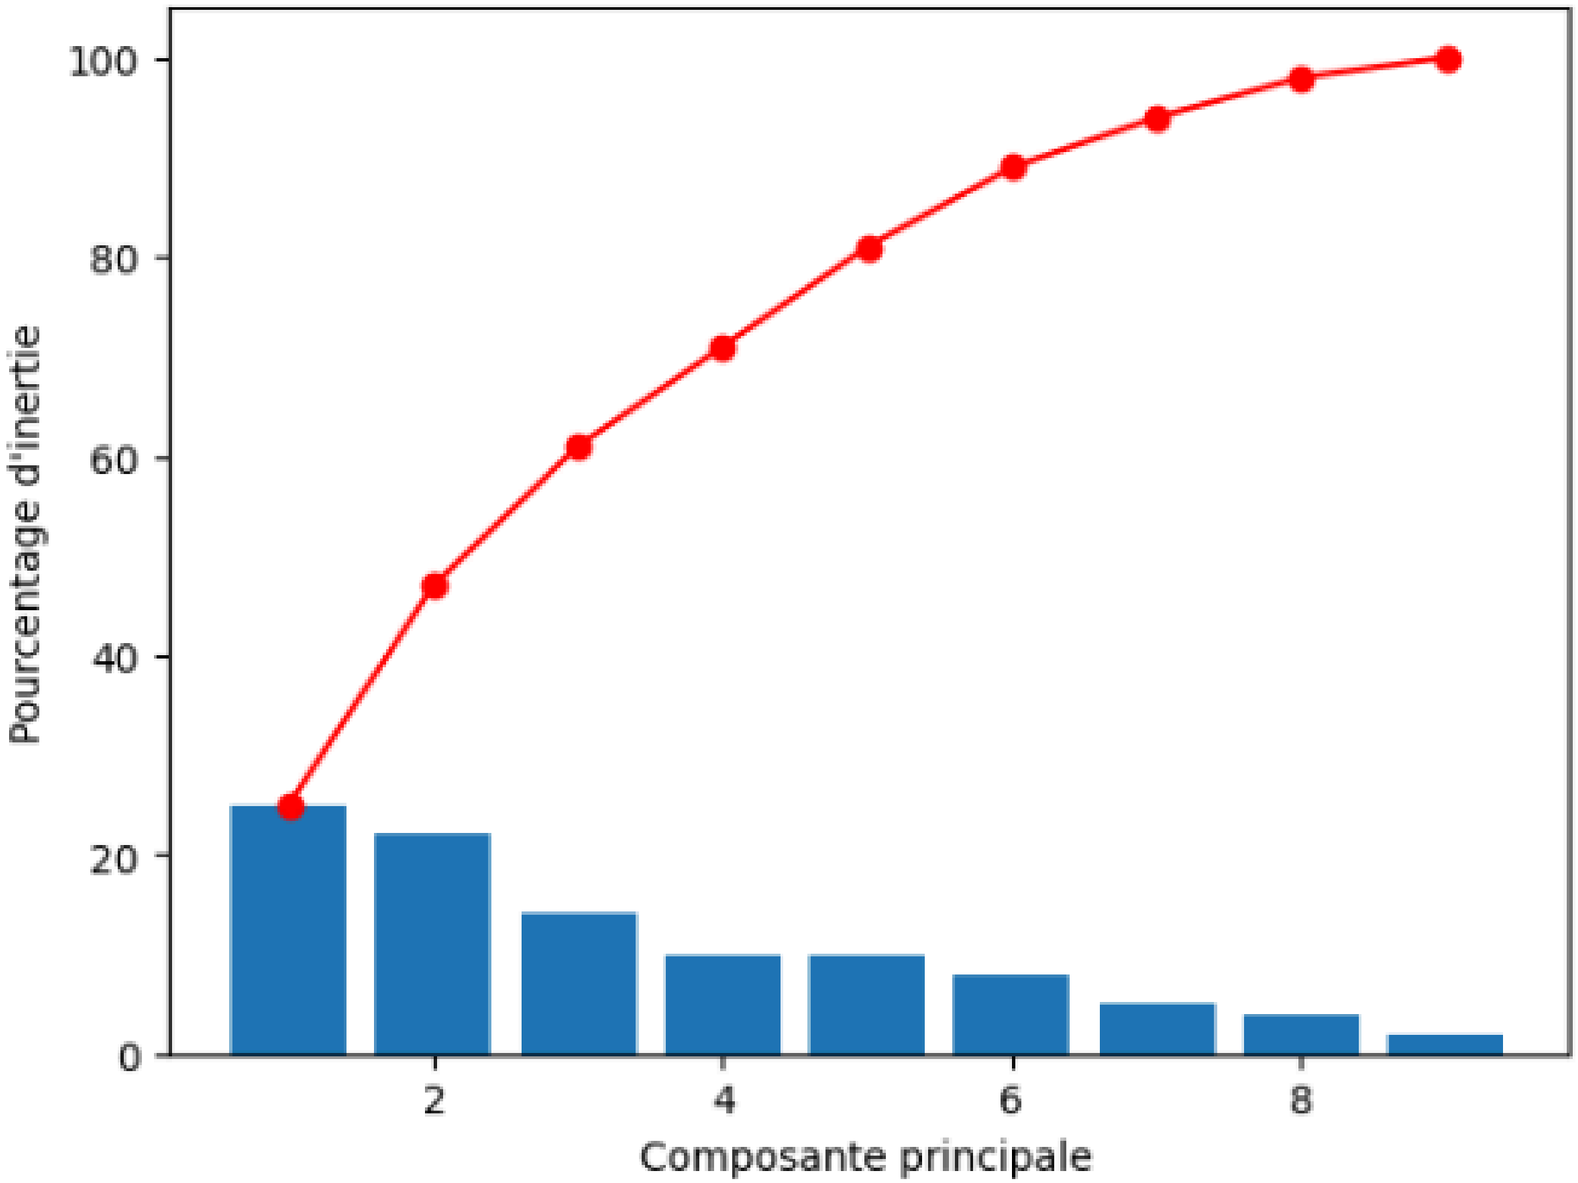
1 représentation qui combine l’ensemble des variables ?

Analyse en composante principale

Analyses

Reduction de la dimensionalité des données

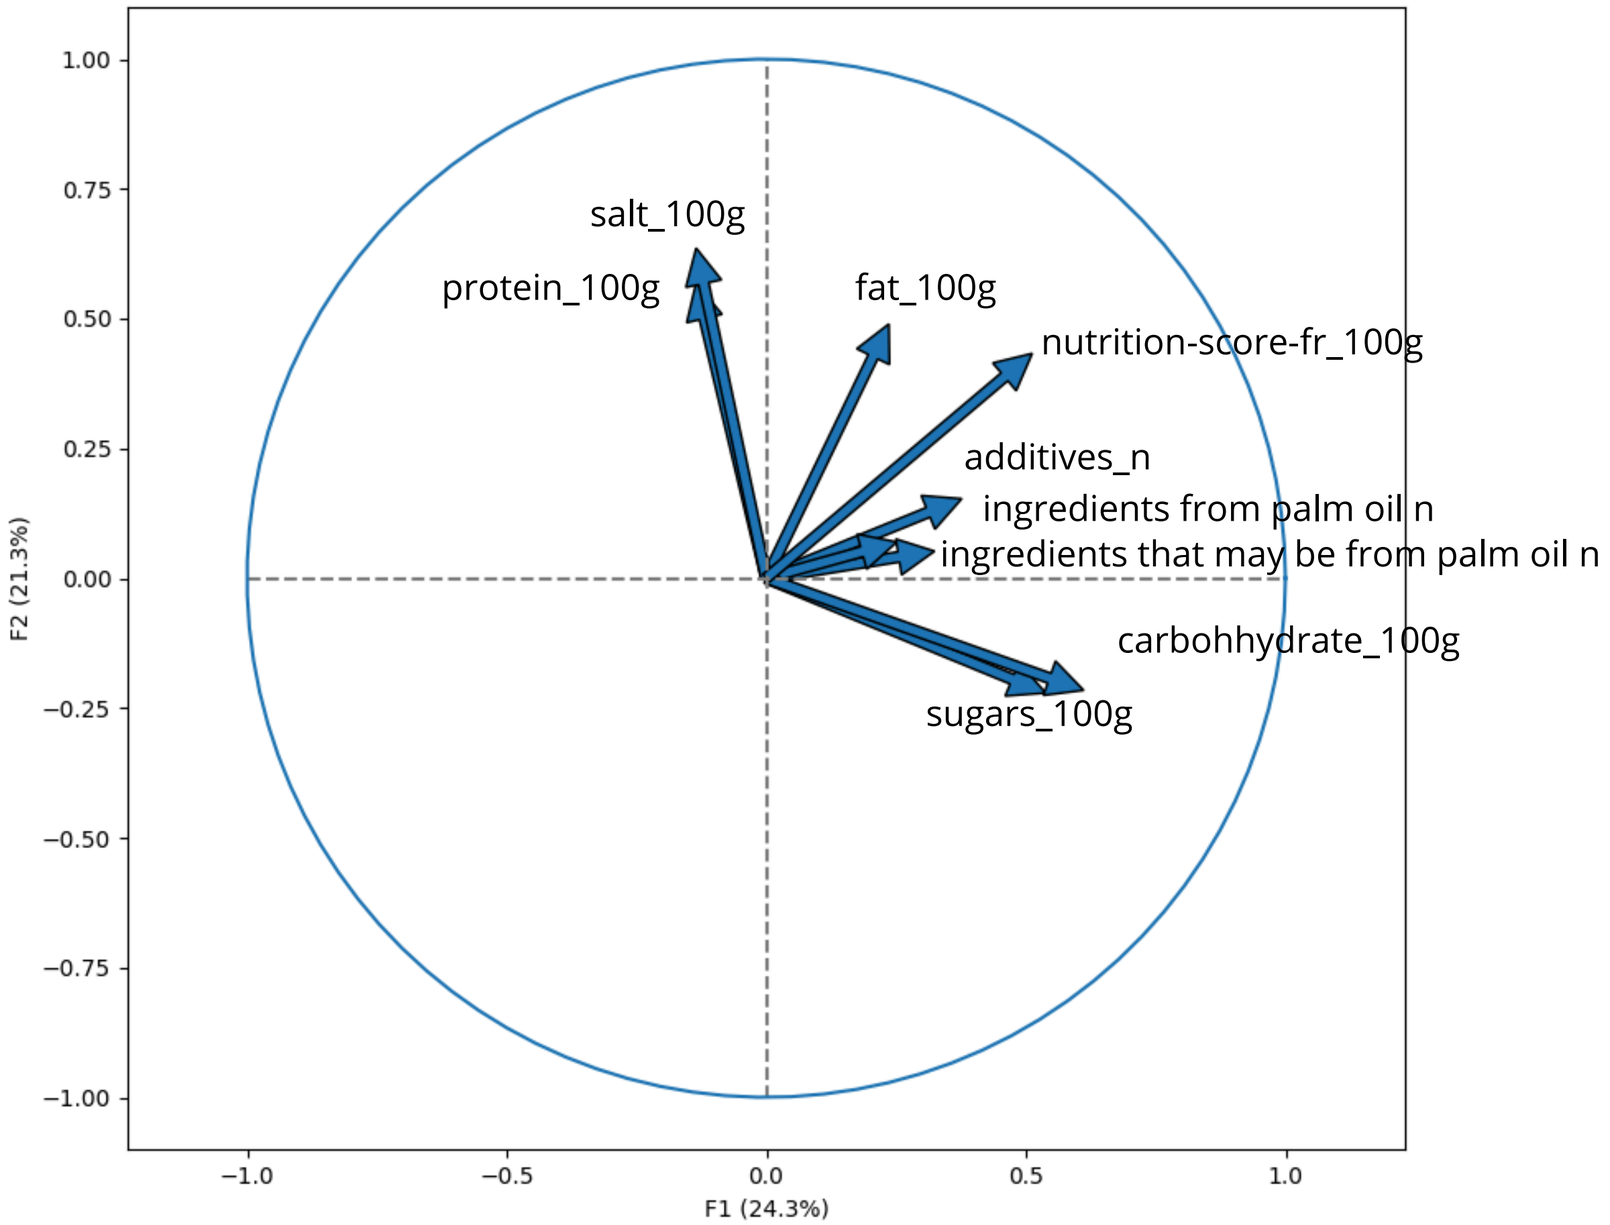
Eboulis des valeurs propres



Analyses

Reduction de la dimensionalité des données

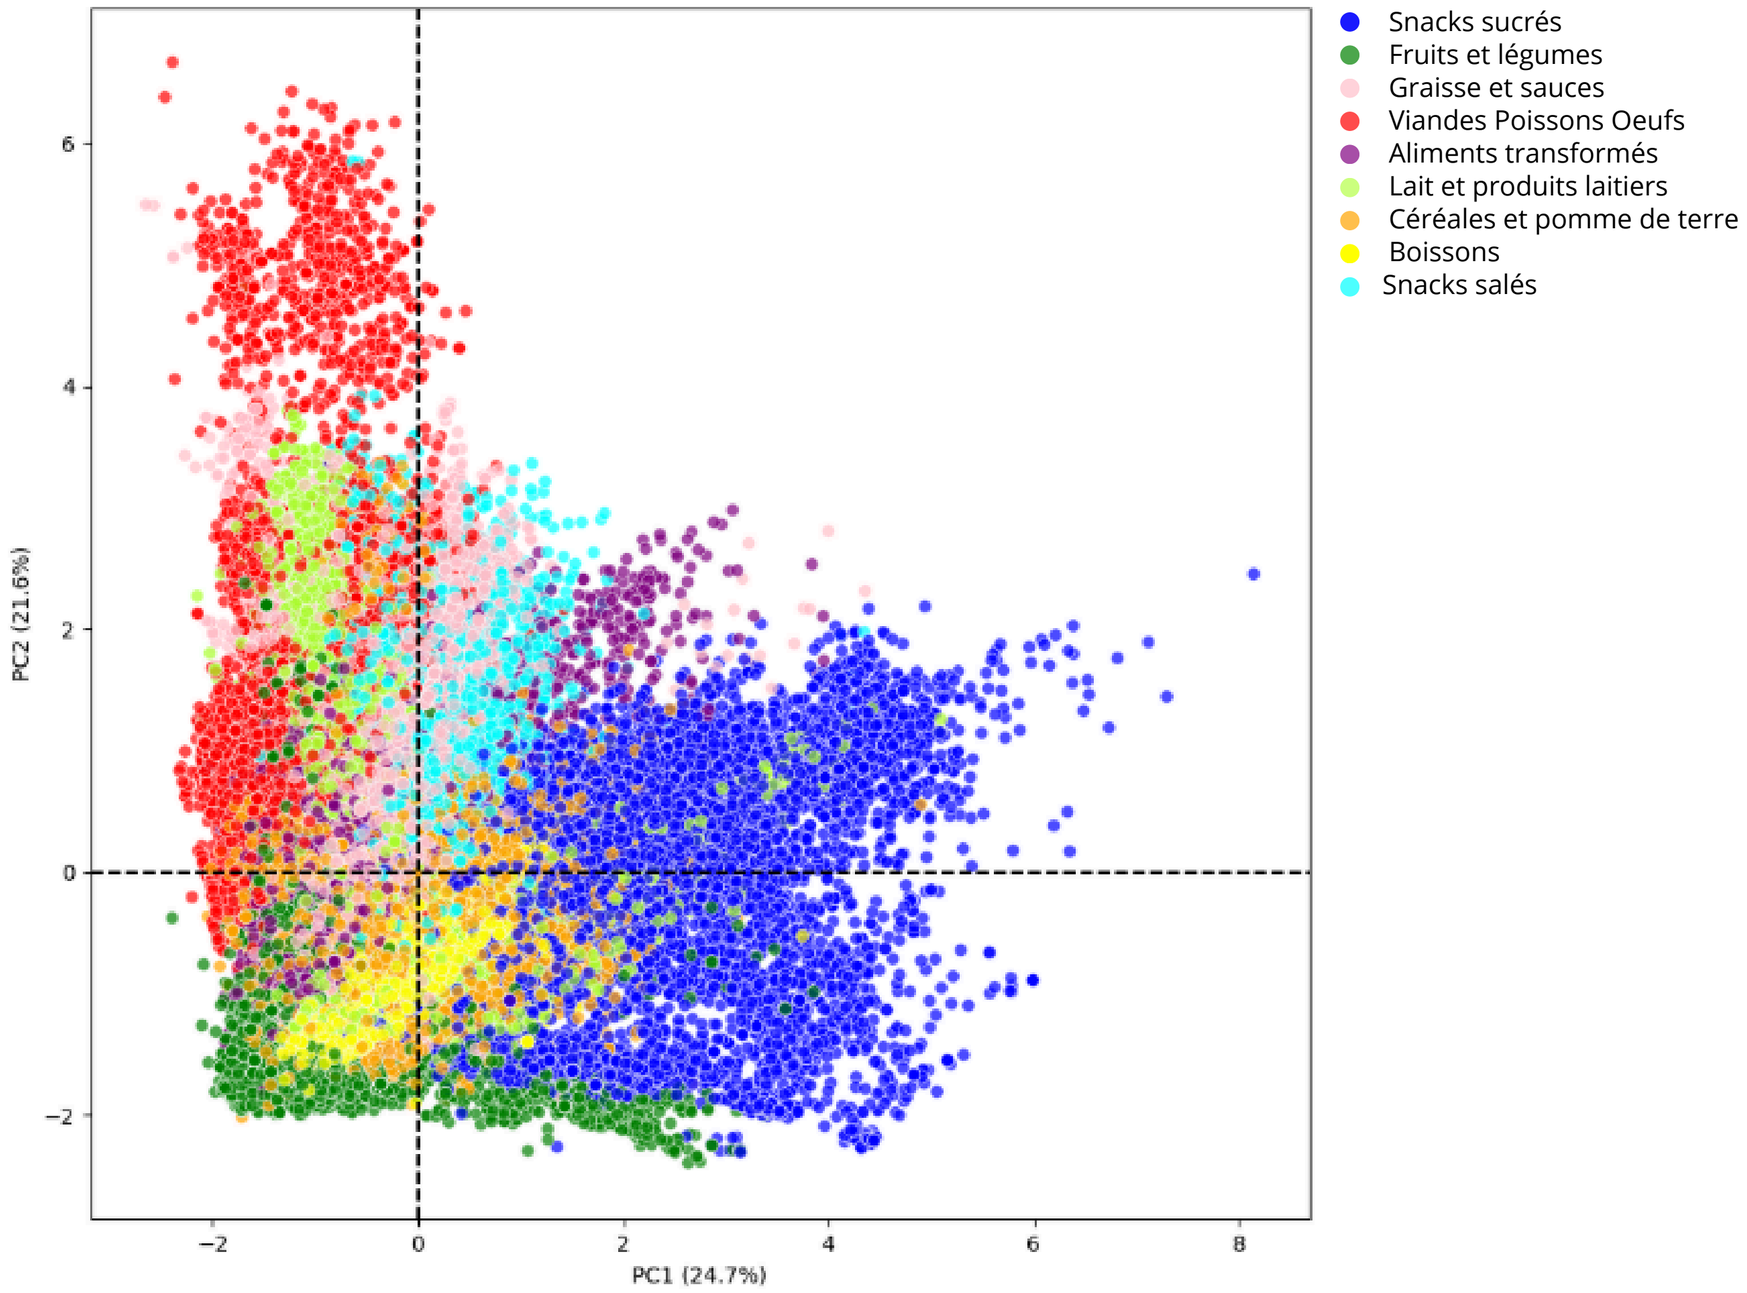
Cercle des corrélations (F1 et F2)



Analyses

Reduction de la dimensionalité des données

Projection des produits sur F1 et F2



Conclusions

Améliorer la base de données d'OpenFoodFact

Proposer des sugestions pour certaines variables

Respecter les grands principes du RGPD

Regroupement des catégories redondantes

Lien fort et significatif entre la variable cible et 8 variables

Organisation cohérente des produits en ACP

Minimisation des données
Objectif clair et défini
Transparence sur les traitements
Attention portée à la qualité des données
Mesures de sécurité

Merci pour votre attention

Santé publique France

open FOOD facts

