City of Seattle

Anticiper les besoins en consommations des bâtiments



Objectifs du projet

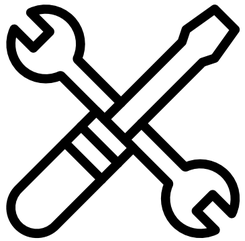
Seattle  Ville Neutre

Prédire les consommations énergétiques

Prédire les émissions en gaz à effet de serre

Etudier l’impact du score ENERGYSTAR









Présentation des données

Feature engineering

Modélisation

Résultats

Présentation des données



Identification



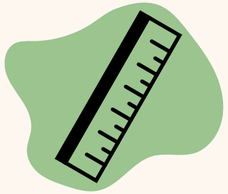
Localisation



Type



Nombre bâtiments et étages



Surface



Profil énergétique

Données : 2016

Cleaning

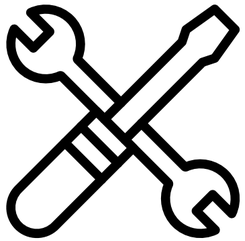


propriétés non conformes

Propriétés destinées à l'habitation uniquement

Propriétés avec données anormales









Présentation des données

Feature engineering

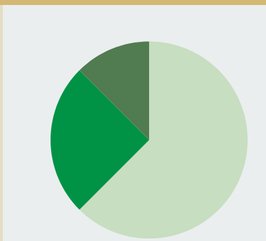
Modélisation

Résultats

Création de nouvelles variables

N°1
N°2
N°3
N°4
N°5
N°6

TYPE D'ENERGIE

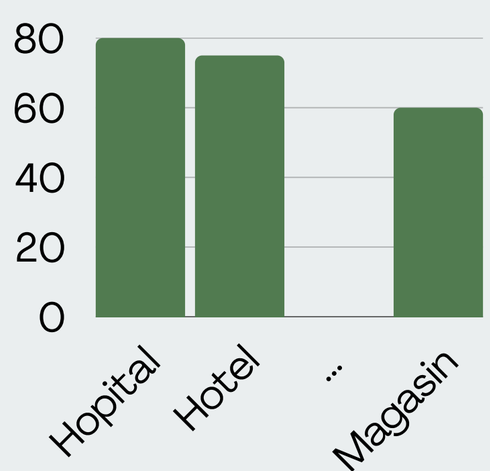


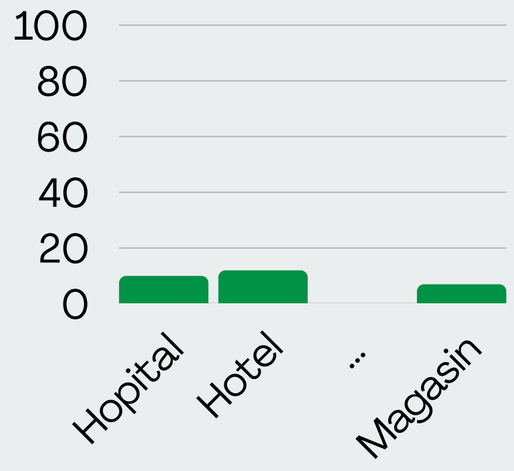
1 **Pour chaque propriétés :**
calcul des proportions des différents types d'énergie utilisée

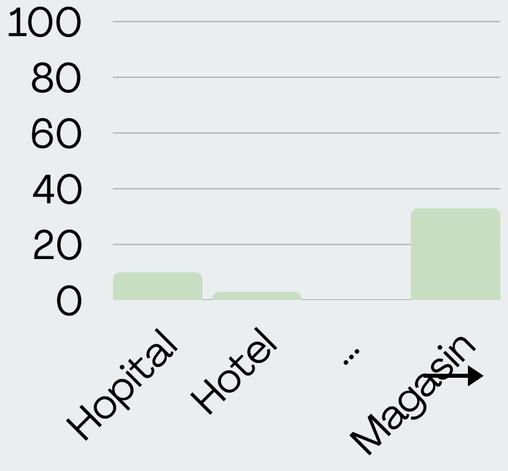
2 **Pour chaque type d'utilisation:**
calcul de la moyenne de la proportion d'énergie utilisée sur les données d'entrainement

Entrainement : Fit_Transform

Test : transform







Création de nouvelles variables

N°1

N°2

N°3

N°4

N°5

N°6

TYPE DE RUE

Catégories	Motifs	Occurence	Exemples
Avenue	Ave Avenue	275	5422 Shilshole **Avenue** NW 6136 6th **Ave** S
Street	St Street	221	401 LENORA **ST** 515 Madison **Street** S. Othello **St.**
Way	Way	117	W Marginal **Way** SW Lake City **Way** Ne
Other		60	

Création de nouvelles variables

N°1

N°2

N°3

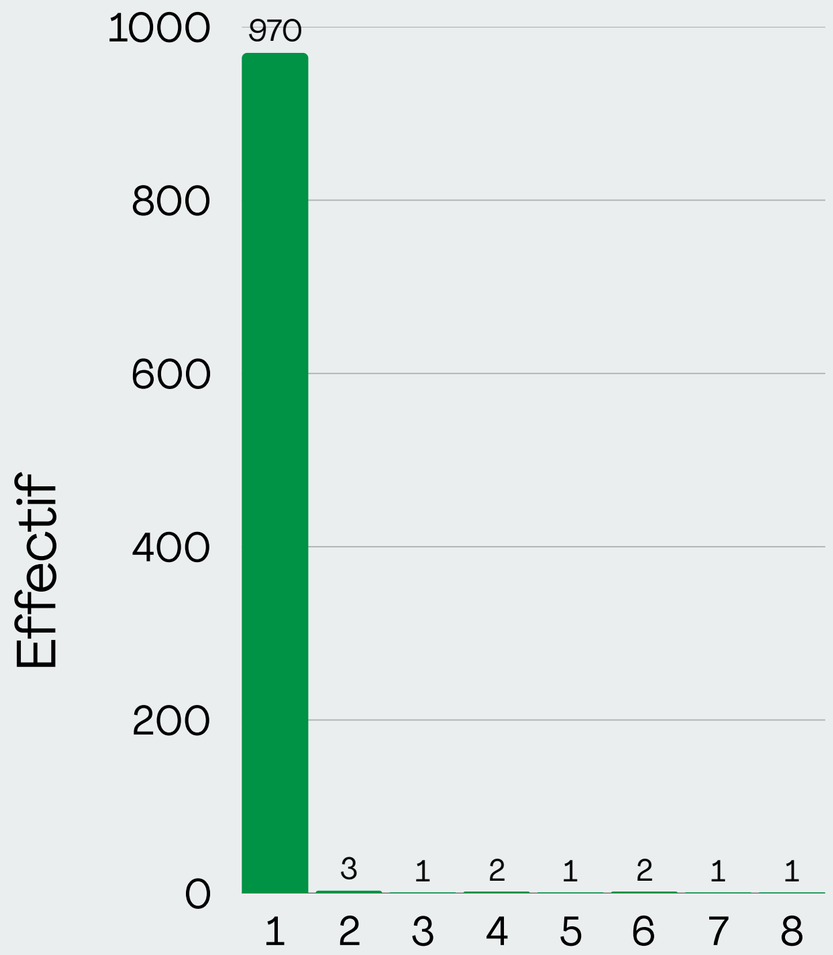
N°4

N°5

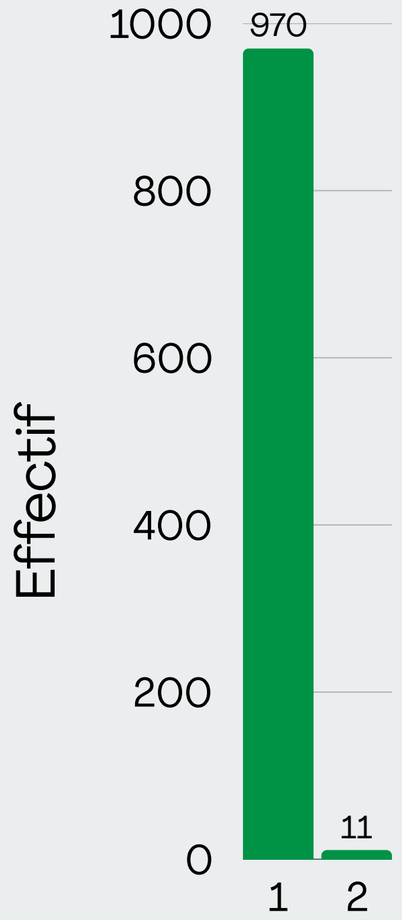
N°6

NOMBRE DE BÂTIMENTS

Variable quantitative



Variable qualitative

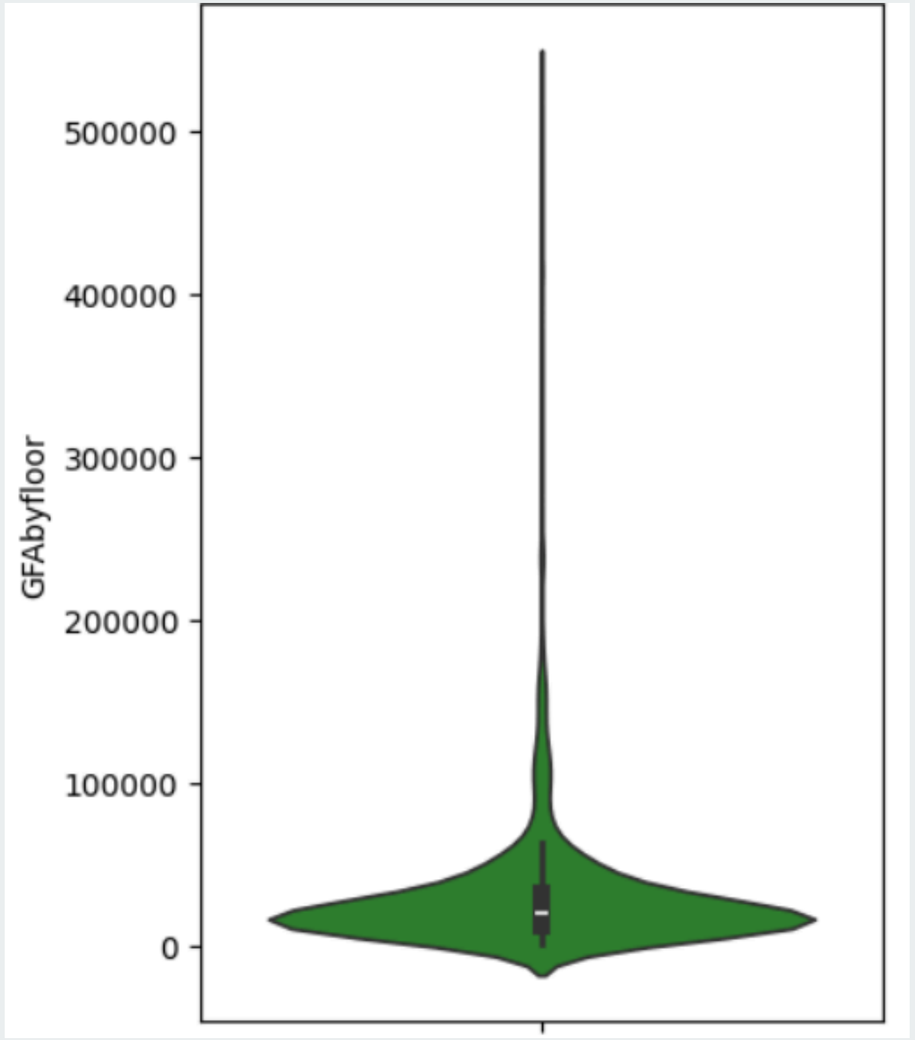


N°1
N°2
N°3
N°4
N°5
N°6

SURFACE

Création de nouvelles variables

Surface par étages









Création de nouvelles variables

N°1

N°2

N°3

N°4

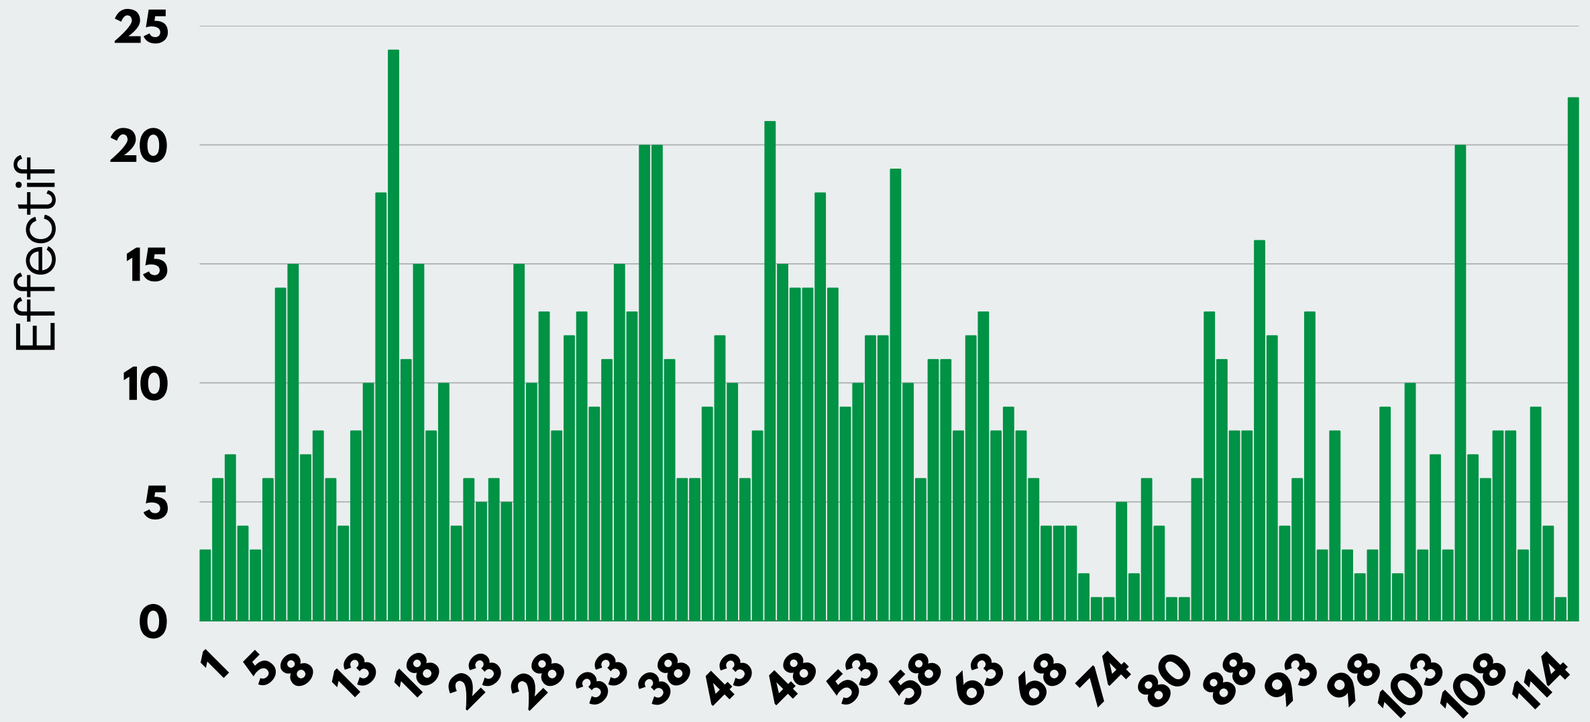
N°5

N°6

AGE DE LA PROPRIETE

AGE = 2016 - Année de construction

Distribution



Création de nouvelles variables

N°1

N°2

N°3

N°4

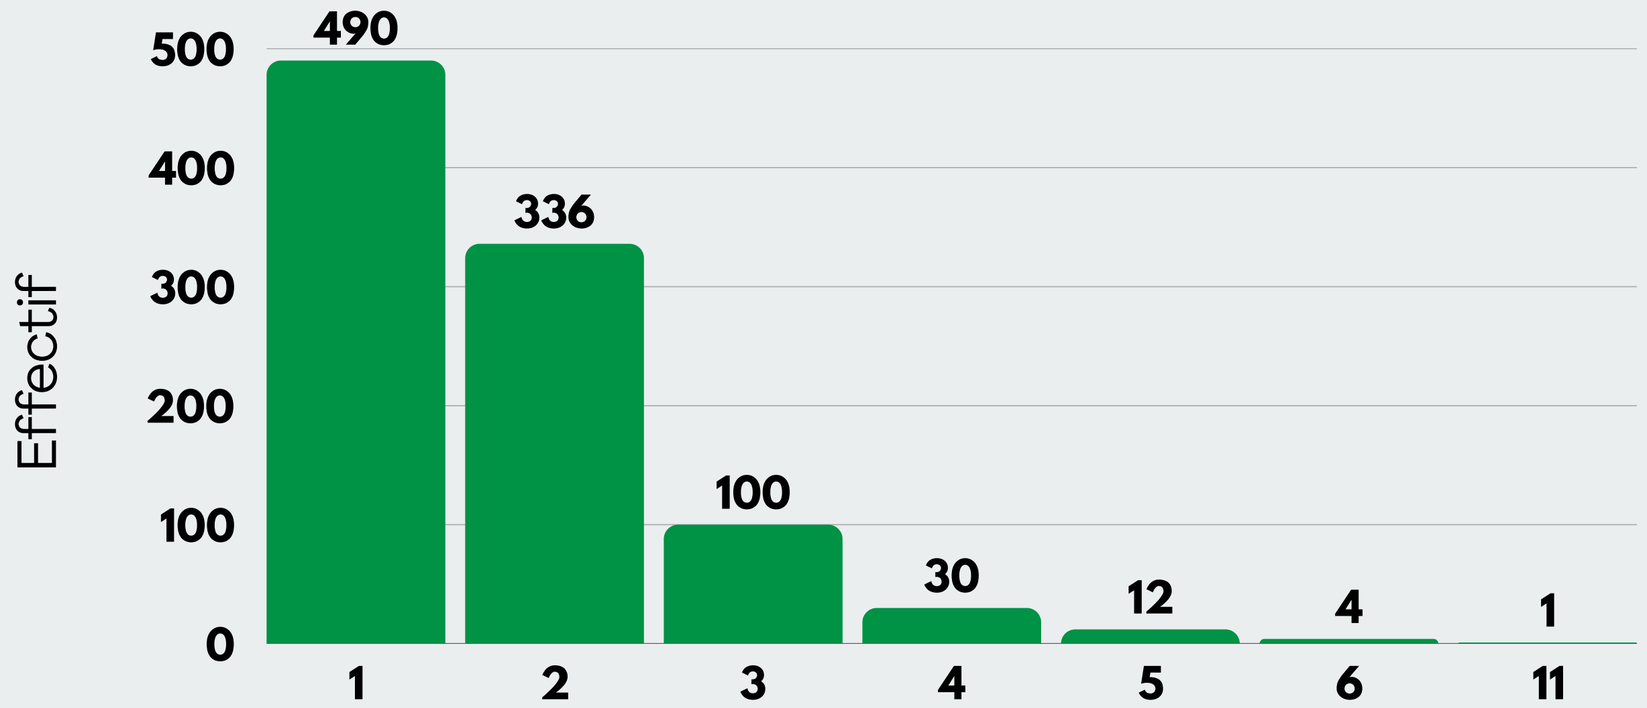
N°5

N°6

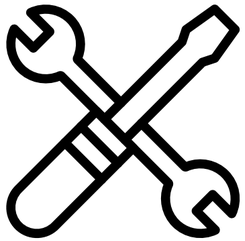
NOMBRE DE TYPE D'USAGE

Nombre = count(List usage)

Distribution











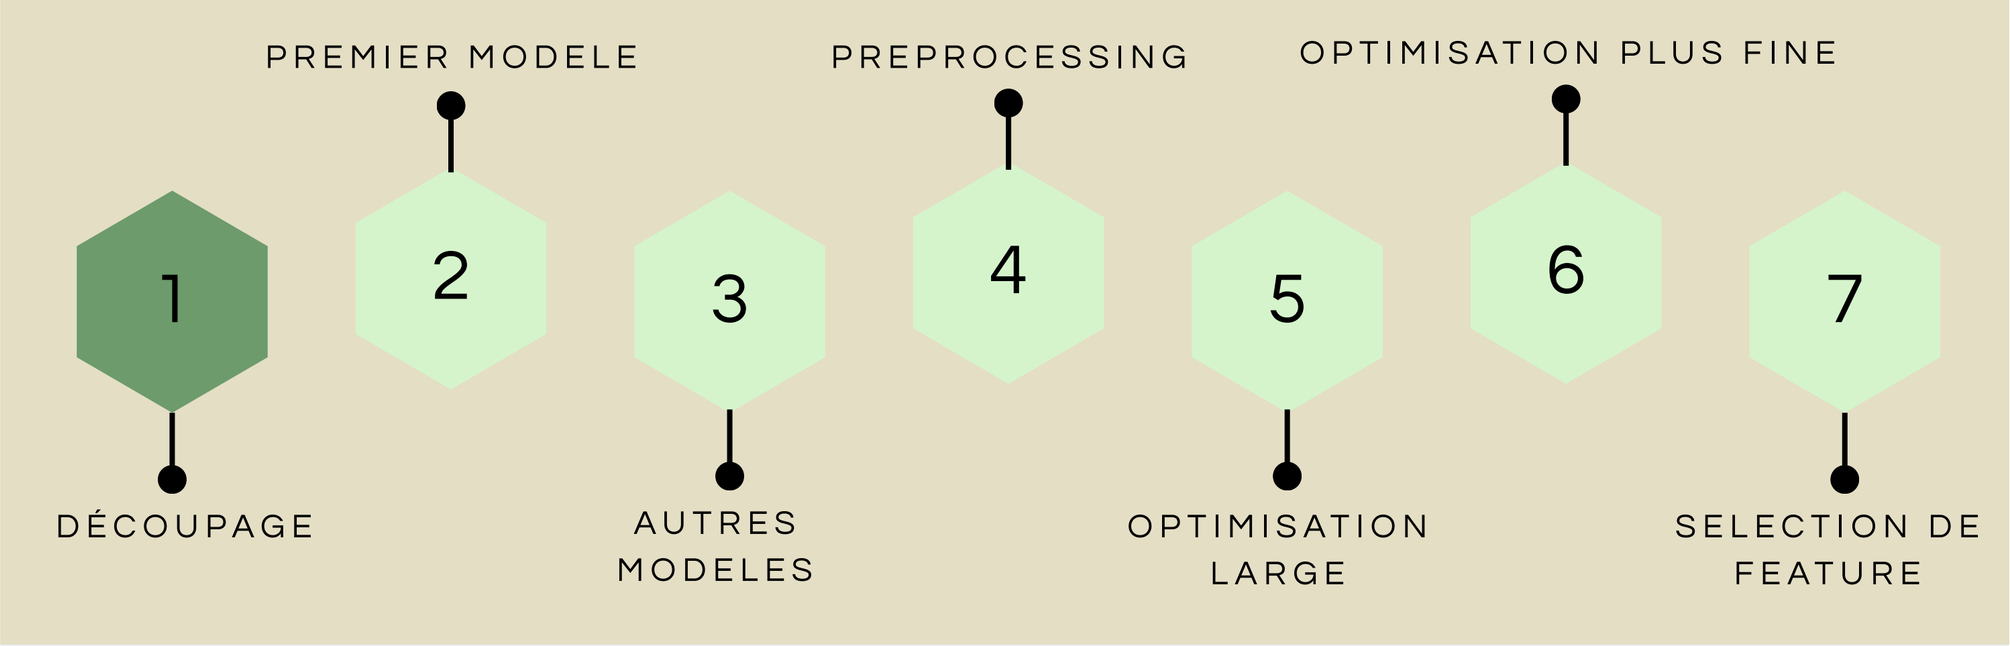
Présentation des données

Feature engineering

Modélisation

Résultats

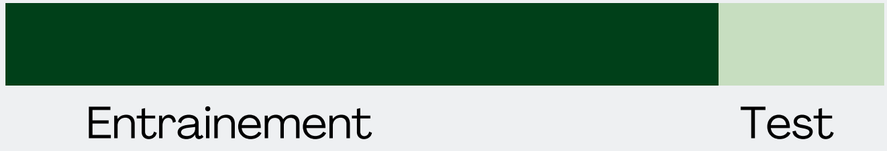
Modélisation



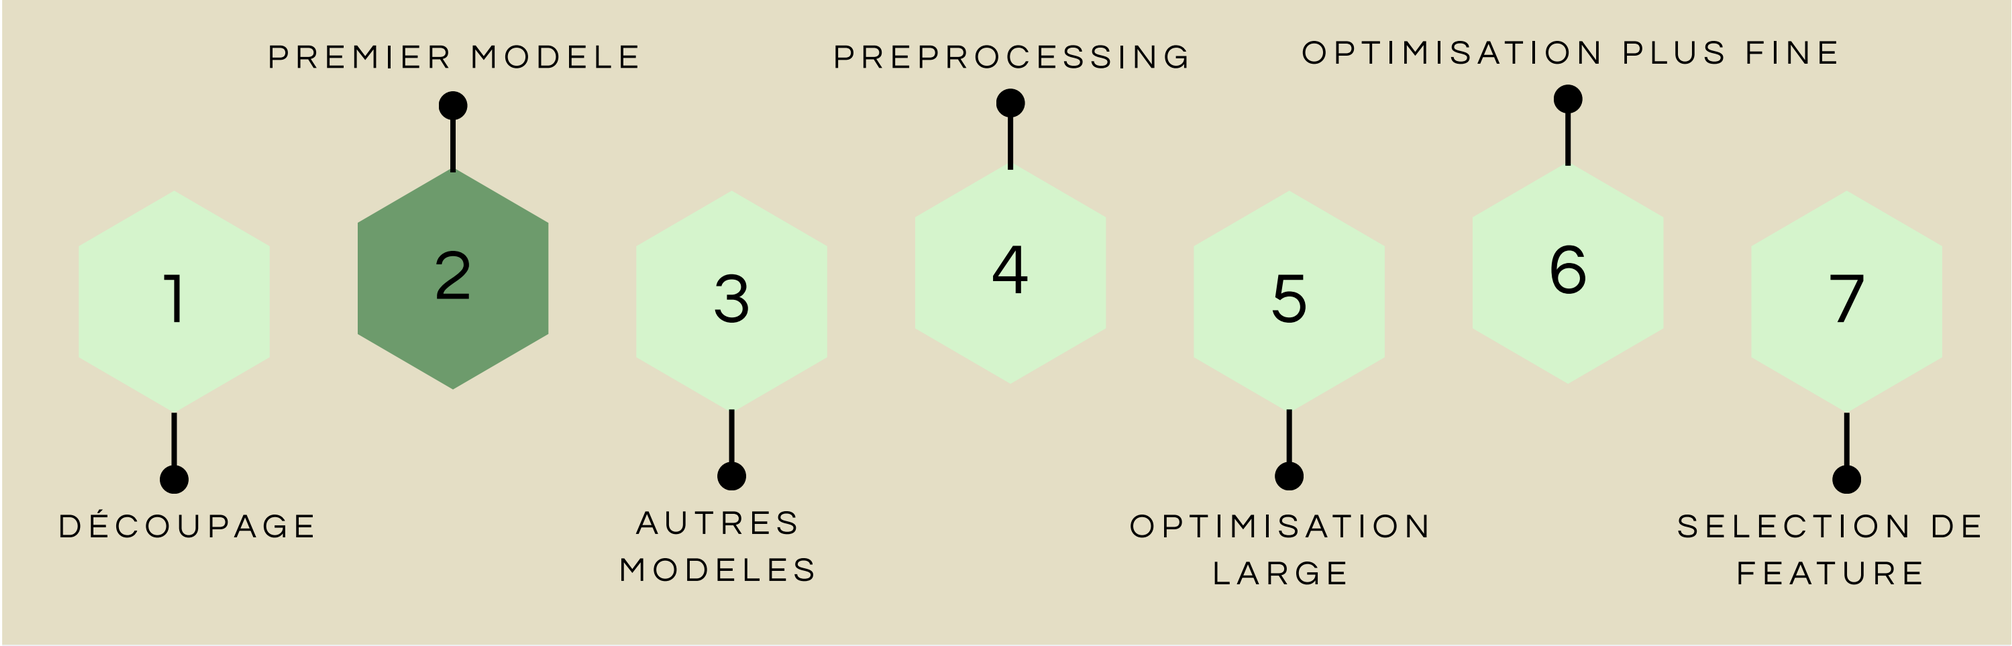
Classe	Valeur
Quantile 1	[0-7.4.10^5]
Quantile 2	(7.4.10^5-1.1.10^6]
Quantile ...	
Quantile 9	(6.4.10^6-9,5.10^6]
Quantile 10	(9.5.10^6-1.7.10^7]

Classement des propriétés par quantile

Découpage par stratification



Modélisation



Normalisation (Robust) + Encodage (One Hot encoder)

	Train	Val **mean**	Val Std
R^2	0.66	0.18	0.73
MAE	5.50	6.20	0.72
RMSE	13.79	15.57	4.67

Régression Linéaire

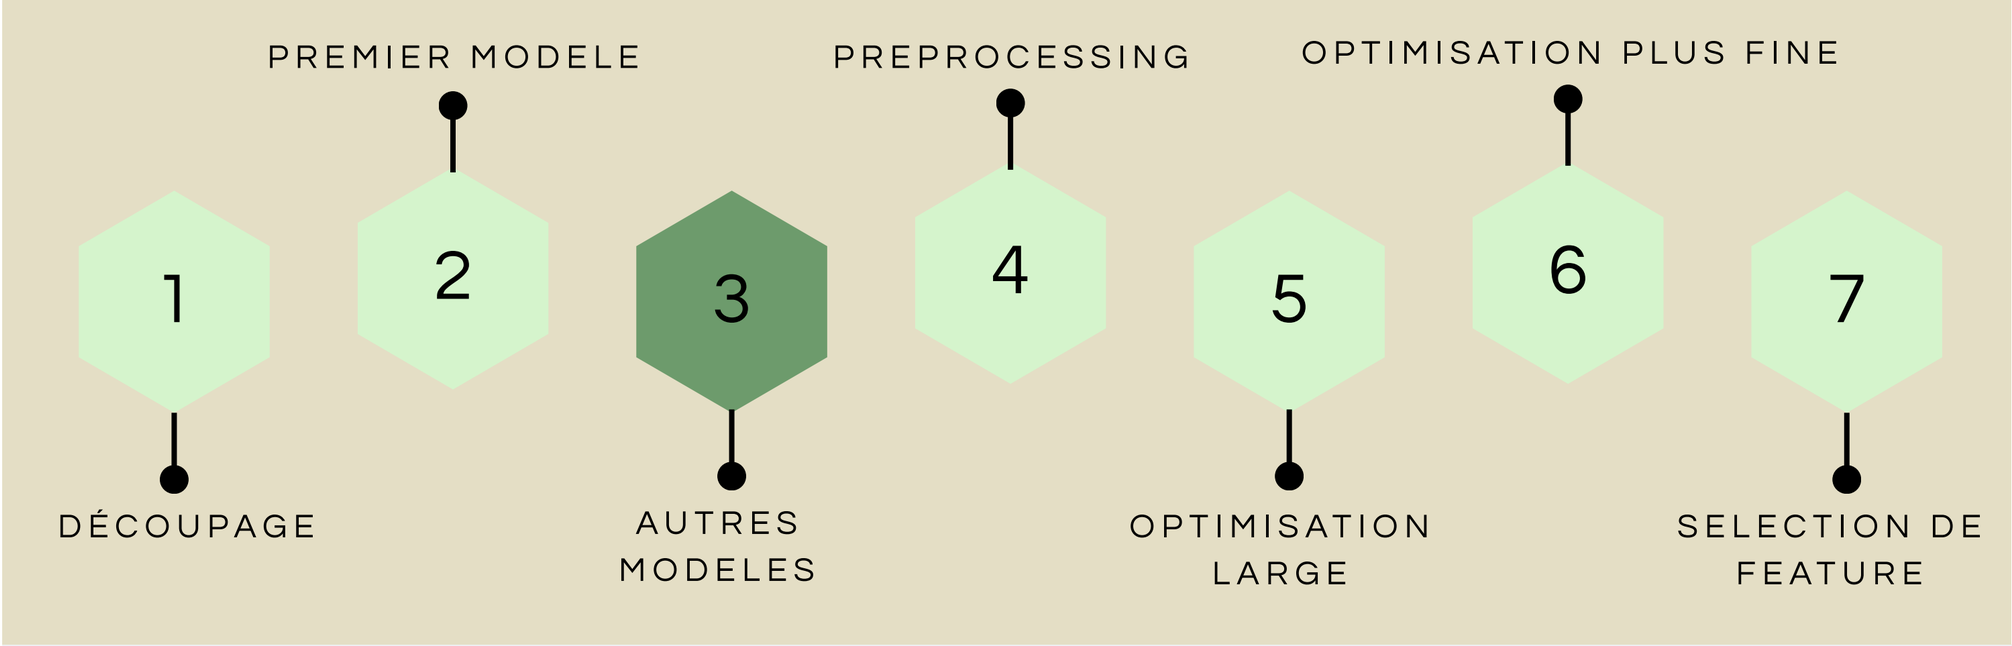
↓

Biais
Overfit
Instabilité

↓

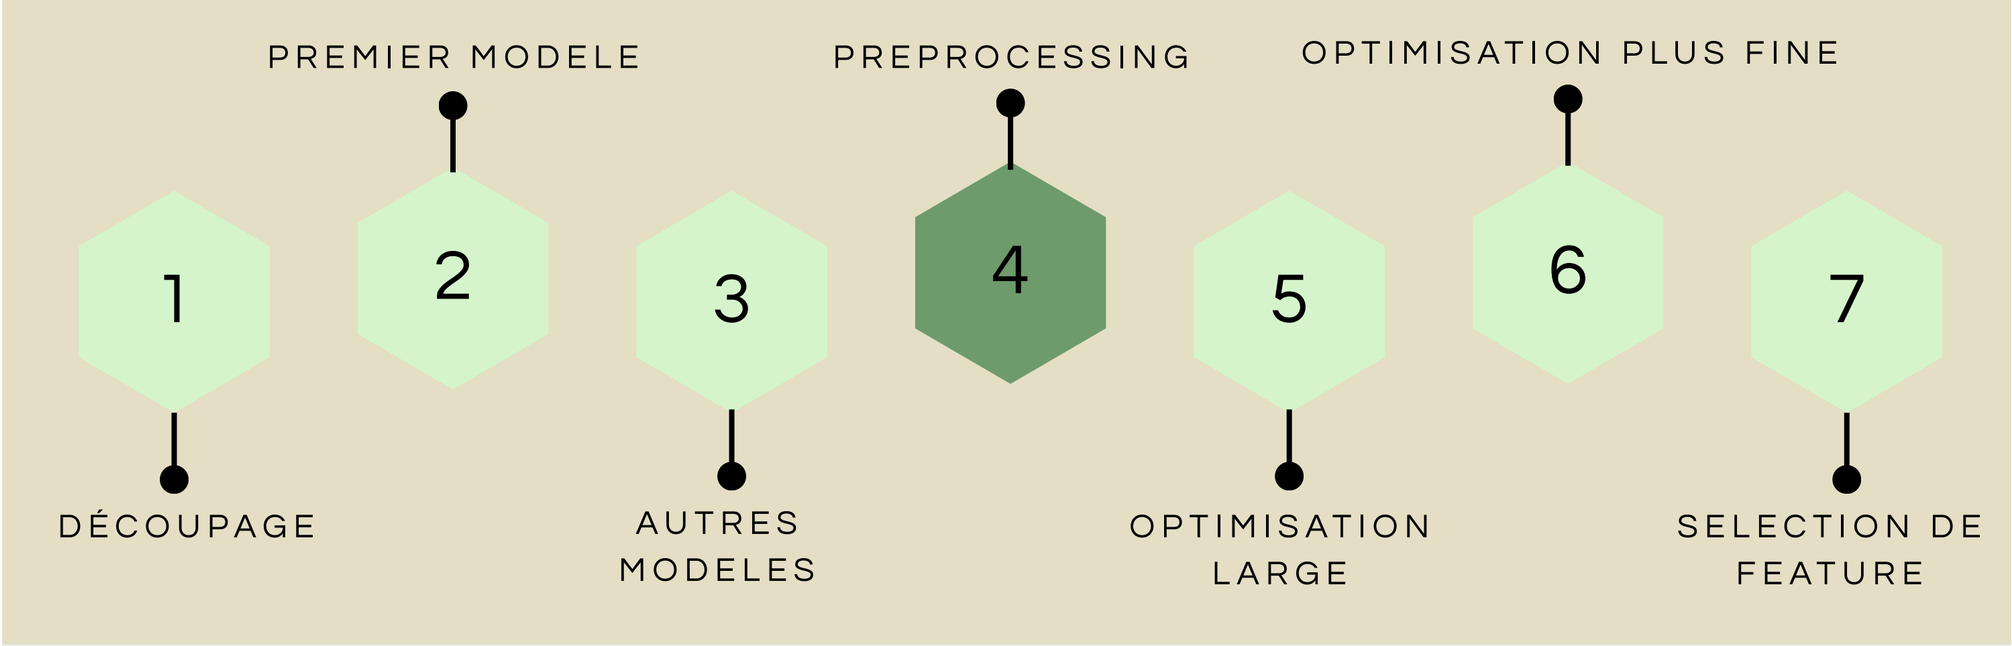
Régularisation
Méthode d'ensembles
Modèles non linéaires
Modification préprocessing

Modélisation



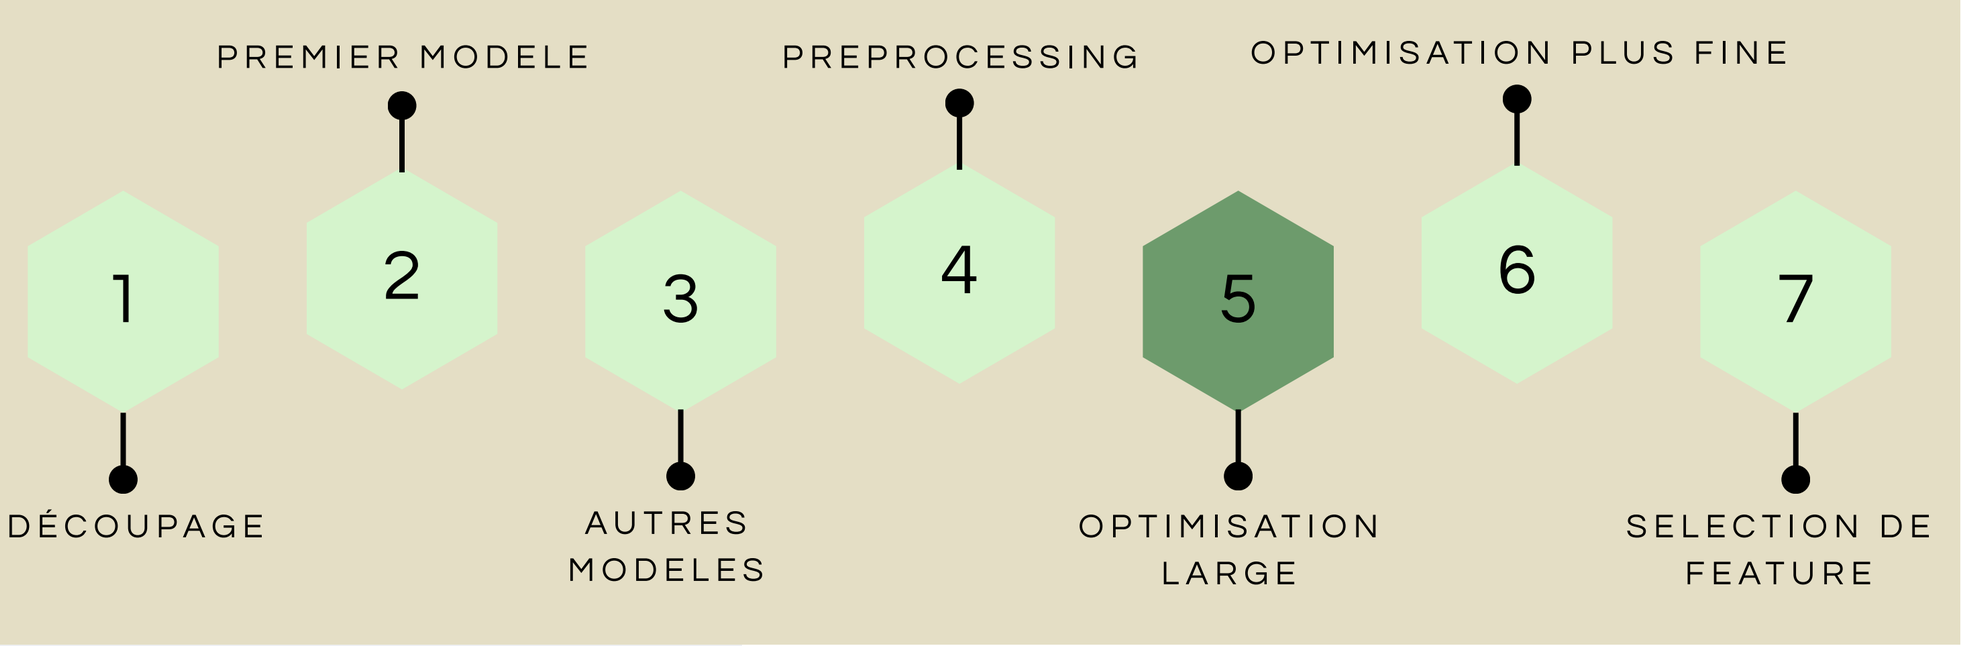
ElasticNet	→ Amélioration en validation croisée mais toujours faible et variable
Bagging Regressor	→ Pas d'amélioration
SVR	→ Amélioration mais overfit et variable
DecisionTree	→ Résultats moins bon et variables
RandomForest	→ Amélioration, stable, moins d'overfit
XGBRegressor	→ Amélioration en validation croisée mais variable et overfit

Modélisation



Variables numériques avec distribution asymétrique	Autres variables numériques	Variables Catégorielles	Variable cible
Transformation Pas de transformation Passage au log **Normalisation** MinMax Robust Standard	**Normalisation** MinMax Robust Standard	**Encodage** OneHot Target	**Transformation** Pas de transformation Passage au log Power Transformation

Modélisation

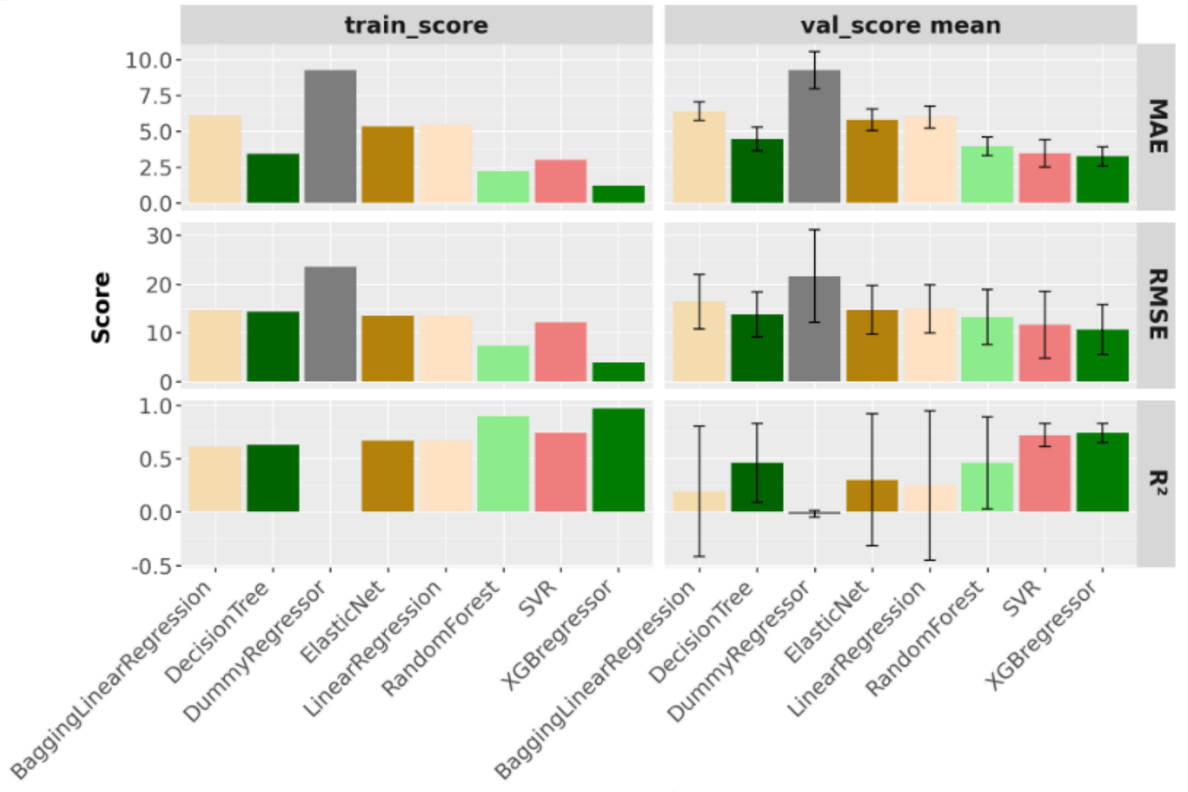


Optimisation sur

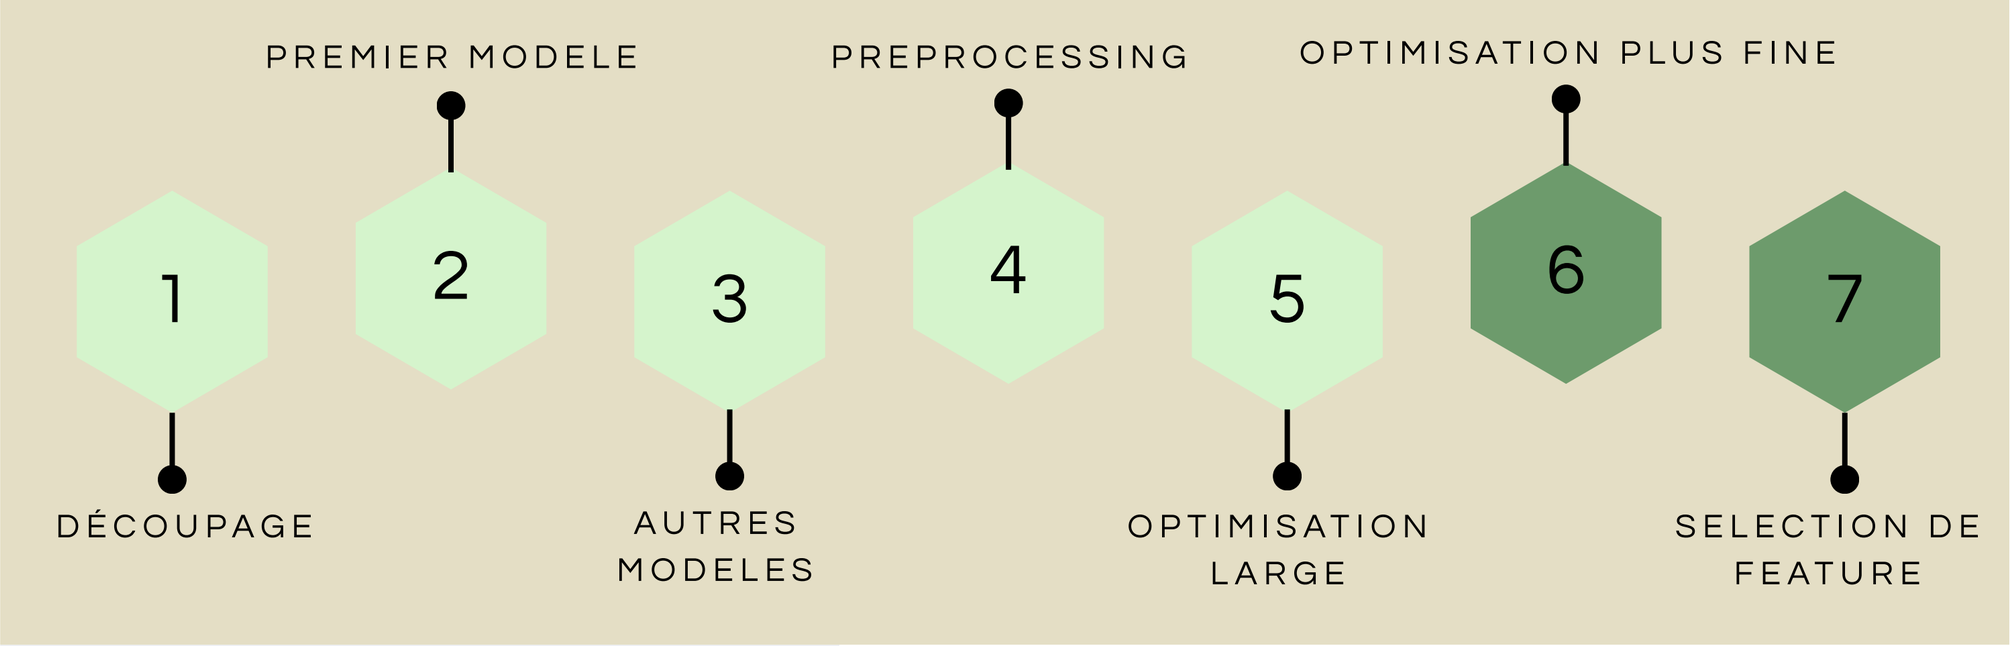
- Préprocessing des features
- Transformation de la target
- Paramètres des modèles
  - nombre d'estimateurs
  - profondeur des arbres
  - epsilon
  - ....

→ SVR

→ XGBRegressor



Modélisation



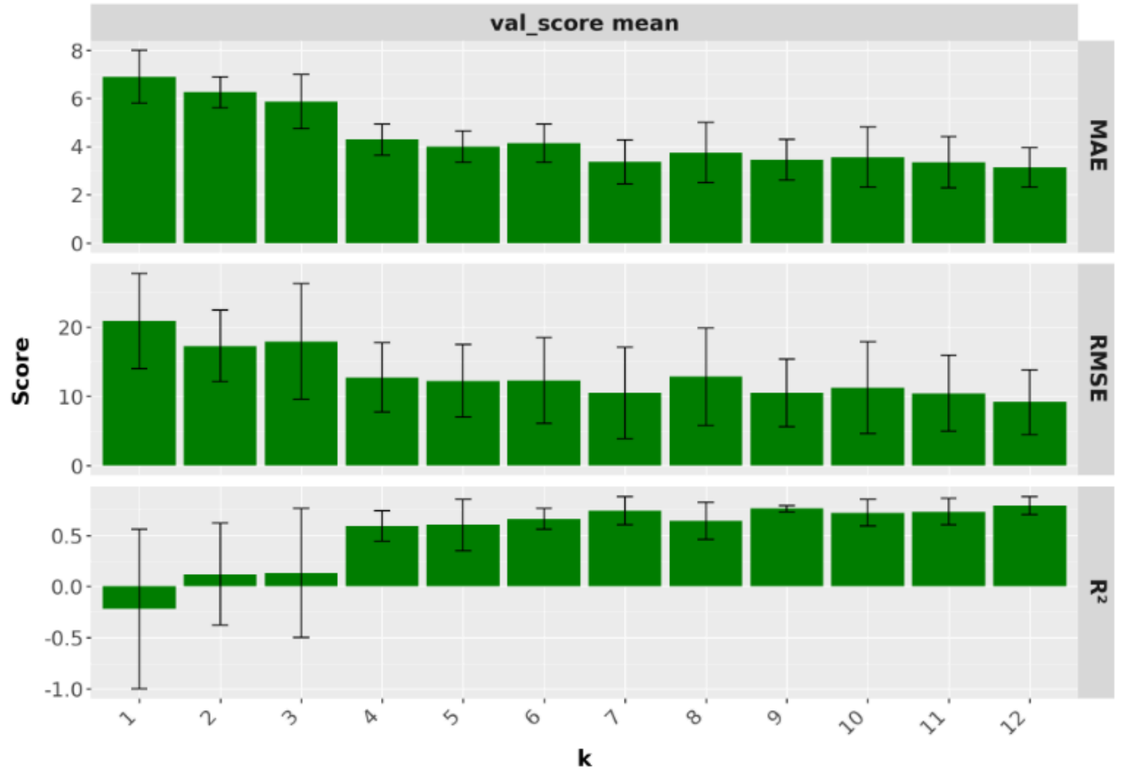
Affinage des performances à partir des configurations optimales

→ **XGBRegressor**

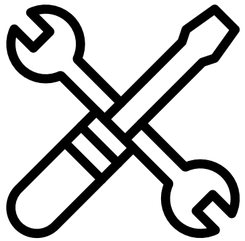
Sélection de variable

→ pas de sélection

	Train	Val mean	Val Std	Test
R^2	0.85	0.79	0.09	0.8
MAE	2.36	3.13	0.82	2.43
RMSE	9,2	9.16	4.63	6,04











Présentation des données

Feature engineering

Modélisation

Résultats

Résultats

Consommations énergétiques

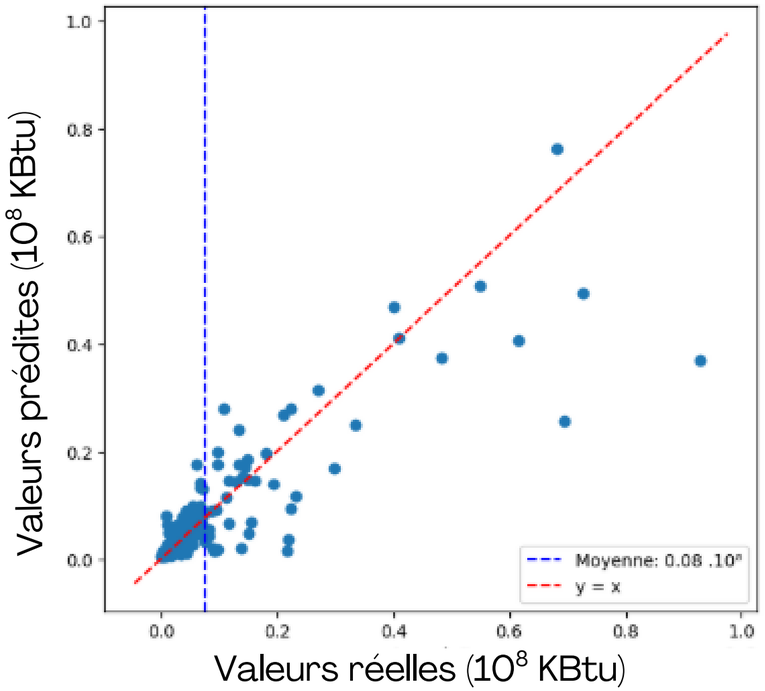
Avec ENERGYSTAR

	Train	Val mean	Val Std	Test
R^2	0.85	0.79	0.09	0.8
MAE	2.36	3.13	0.82	2.43
RMSE	9,2	9.16	4.63	6,04

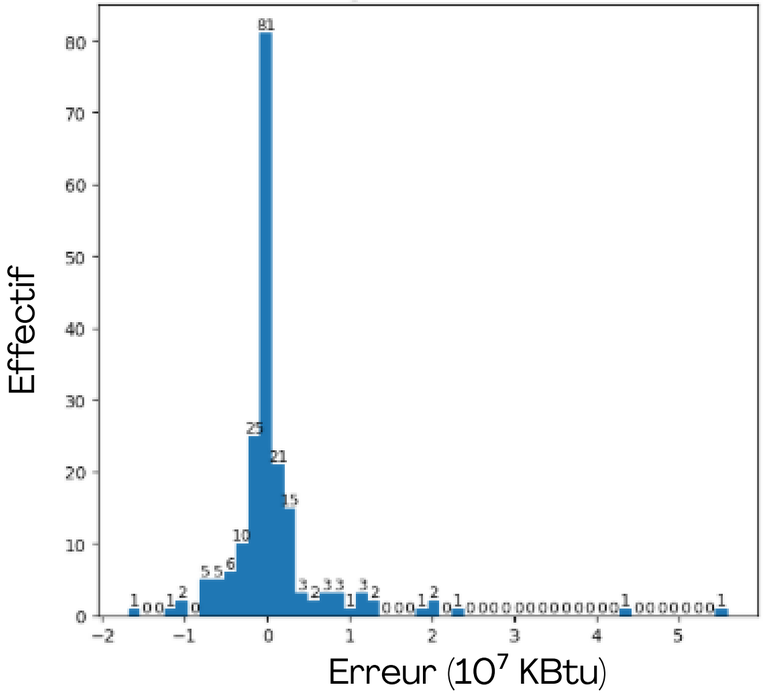
Sans ENERGYSTAR

	Train	Val mean	Val Std	Test
R^2	0.73	0.7	0.13	0.73
MAE	2.94	3.74	0.71	3,2
RMSE	12.23	11.46	6,08	7,01

Prédictions vs valeurs réelles

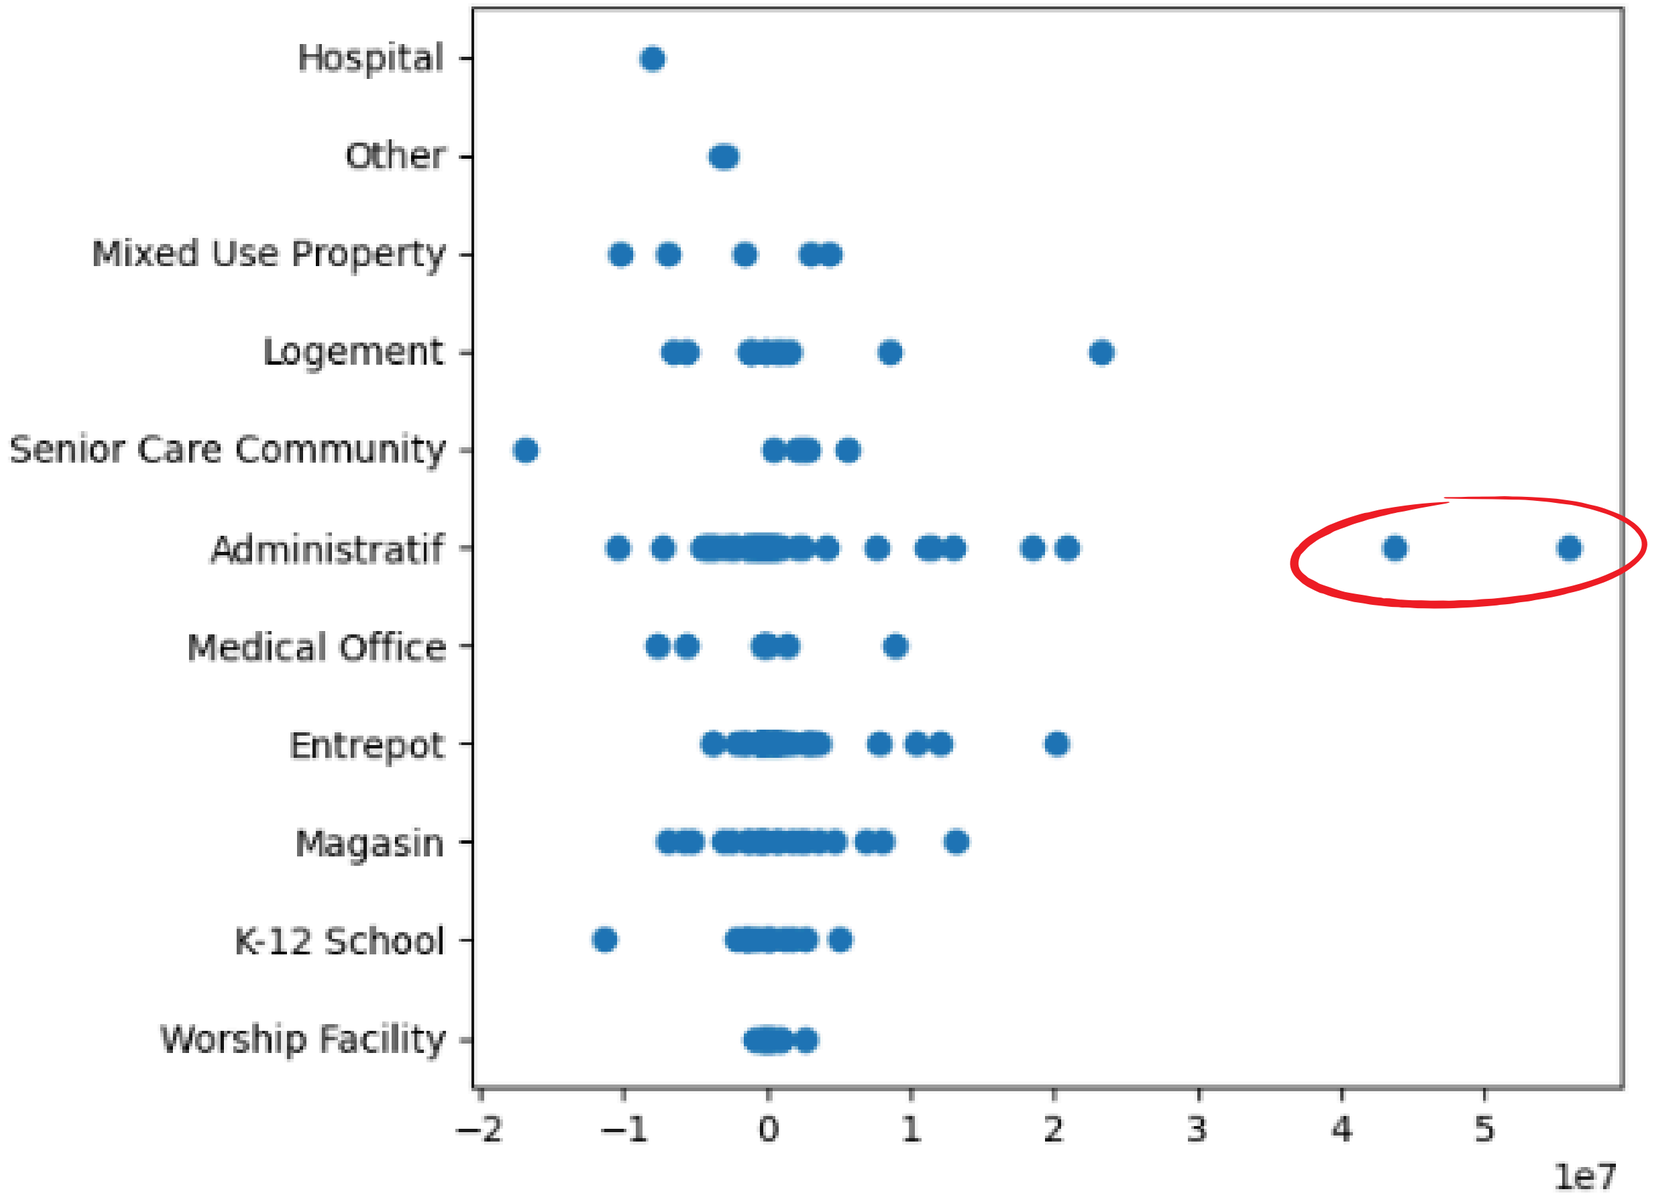


Histogramme des erreurs



Résultats

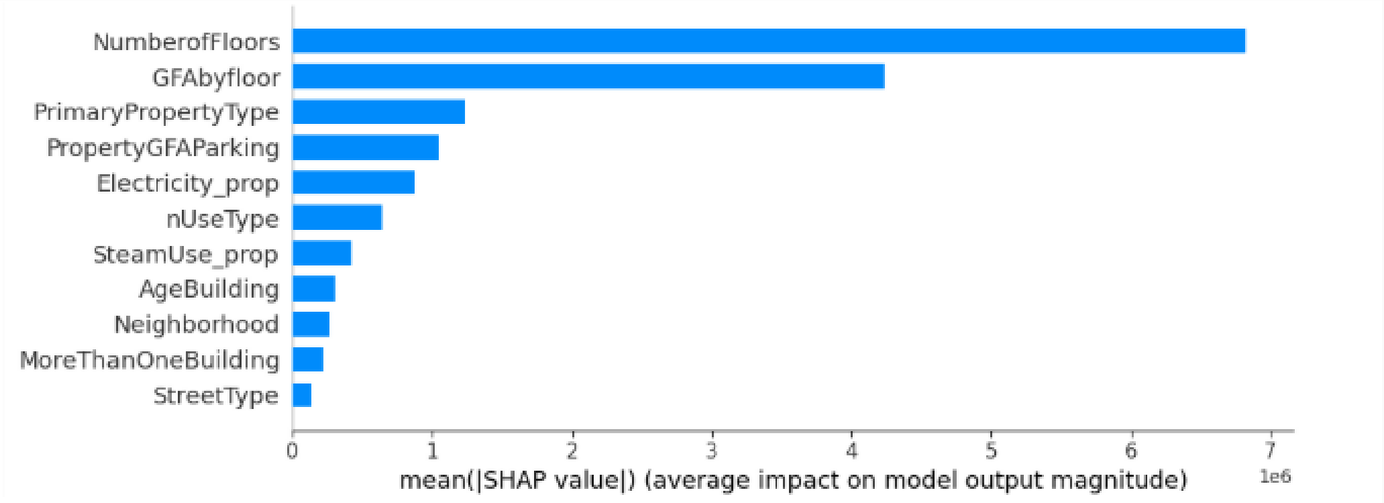
Consommations énergétiques



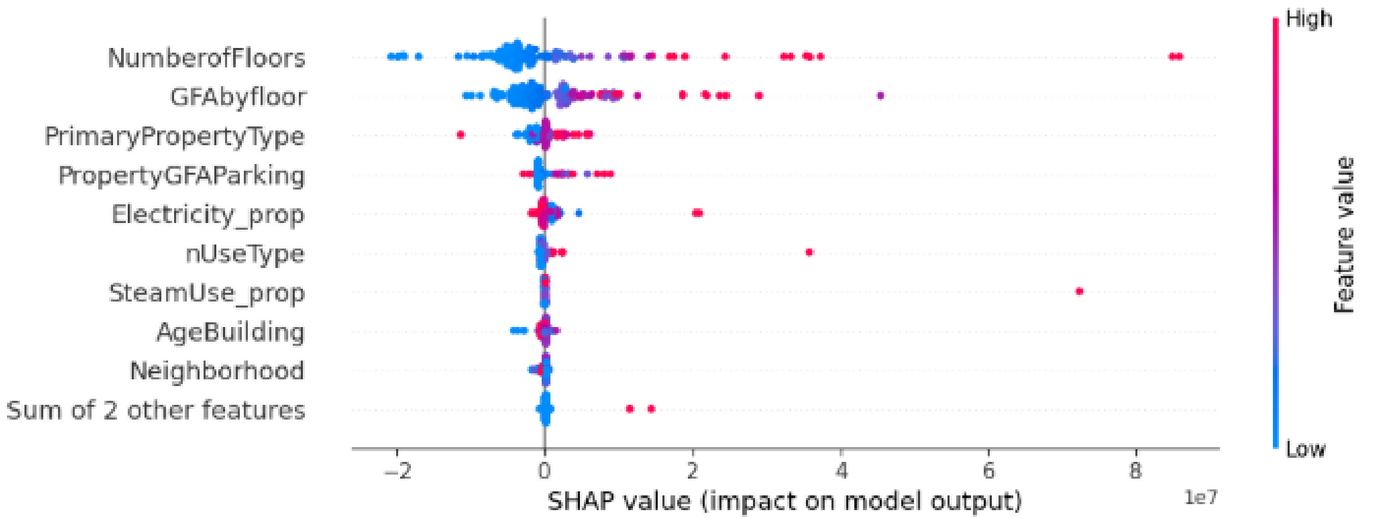
Résultats

Consommations énergétiques

Features contributions

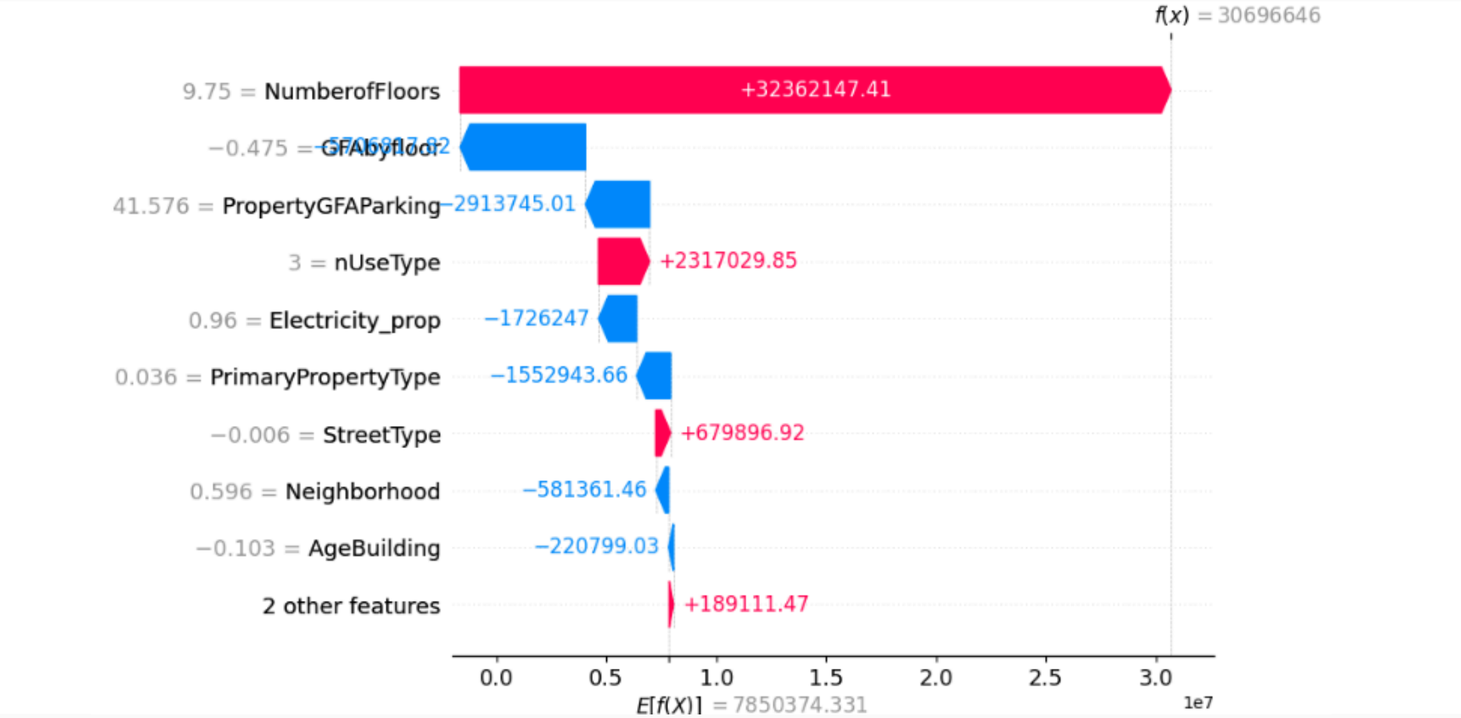


Indépendance



Résultats

Features contributions (locale)



- **Surface par étage**
- Surface du parking
- Proportion d’électricité
- Type d’usage associé
- Quartier
- Age du bâtiment

Résultats

Emission de gaz à effet de serre

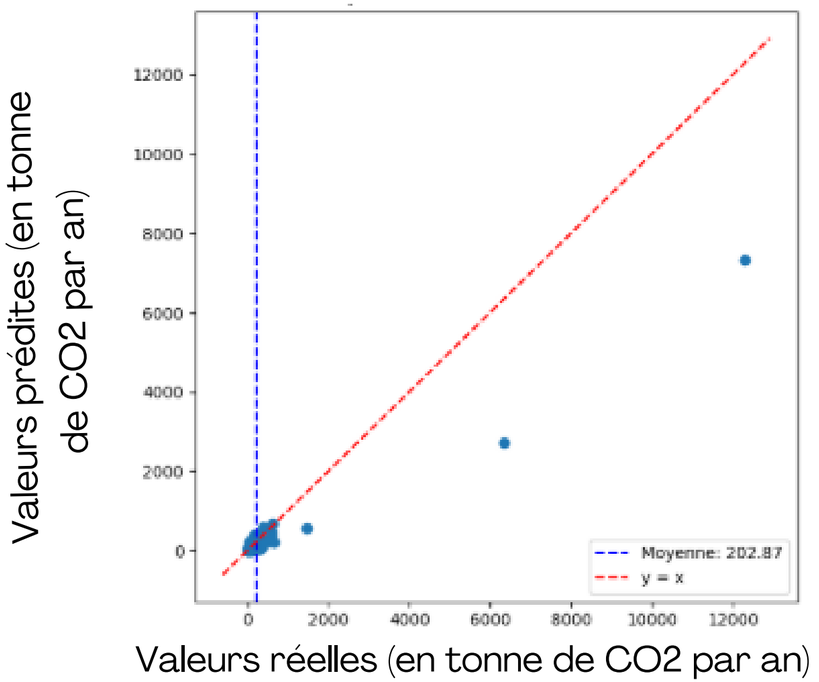
Avec ENERGYSTAR

	Train	Val mean	Val Std	Test
R^2	0.88	0.75	0.15	0.9
MAE	71	85.01	14,04	77.90
RMSE	207.14	224.38	71.53	309.5

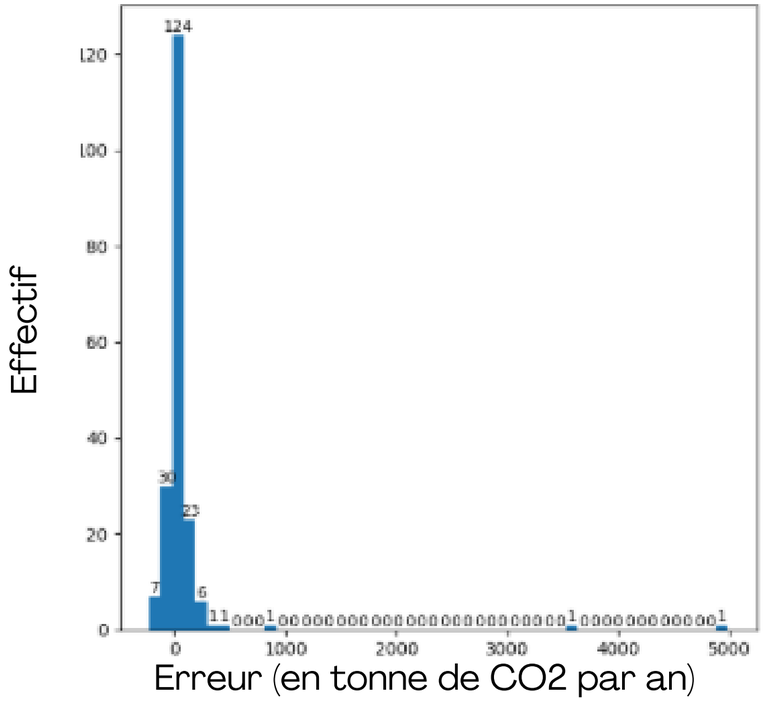
Sans ENERGYSTAR

	Train	Val mean	Val Std	Test
R^2	0.88	0.7	0.08	0.84
MAE	71.45	92.81	11.72	107.17
RMSE	201.09	269.57	73.02	509.72

Prédictions vs valeurs réelles



Histogramme des erreurs



Résultats

Emission de gaz à effet de serre

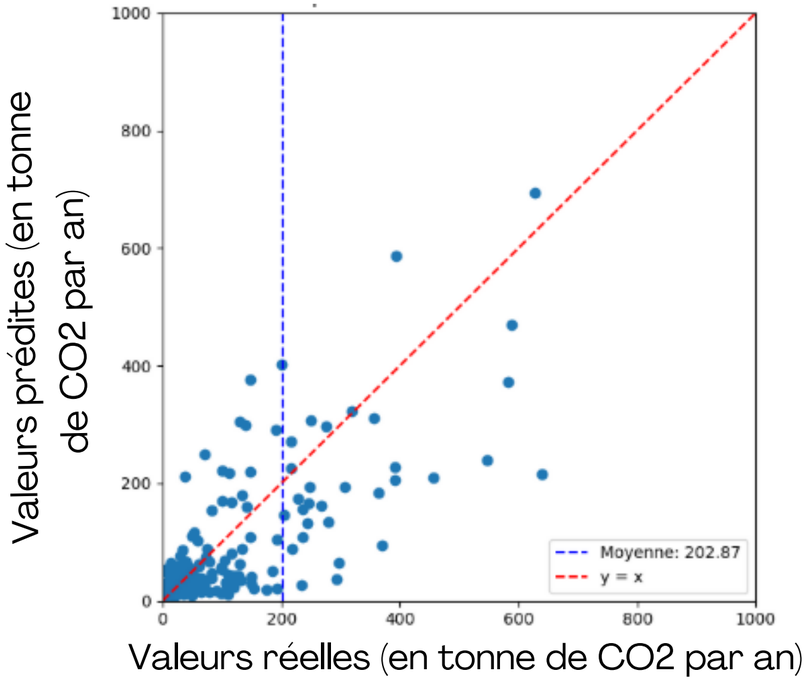
Avec ENERGYSTAR

	Train	Val mean	Val Std	Test
R^2	0.88	0.75	0.15	0.9
MAE	71	85.01	14,04	77.90
RMSE	207.14	224.38	71.53	309.5

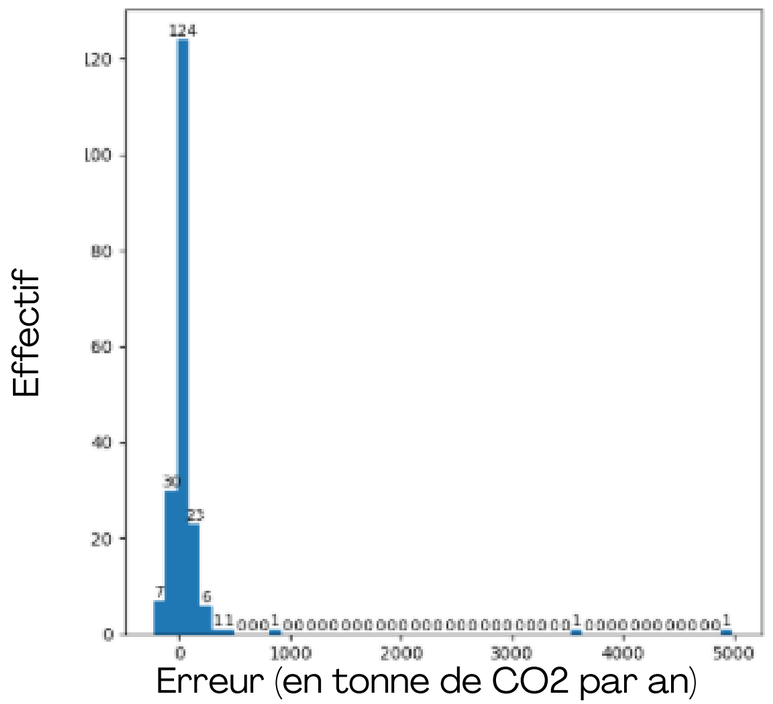
Sans ENERGYSTAR

	Train	Val mean	Val Std	Test
R^2	0.88	0.7	0.08	0.84
MAE	71.45	92.81	11.72	107.17
RMSE	201.09	269.57	73.02	509.72

Prédictions vs valeurs réelles



Histogramme des erreurs



Conclusions

Seattle Ville Neutre

Prédire les consommations énergétiques

Prédire les émissions en gaz à effet de serre

Etudier l’impact du score ENERGYSTAR

Bonne prédiction globale
Quelques erreurs importantes
Principalement des sous-estimations

Meilleures performances avec la variable mais compromis perte de performance vs gain de temps acceptable