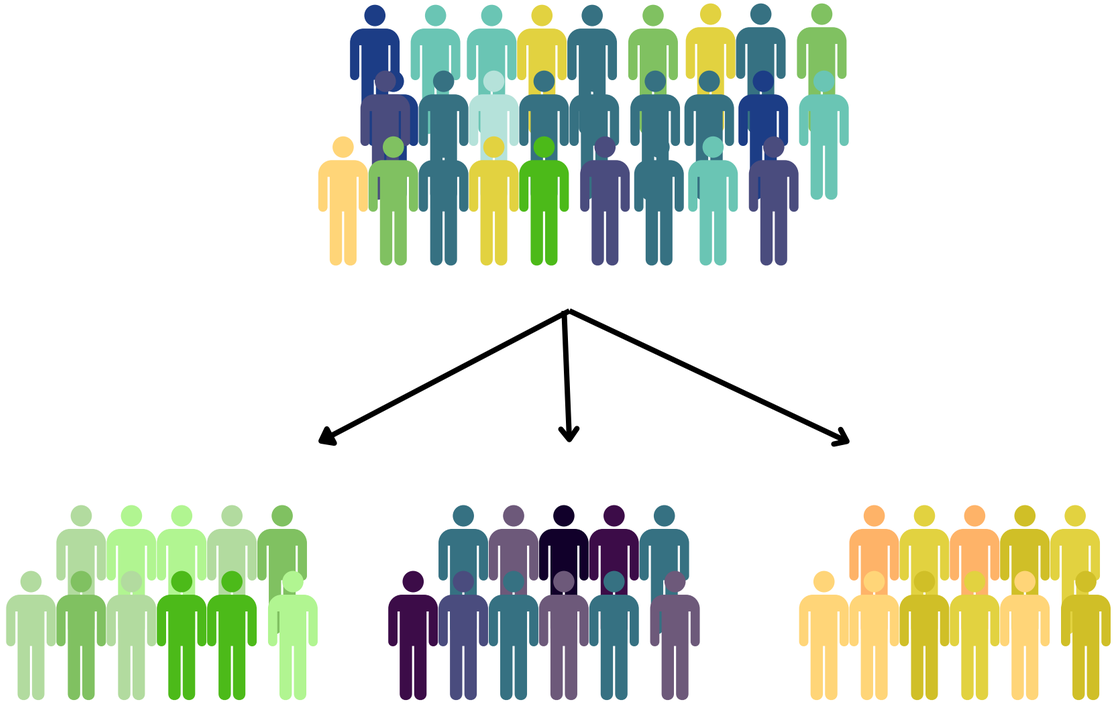
Segmentation des clients de la base d’Olist

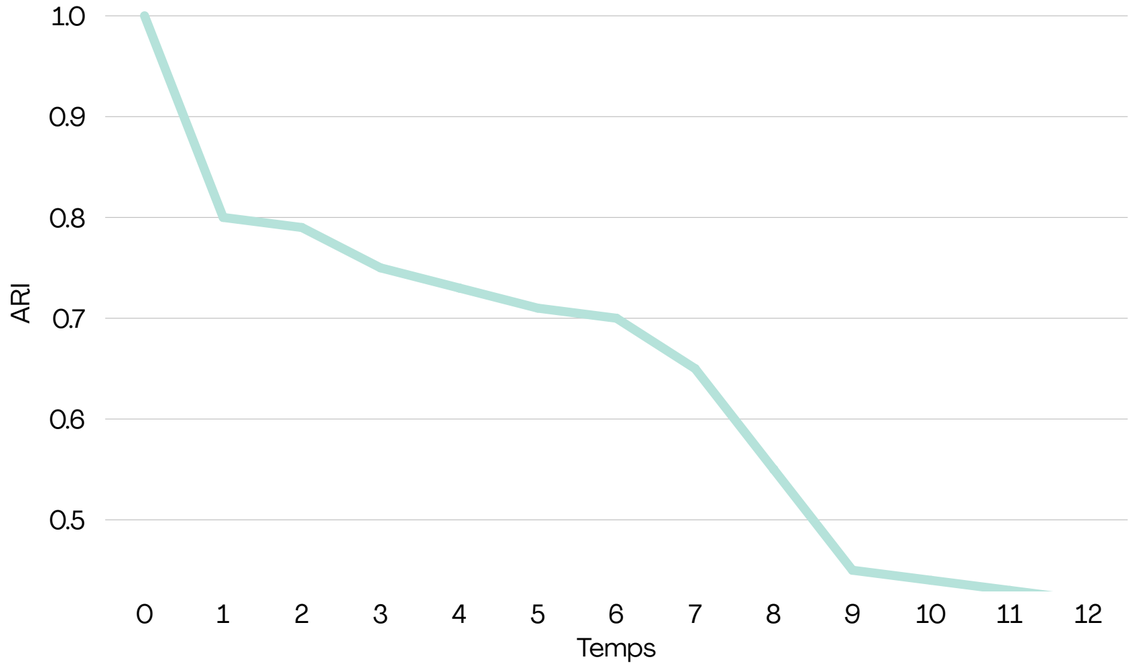


Objectifs du projet

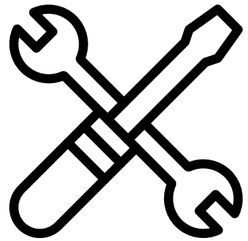
Segmenter la base client

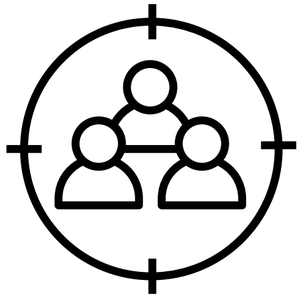


Fournir un contrat de maintenance











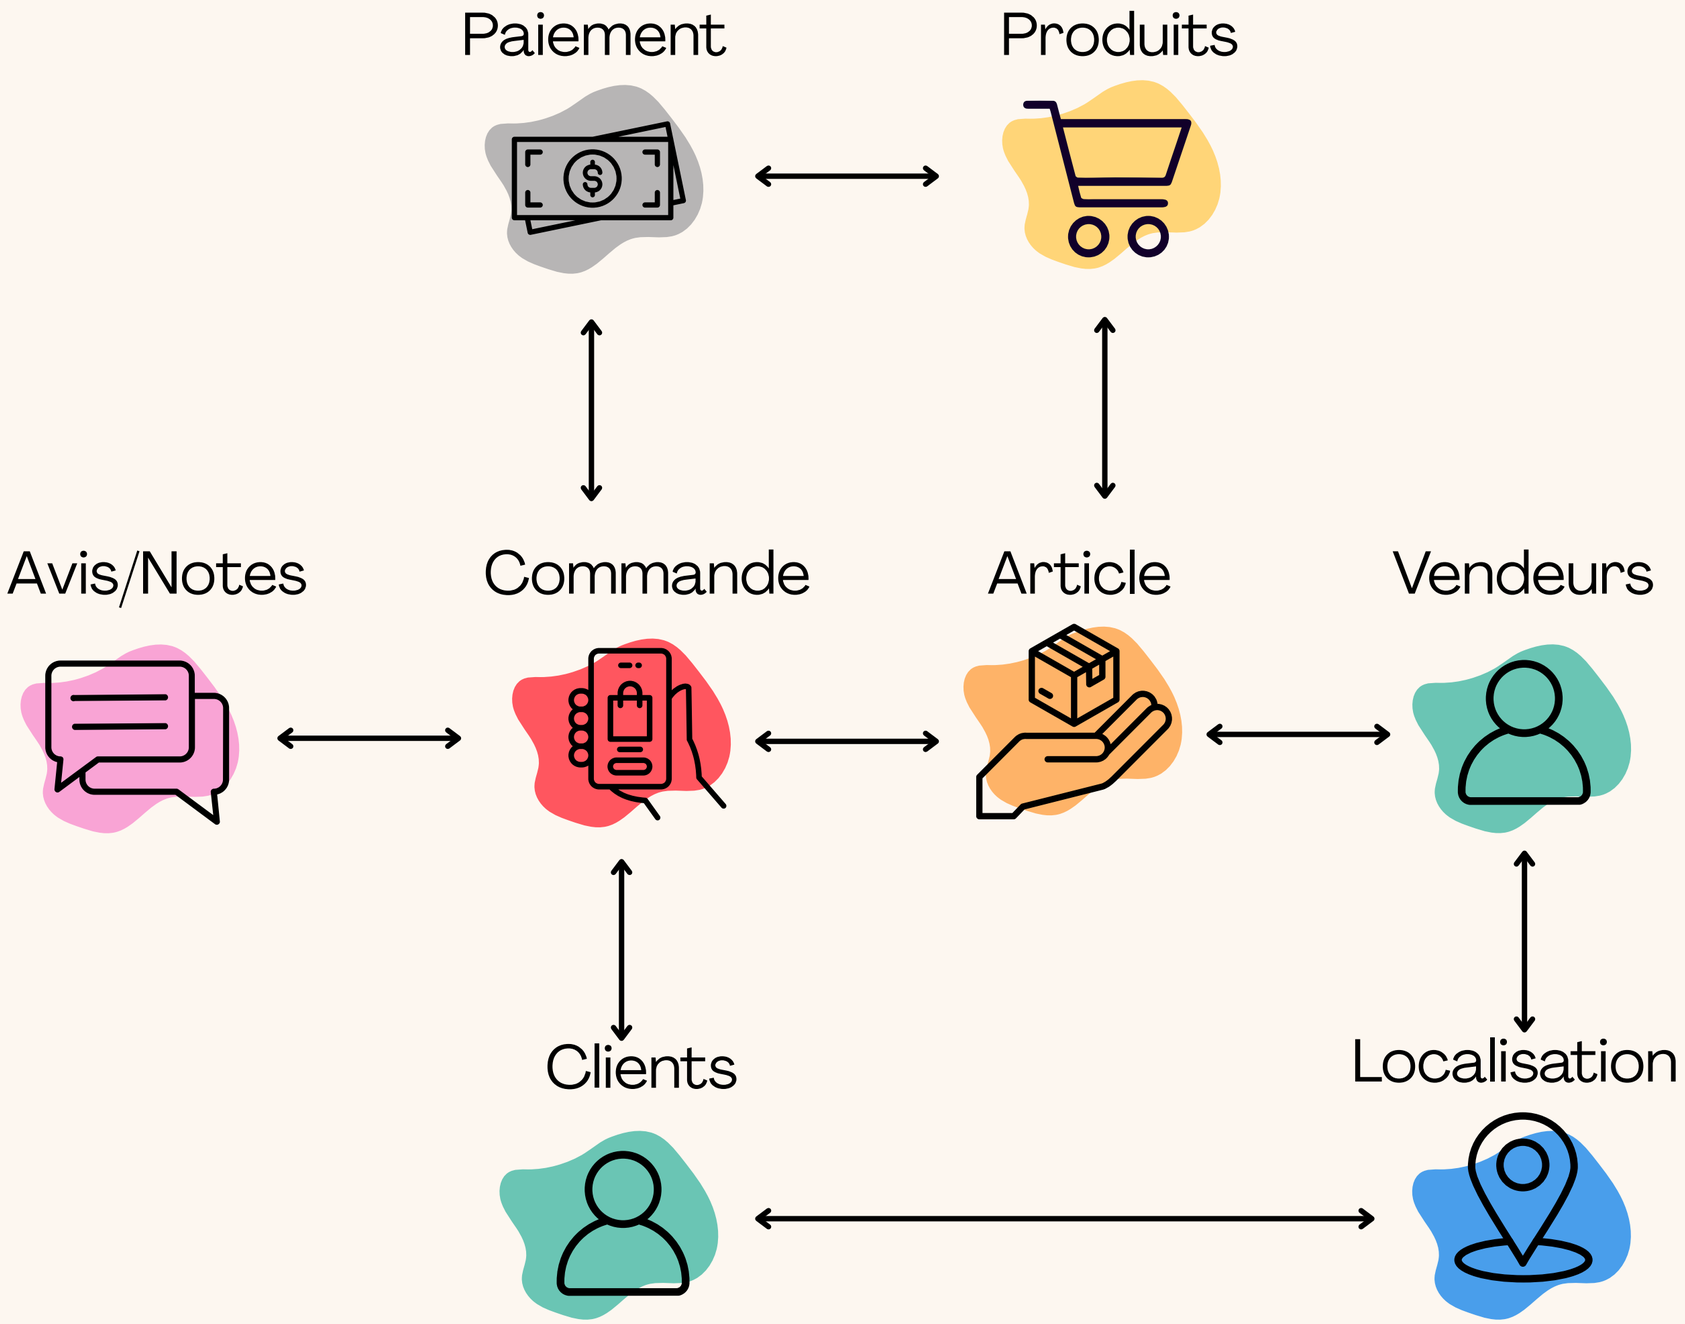
Présentation des données

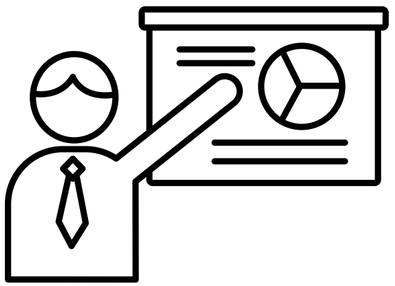
Feature engineering

Segmentation

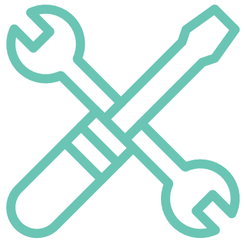
Contrat de maintenance

Présentation des données

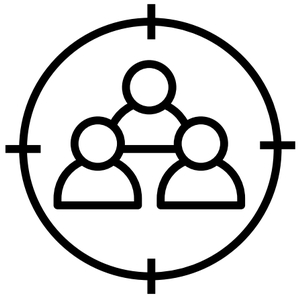




Présentation des données



Feature engineering



Segmentation

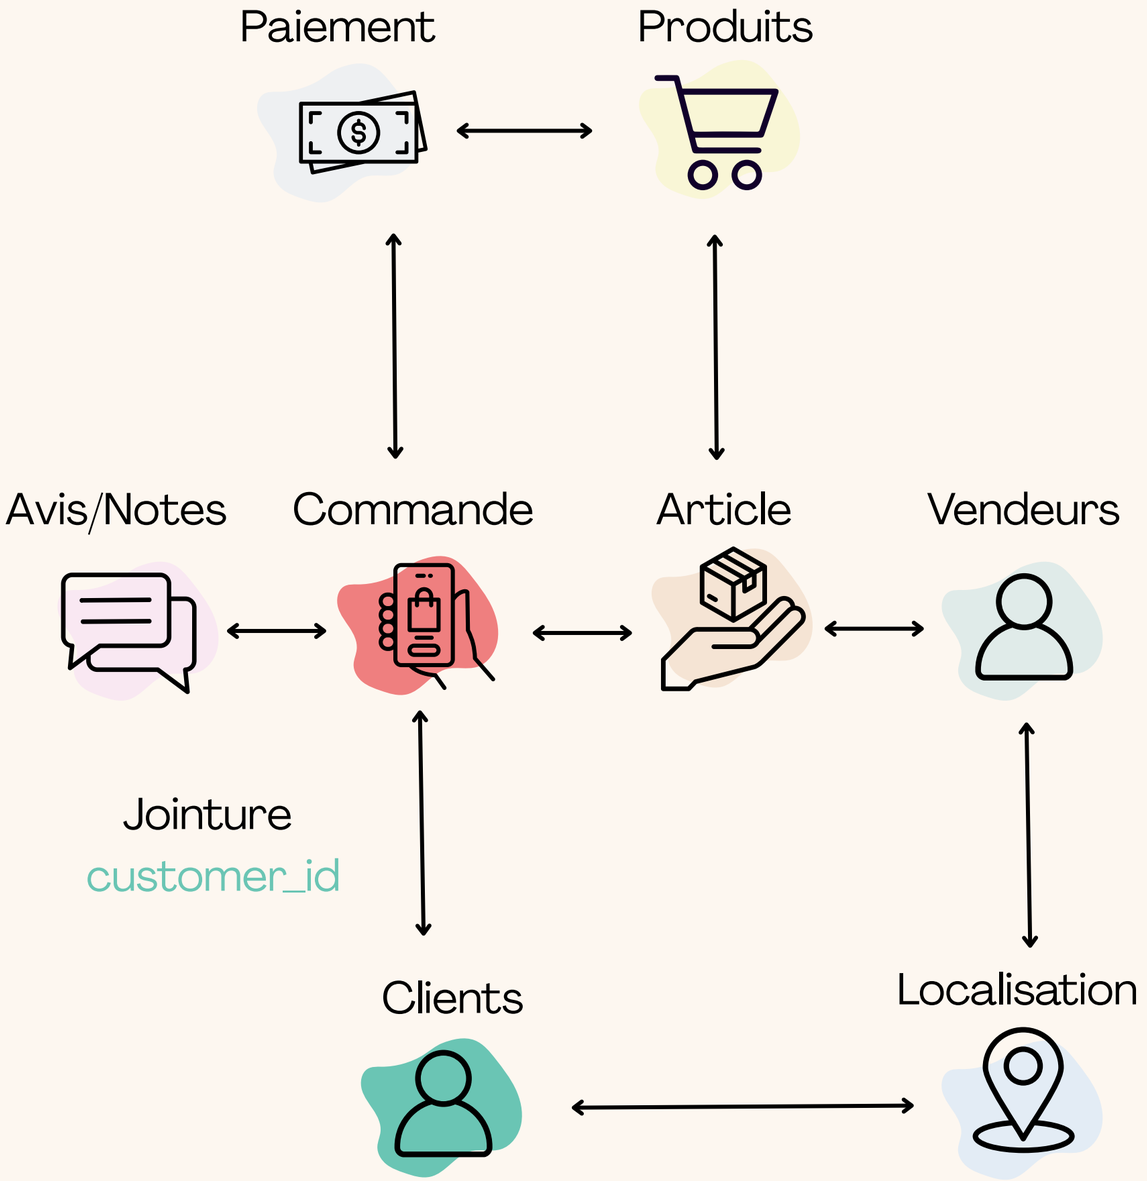


Contrat de maintenance

Construction du profil client

Infos par commande

Identifiant client

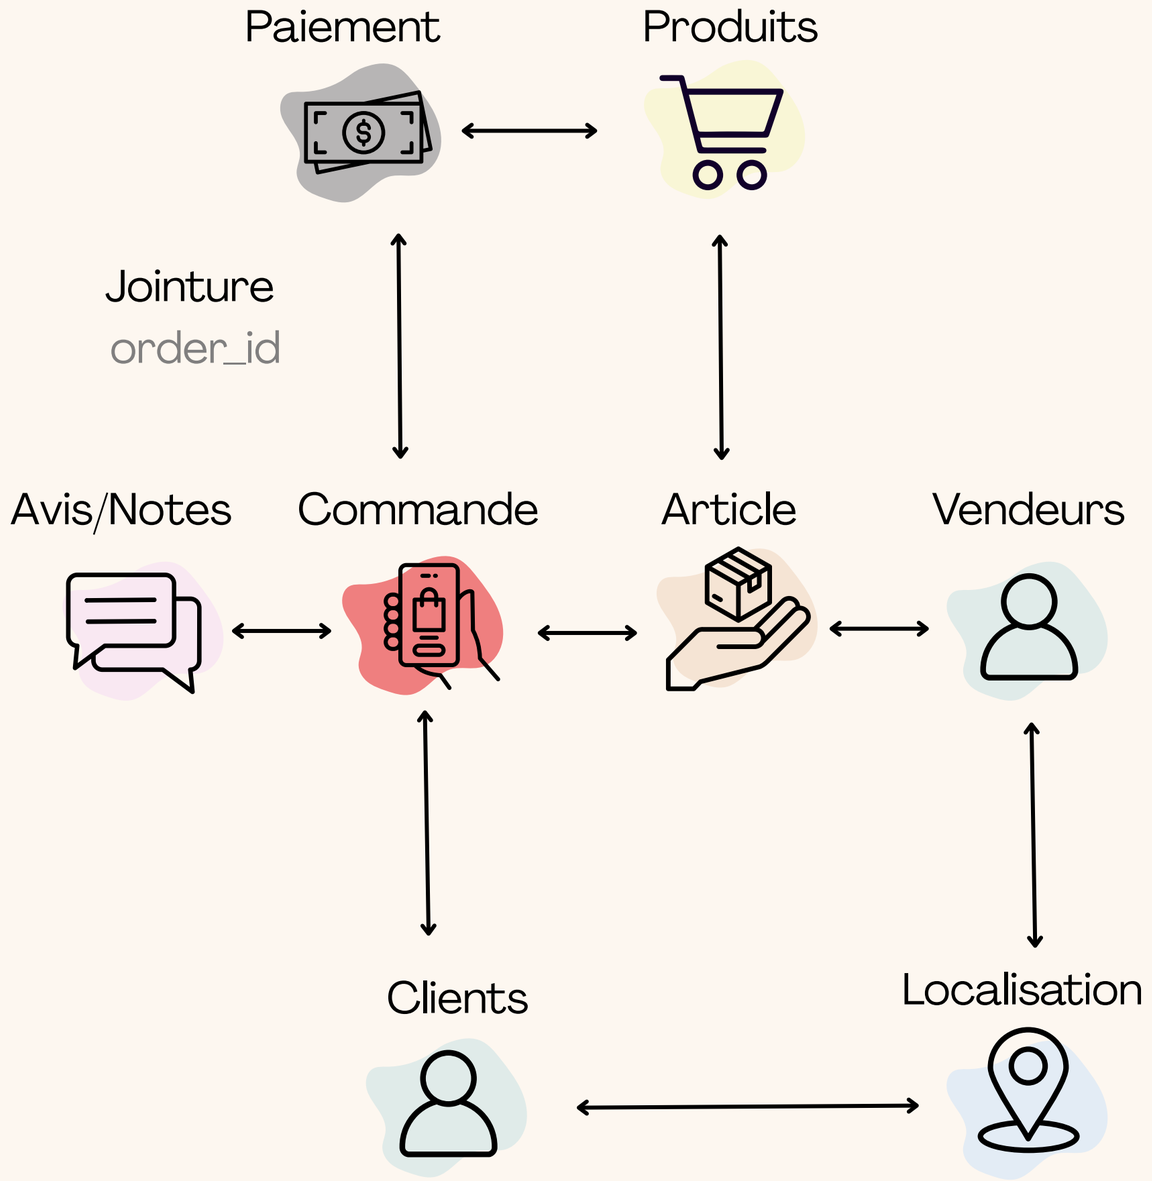


Construction du profil client

Infos par commande

Identifiant client

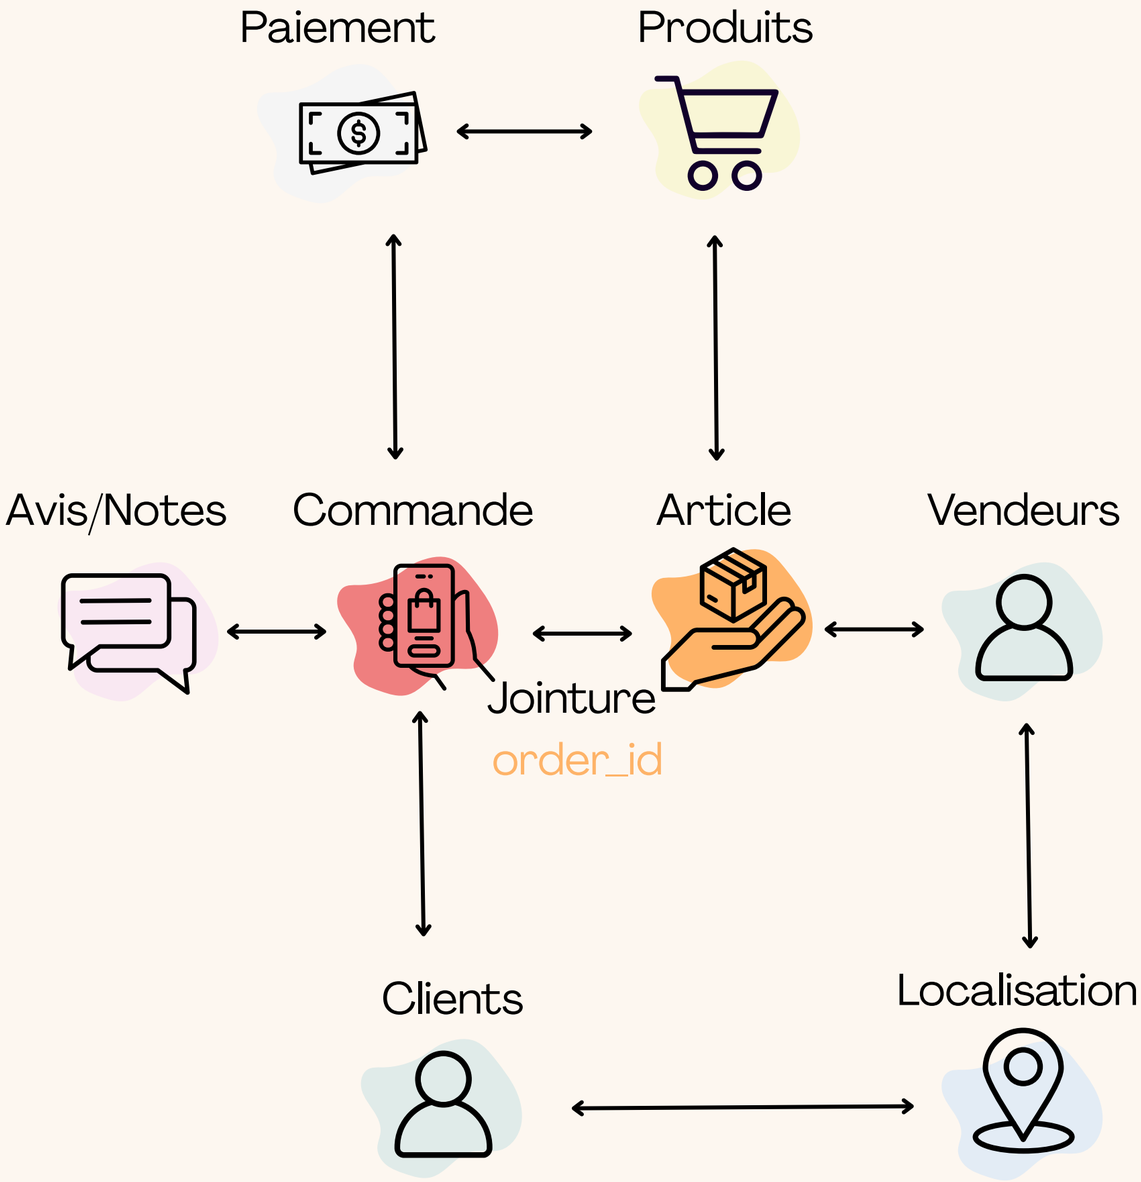
Montant



Construction du profil client

Infos par commande

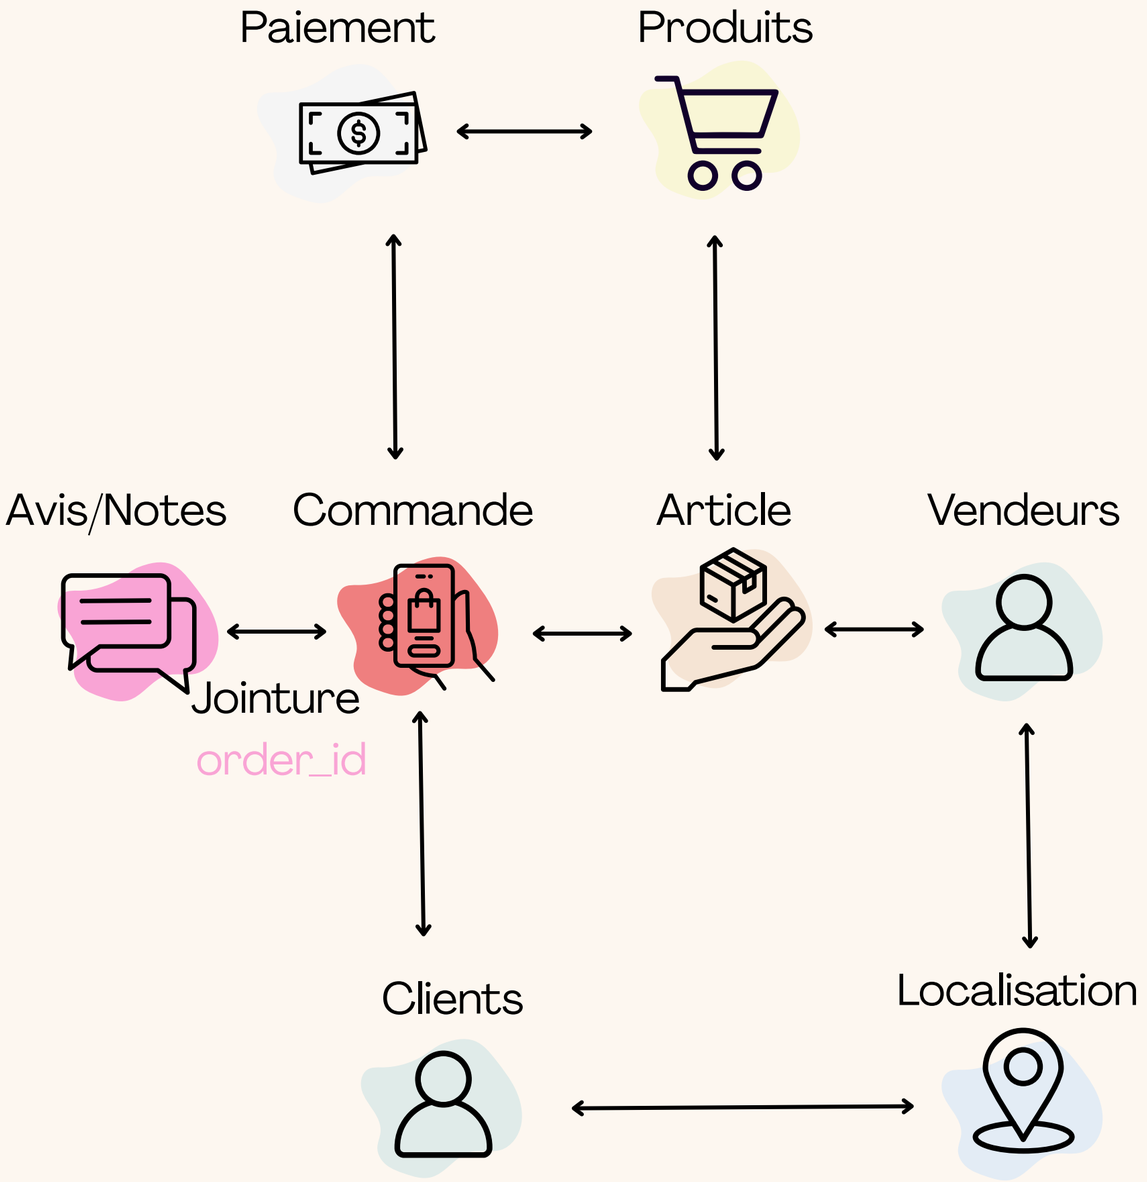
- Identifiant client
- Montant
- Frais de port
- Nombre de produits / commande



Construction du profil client

Infos par commande

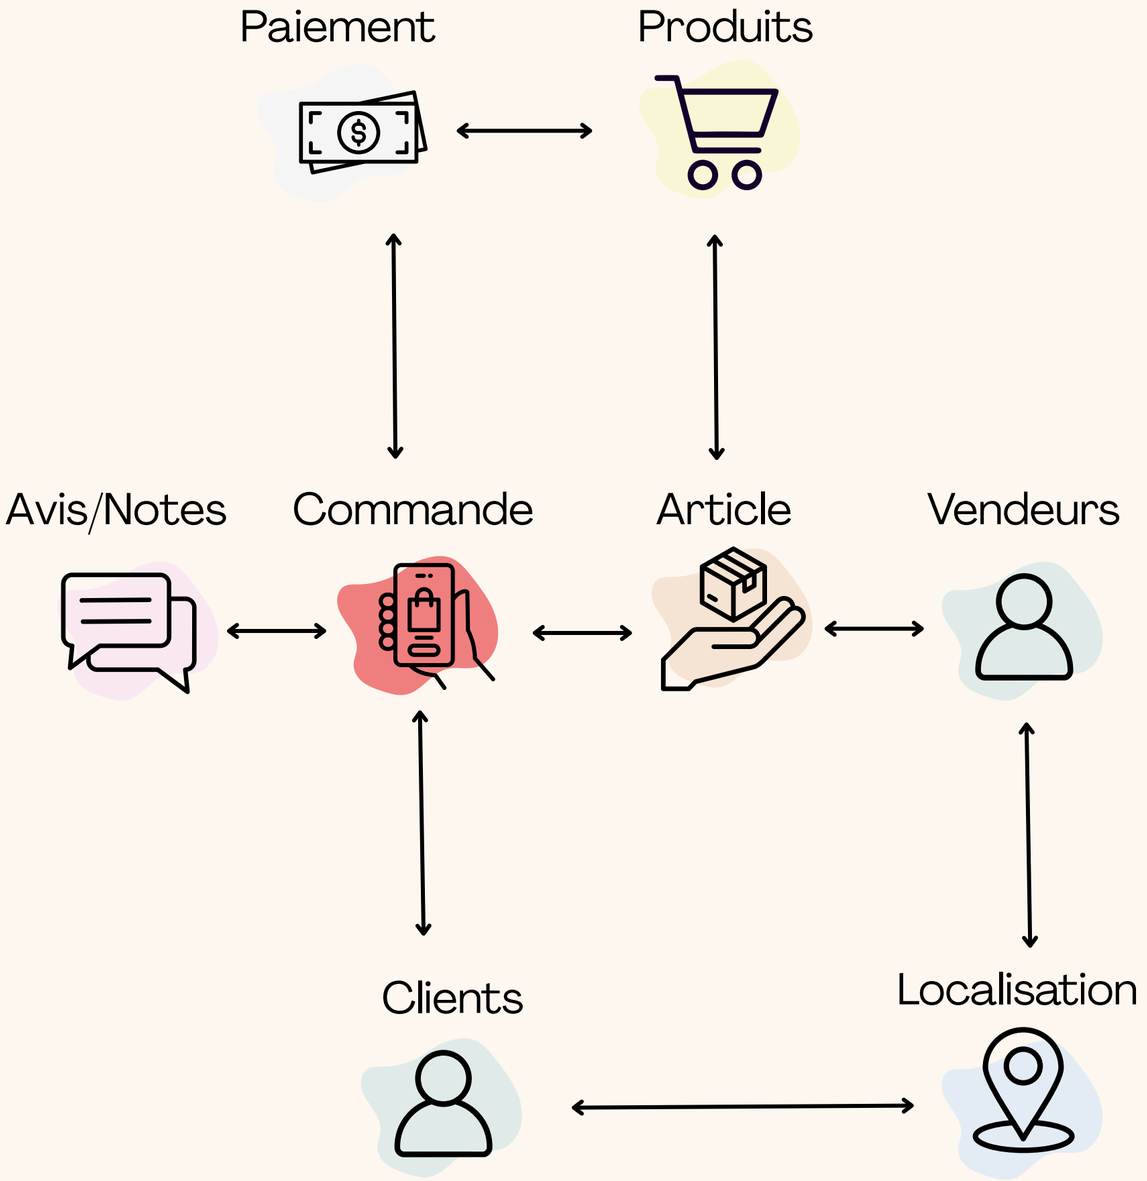
- Identifiant client
- Montant
- Frais de port
- Nombre de produits / commande
- Note par commande



Construction du profil client

Infos par commande

- Identifiant client
- Montant
- Frais de port
- Nombre de produits / commande
- Note par commande
- Ratio frais de port / montant
- Délais achat livraison
- Retard livraison
- Date de la commande
- Mois de la commande
- Jour de la commande
- Statut de la commande



Construction du profil client

Infos par commande

- Identifiant client
- Montant
- Nombre de produits / commande
- Frais de port
- Nombre de produits / commande
- Note par commande
- Ratio frais de port / montant
- Délais achat livraison
- Retard livraison
- Date de la commande
- Date de la commande
- Mois de la commande
- Jour de la commande
- Statut de la commande

Regroupement par



Identifiant client

Construction du profil client

Infos par commande

- Identifiant client
- Montant
- Nombre de produits / commande
- Frais de port
- Nombre de produits / commande
- Note par commande
- Ratio frais de port / montant
- Délais achat livraison
- Retard livraison
- Date de la commande
- Date de la commande
- Mois de la commande
- Jour de la commande
- Statut de la commande

Regroupement par



Identifiant client

Somme

Infos par client

- Identifiant client
- Montant total
- Nombre de produits total
- Frais de port moyen
- Nombre de produits moyen
- Note par commande moyenne
- Ratio frais de port / montant moyen
- Délais achat livraison moyen
- Retard livraison moyen
- Nombre jour depuis dernier achat
- Nombre de jour depuis premier achat
- Jour préféré d’achat
- Mois préféré d’achat
- Nombre de commandes annulée

Construction du profil client

Infos par commande

- Identifiant client
- Montant
- Nombre de produits / commande
- Frais de port
- Nombre de produits / commande
- Note par commande
- Ratio frais de port / montant
- Délais achat livraison
- Retard livraison
- Date de la commande
- Date de la commande
- Mois de la commande
- Jour de la commande
- Statut de la commande

Regroupement par



Identifiant client

Moyenne

Infos par client

- Identifiant client
- Montant total
- Nombre de produits total
- Frais de port moyen
- Nombre de produits moyen
- Note par commande moyenne
- Ratio frais de port / montant moyen
- Délais achat livraison moyen
- Retard livraison moyen
- Nombre jour depuis dernier achat
- Nombre de jour depuis premier achat
- Jour préféré d’achat
- Mois préféré d’achat
- Nombre de commandes annulée

Construction du profil client

Infos par commande

- Identifiant client
- Montant
- Nombre de produits / commande
- Frais de port
- Nombre de produits / commande
- Note par commande
- Ratio frais de port / montant
- Délais achat livraison
- Retard livraison
- Date de la commande
- Date de la commande
- Mois de la commande
- Jour de la commande
- Statut de la commande

Regroupement par



Identifiant client

Max
Min

Infos par client

- Identifiant client
- Montant total
- Nombre de produits total
- Frais de port moyen
- Nombre de produits moyen
- Note par commande moyenne
- Ratio frais de port / montant moyen
- Délais achat livraison moyen
- Retard livraison moyen
- Nombre jour depuis dernier achat
- Nombre de jour depuis premier achat
- Jour préféré d’achat
- Mois préféré d’achat
- Nombre de commandes annulée

Construction du profil client

Infos par commande

- Identifiant client
- Montant
- Nombre de produits / commande
- Frais de port
- Nombre de produits / commande
- Note par commande
- Ratio frais de port / montant
- Délais achat livraison
- Retard livraison
- Date de la commande
- Date de la commande
- Mois de la commande
- Jour de la commande
- Statut de la commande

Regroupement par



Identifiant client

Compte

Infos par client

- Identifiant client
- Montant total
- Nombre de produits total
- Frais de port moyen
- Nombre de produits moyen
- Note par commande moyenne
- Ratio frais de port / montant moyen
- Délais achat livraison moyen
- Retard livraison moyen
- Nombre jour depuis dernier achat
- Nombre de jour depuis premier achat
- Jour préféré d’achat
- Mois préféré d’achat
- Nombre de commandes annulée

Construction du profil client

Infos par commande

- Identifiant client
- Montant
- Nombre de produits / commande
- Frais de port
- Nombre de produits / commande
- Note par commande
- Ratio frais de port / montant
- Délais achat livraison
- Retard livraison
- Date de la commande
- Date de la commande
- Mois de la commande
- Jour de la commande
- Statut de la commande

Regroupement par



Identifiant client

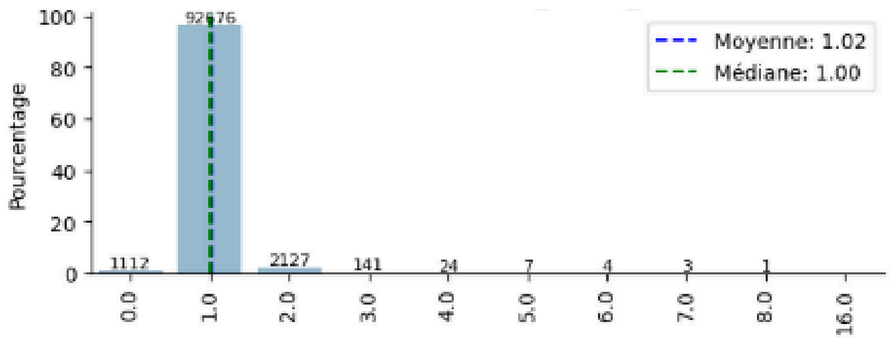
Infos par client

- Identifiant client
- Montant total
- Nombre de produits total
- Frais de port moyen
- Nombre de produits moyen
- Note par commande moyenne
- Ratio frais de port / montant moyen
- Délais achat livraison moyen
- Retard livraison moyen
- Nombre jour depuis dernier achat
- Nombre de jour depuis premier achat
- Jour préféré d'achat
- Mois préféré d'achat
- Nombre de commandes annulée

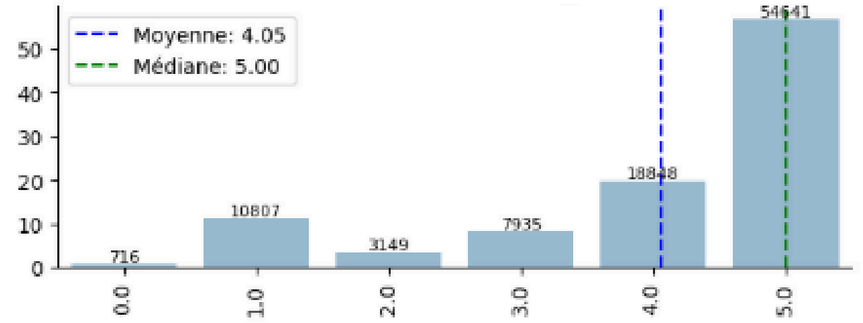
Traitement des commandes annulées et indisponibles
différent des autres commandes (ex: montant → 0)

Construction du profil client

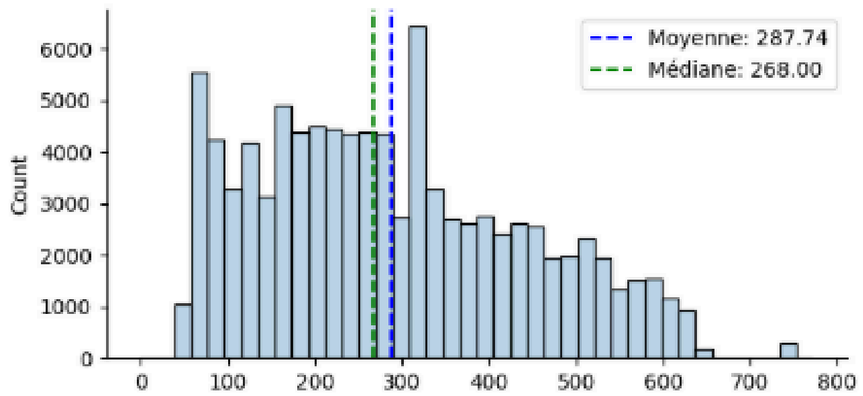
Nombre de commandes



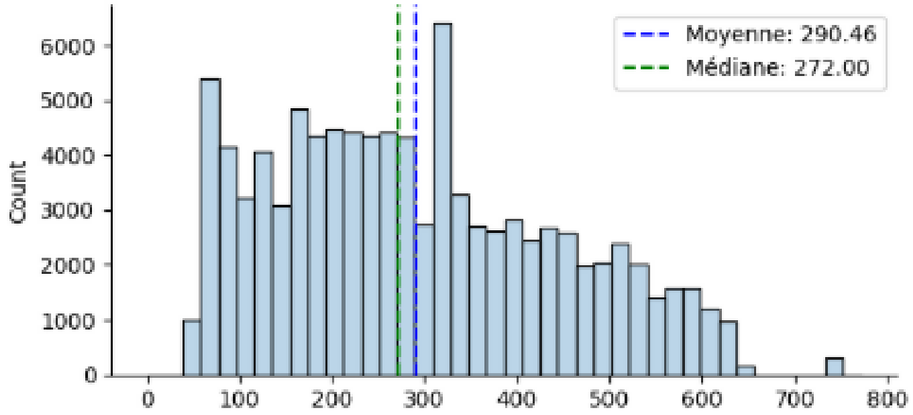
Note moyenne



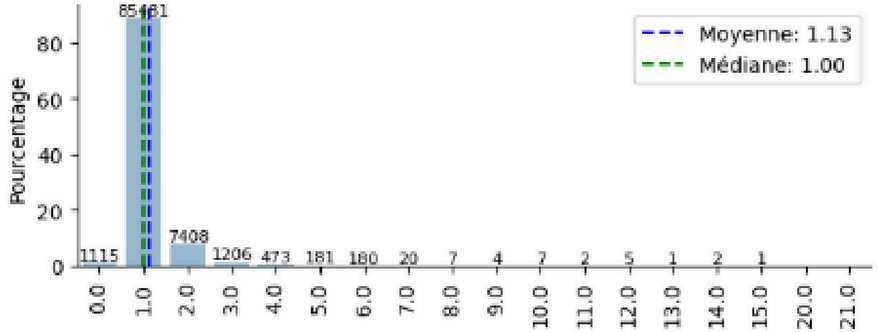
Nombre de jours écoulés depuis la dernière commande



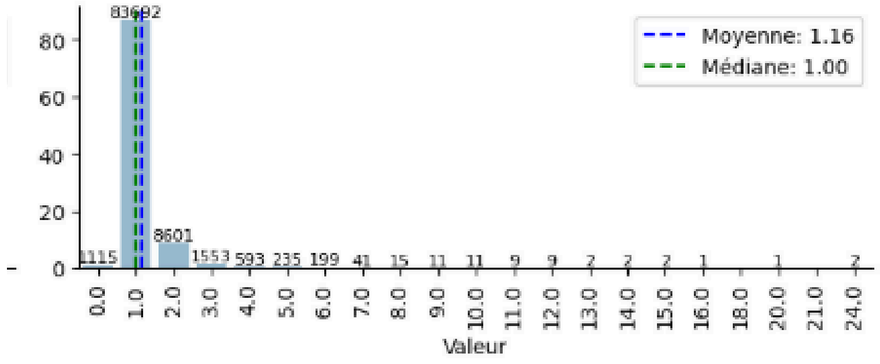
Ancienneté du client



Nombre de produits moyen par commandes

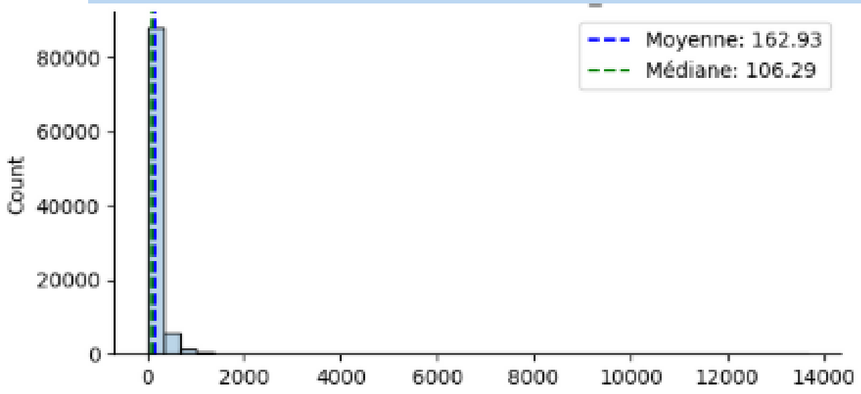


Nombre de produits total achetés

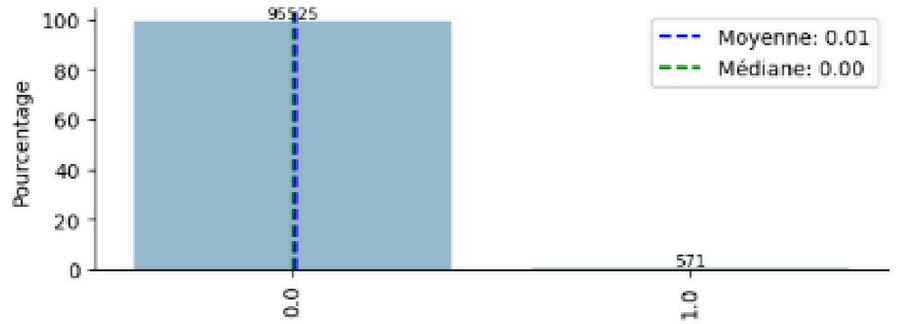


Construction du profil client

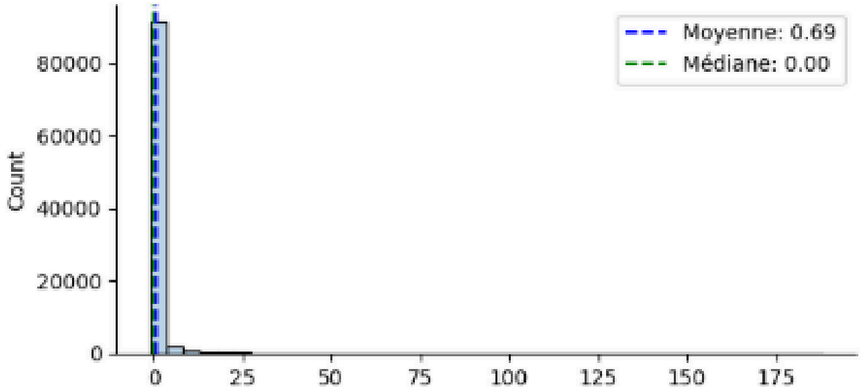
Montant total



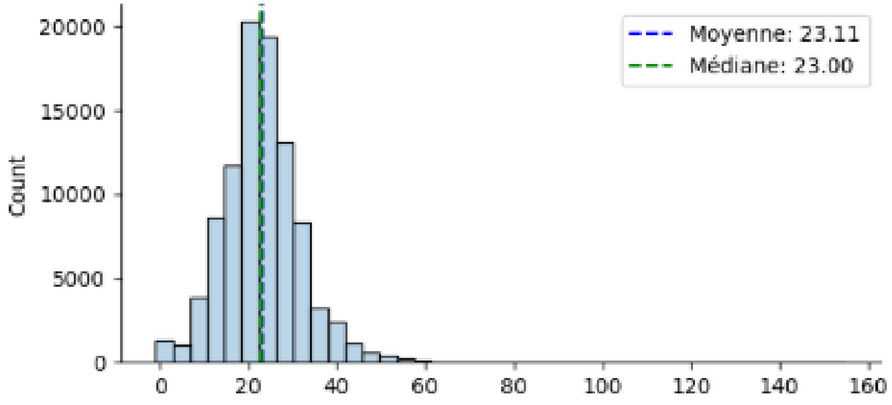
Nombre de commande annulées



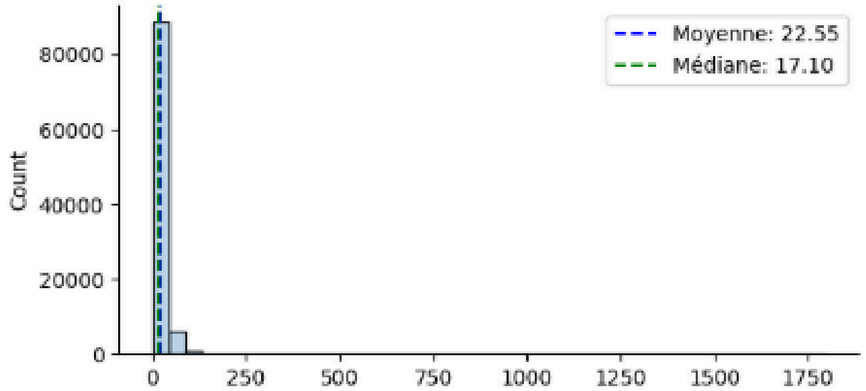
Nombre de jours de retard à la livraison moyen



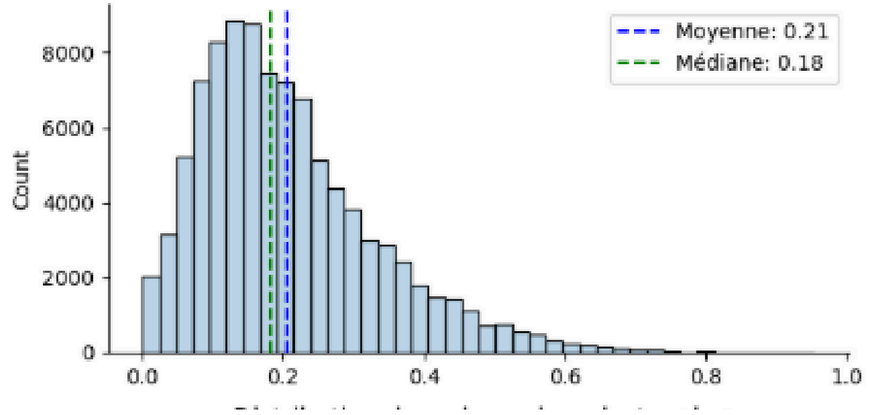
Délais moyen entre l'achat et la livraison estimée

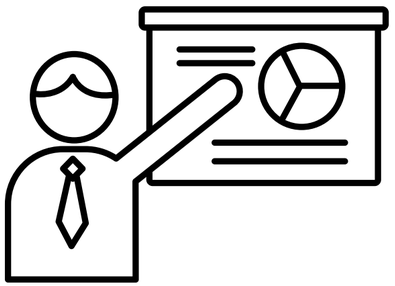


Frais de port moyen

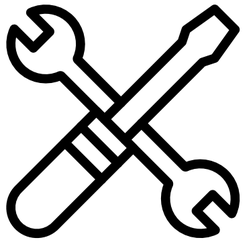


Rapport moyen entre les frais de port et le montant total





Présentation des données



Feature engineering



Segmentation



Contrat de maintenance

Segmentation

PLAN

1

2

SEGMENTATION

a

b

c

3

SYNTHÈSE

CHOIX FINAL

4

PRETRAITEMENT DES DONNÉES

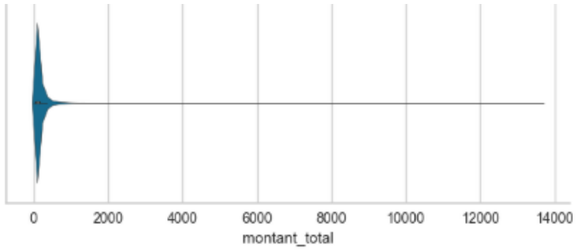
Variable asymétrique
PowerTransform

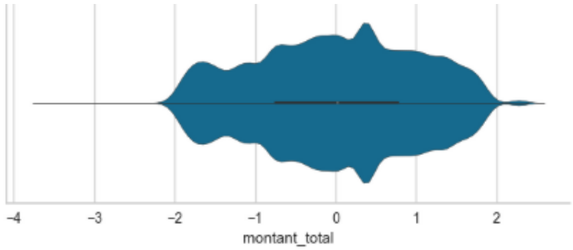
Variable discrètes
MinMax

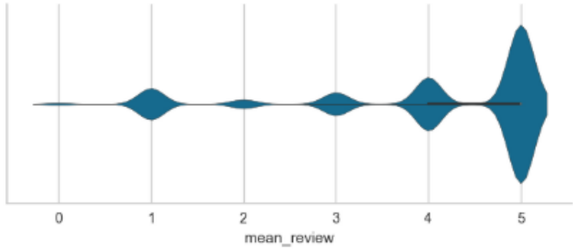
Variable binaire
pas de traitement

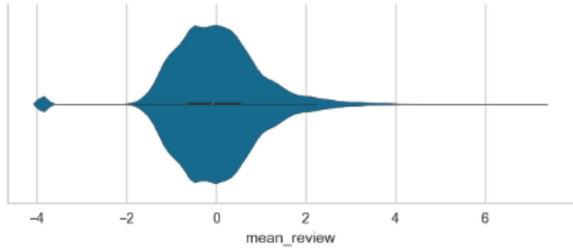
AVANT NORMALLISATION

APRES NORMALLISATION









PLAN

CHOIX FINAL

1

2

a

b

c

3

4

SEGMENTATION

SYNTHÈSE

Segmentation

PRETRAITEMENT DES DONNÉES

Variable asymétrique
PowerTransform

Variable discrètes
MinMax

Variable binaire
pas de traitement

CHOIX DE L'ALGORITHME

KMeans

KMédoïd

DBSCAN

Agglomerative Clustering

CHOIX DES VARIABLES

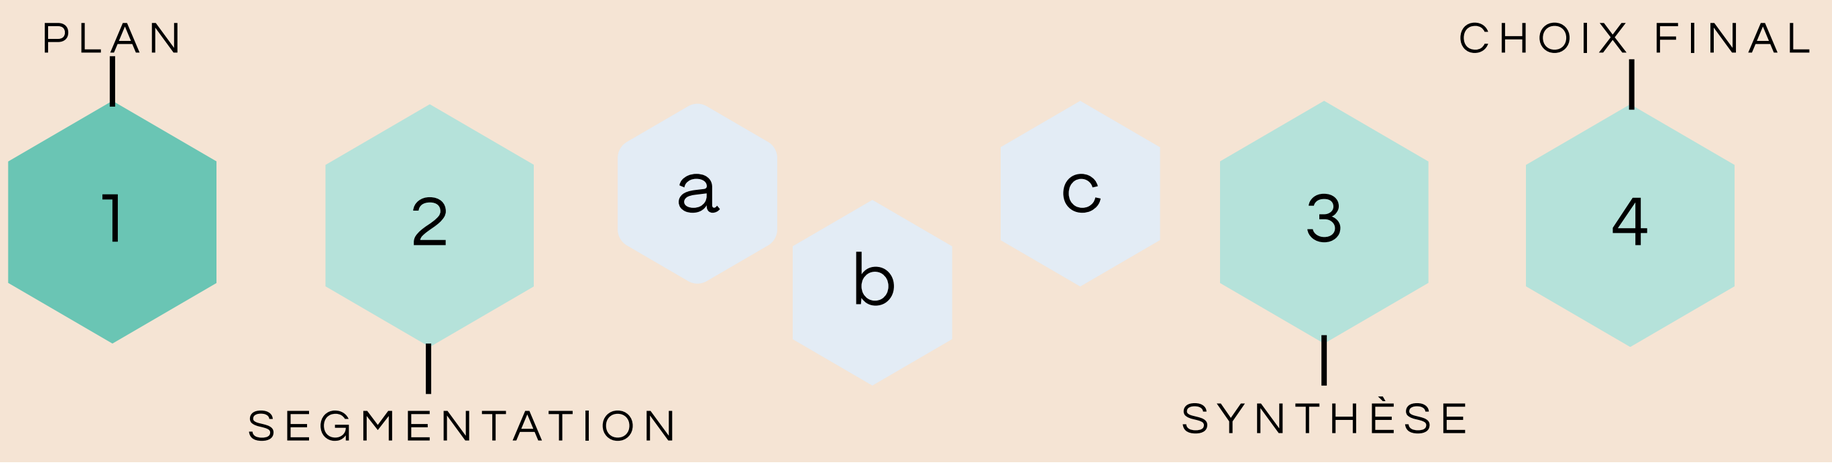
RFM

RFRMA : RFM + Avis

RFMADC = RFMA + retard de livraison + nombre de commandes annulées

RFMADCMJ = RFMADC + jours préféré d'achat + mois préféré d'achat

Segmentation



PRETRAITEMENT DES DONNÉES

Variable asymétrique
PowerTransform

Variable discrètes
MinMax

Variable binaire
pas de traitement

CHOIX DE L'ALGORITHME

KMeans

KMédoïd

DBSCAN

Agglomerative Clustering

CHOIX DES VARIABLES

RFM

RFRMA : RFM + Avis

RFMADC = RFMA + retard de livraison + nombre de commandes annulées

RFMADCMJ = RFMADC + jours préféré d'achat + mois préféré d'achat

Segmentation

PLAN

1

2

SEGMENTATION

a

b

c

3

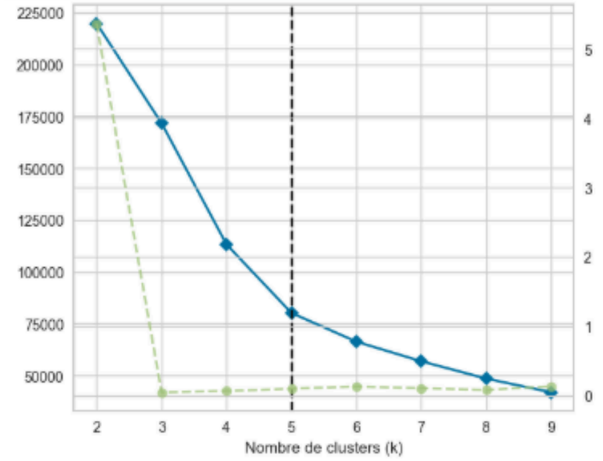
SYNTHÈSE

CHOIX FINAL

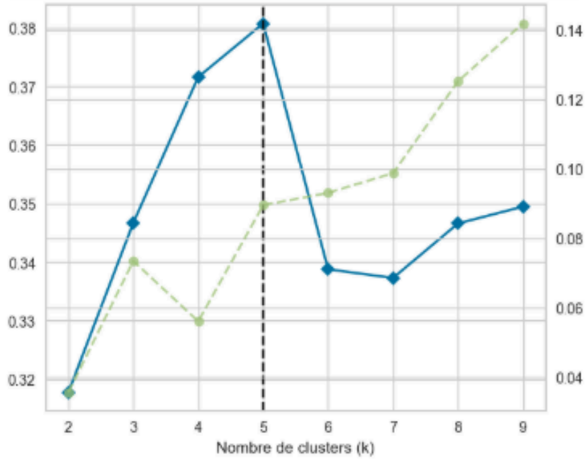
4

Optimisation des paramètres

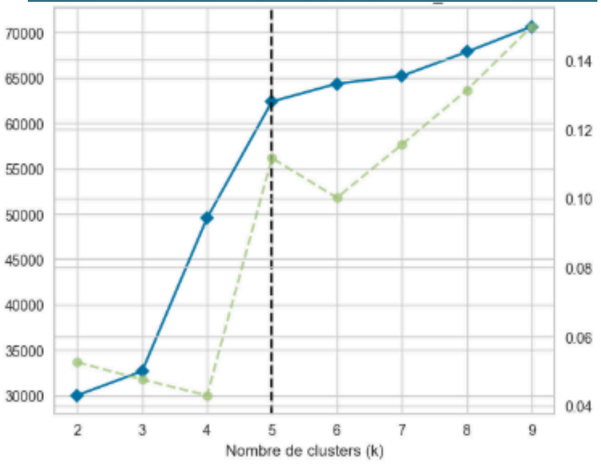
Distorsion



Silhouette



Calinski-Harabasz



PLAN

CHOIX FINAL

1

2

a

b

c

3

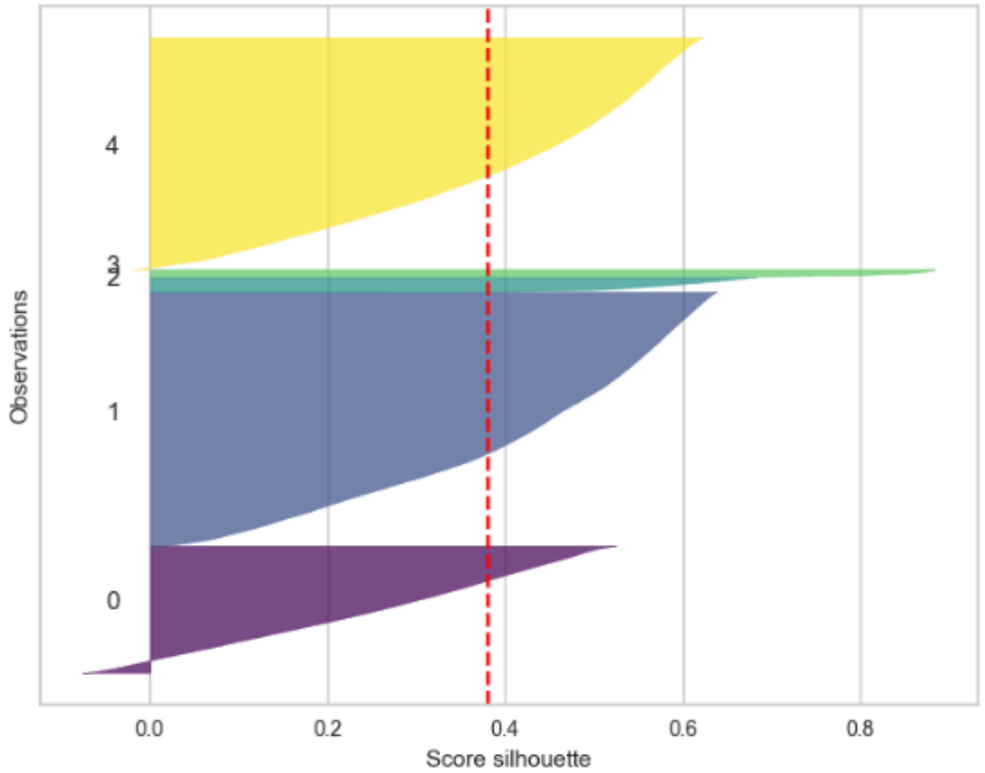
4

SEGMENTATION

SYNTHÈSE

Segmentation

Analyse des scores de silhouette



PLAN

CHOIX FINAL

1

2

a

b

c

3

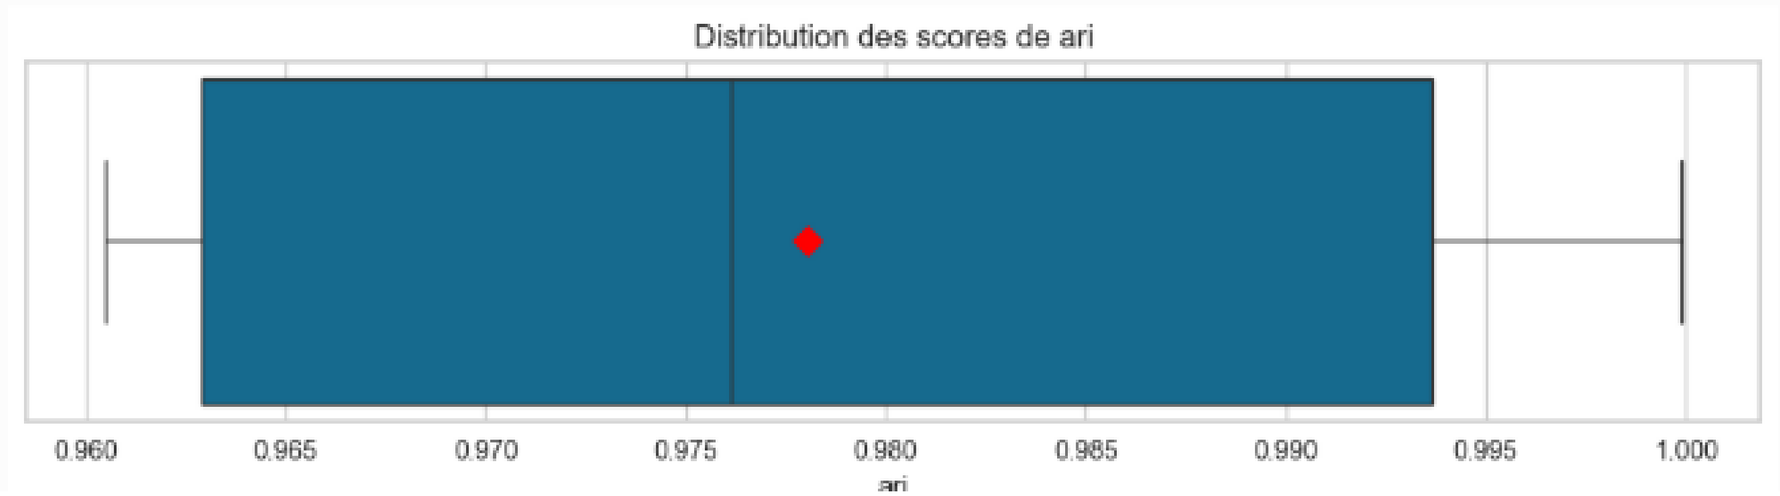
4

SEGMENTATION

SYNTHÈSE

Segmentation

Stabilité à l'initialisation



Segmentation

PLAN

1

2

SEGMENTATION

a

b

c

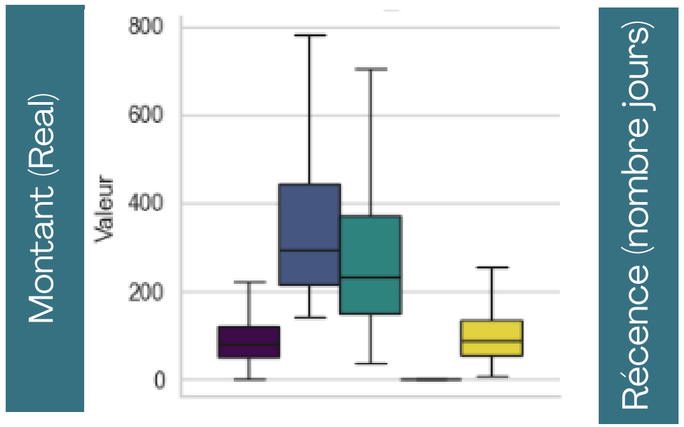
3

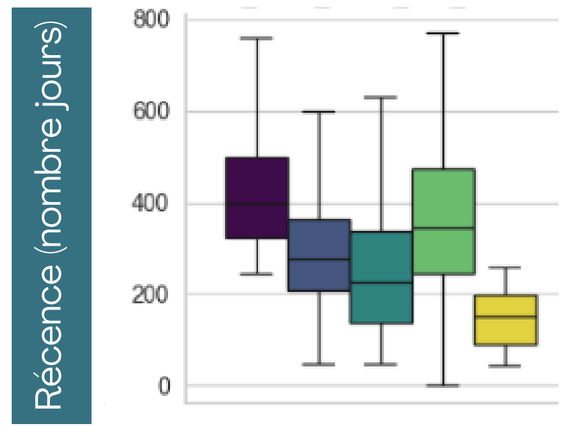
SYNTHÈSE

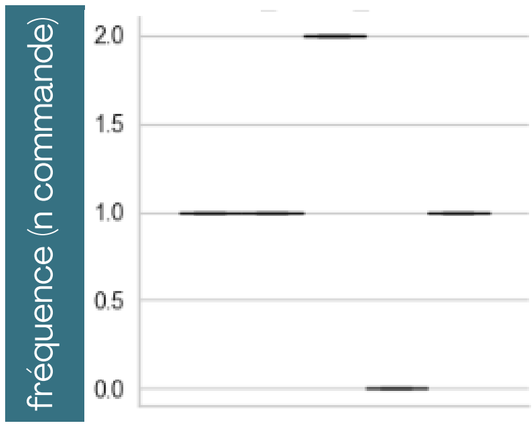
CHOIX FINAL

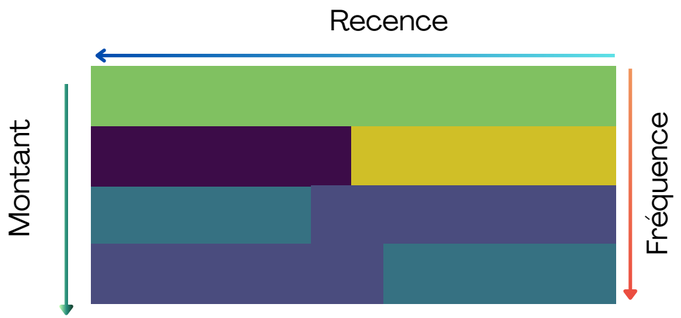
4

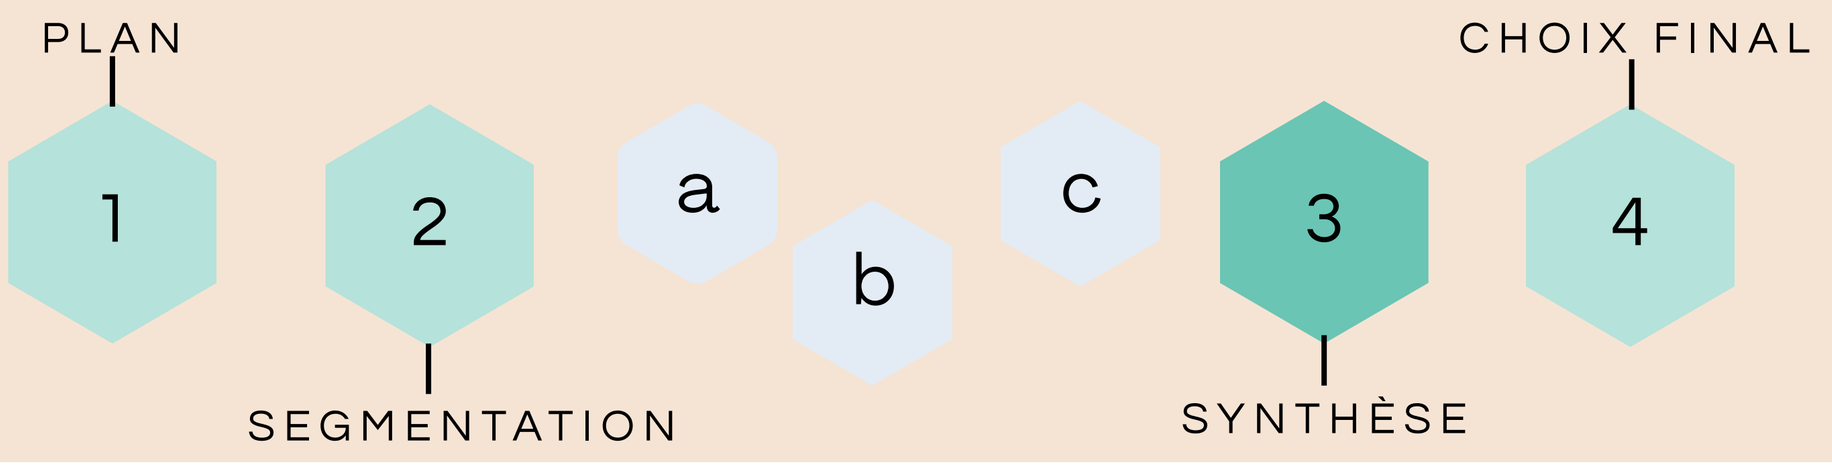
Caractérisation des profils clients





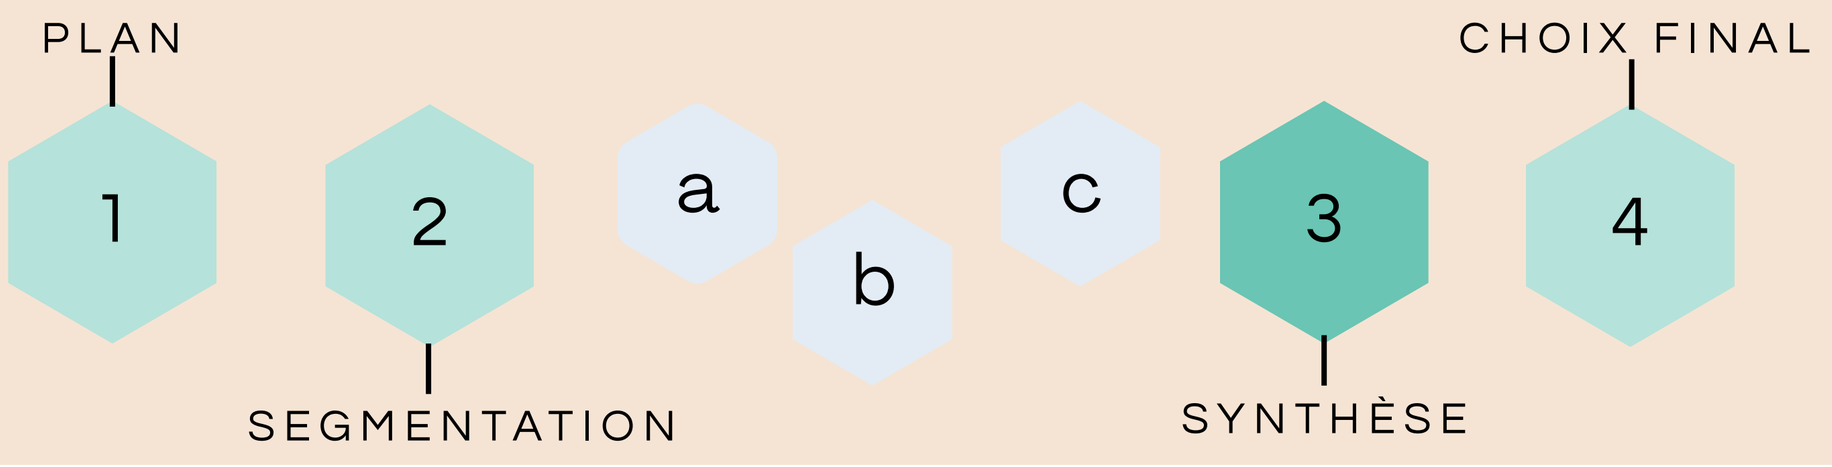






Segmentation

	Nombre cluster	Silhouette	Stabilité	Effectif cluster	Exploitabilité
KMean RFM	5	0.38	++	Hétérogène	++
KMean RFMA	5	0.36	++	Hétérogène	++
KMean RFMADC	6	0.37	++	Hétérogène	+++
Kmédoid	6	0.17			
DBSCAN	6	0.60	+++	Très hétérogène	
AgglomerativeClust	4	0.31	+++	Hétérogène	++



Segmentation

	Nombre cluster	Silhouette	Stabilité	Effectif cluster	Exploitabilité
KMean RFM	5	0.38	++	Hétérogène	++
KMean RFMA	5	0.36	++	Hétérogène	++
KMean RFMADC	6	0.37	++	Hétérogène	+++
Kmédoid	6	0.17			
DBSCAN	6	0.60	+++	Très hétérogène	
AgglomerativeClust	4	0.31	+++	Hétérogène	++

PLAN

CHOIX FINAL

1

2

a

b

c

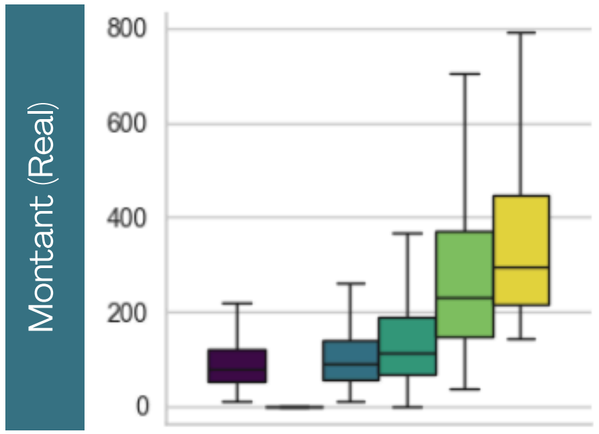
3

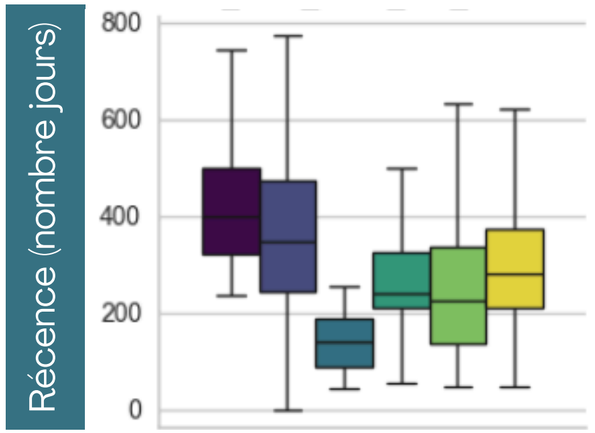
4

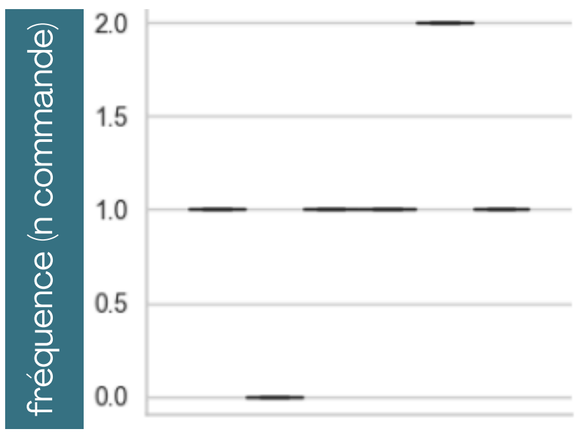
SEGMENTATION

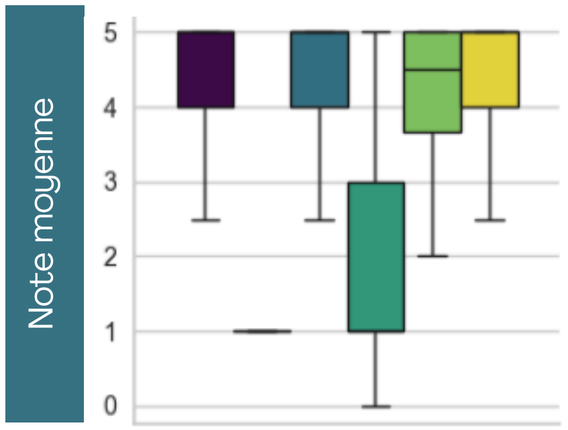
SYNTHÈSE

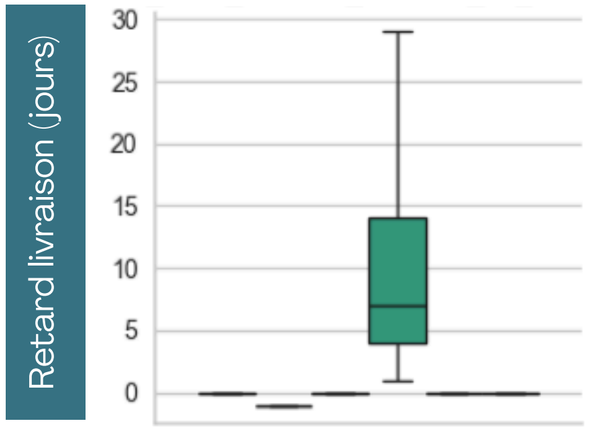
Segmentation

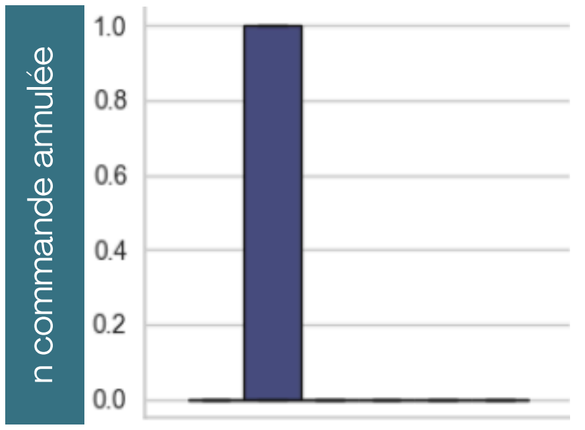












PLAN

CHOIX FINAL

1

2

a

b

c

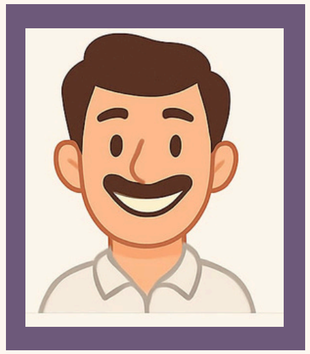
3

4

SEGMENTATION

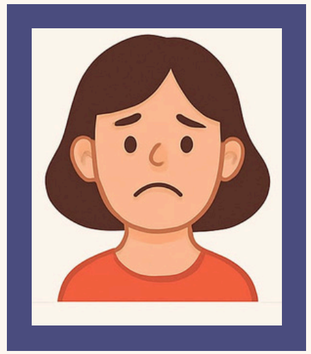
SYNTHÈSE

Segmentation



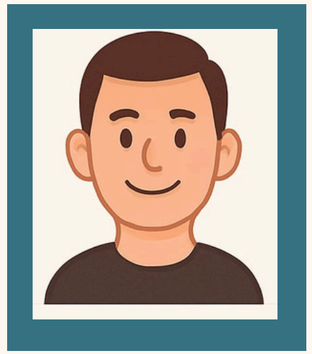
L’occasionnel

Ancien
Peu dépensier
Satisfait



Le frustré

Insatisfait
Commande
non aboutie



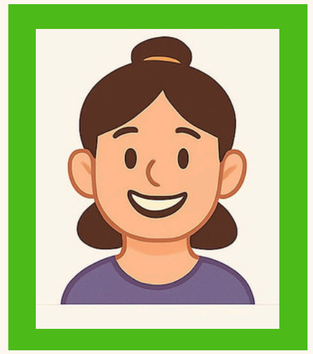
Le nouveau

Récent
Peu dépensier
Très satisfait



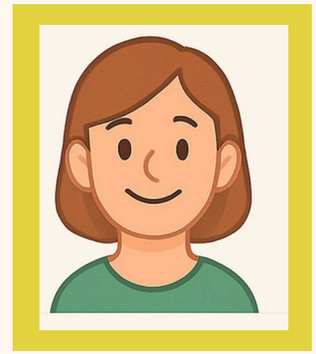
Le mécontent

Retard de
livraison
Insatisfait



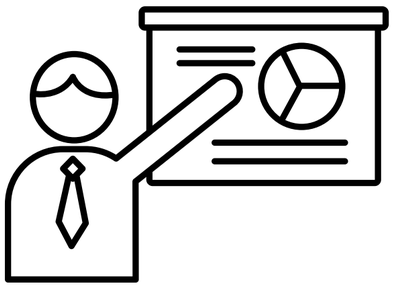
Le Fidèle

Actif
Très satisfait

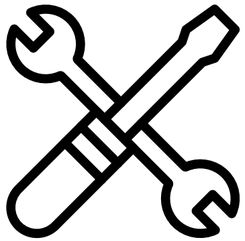


Le prenium

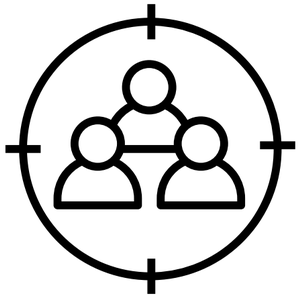
Grosse
dépense
Satisfait



Présentation des données



Feature engineering



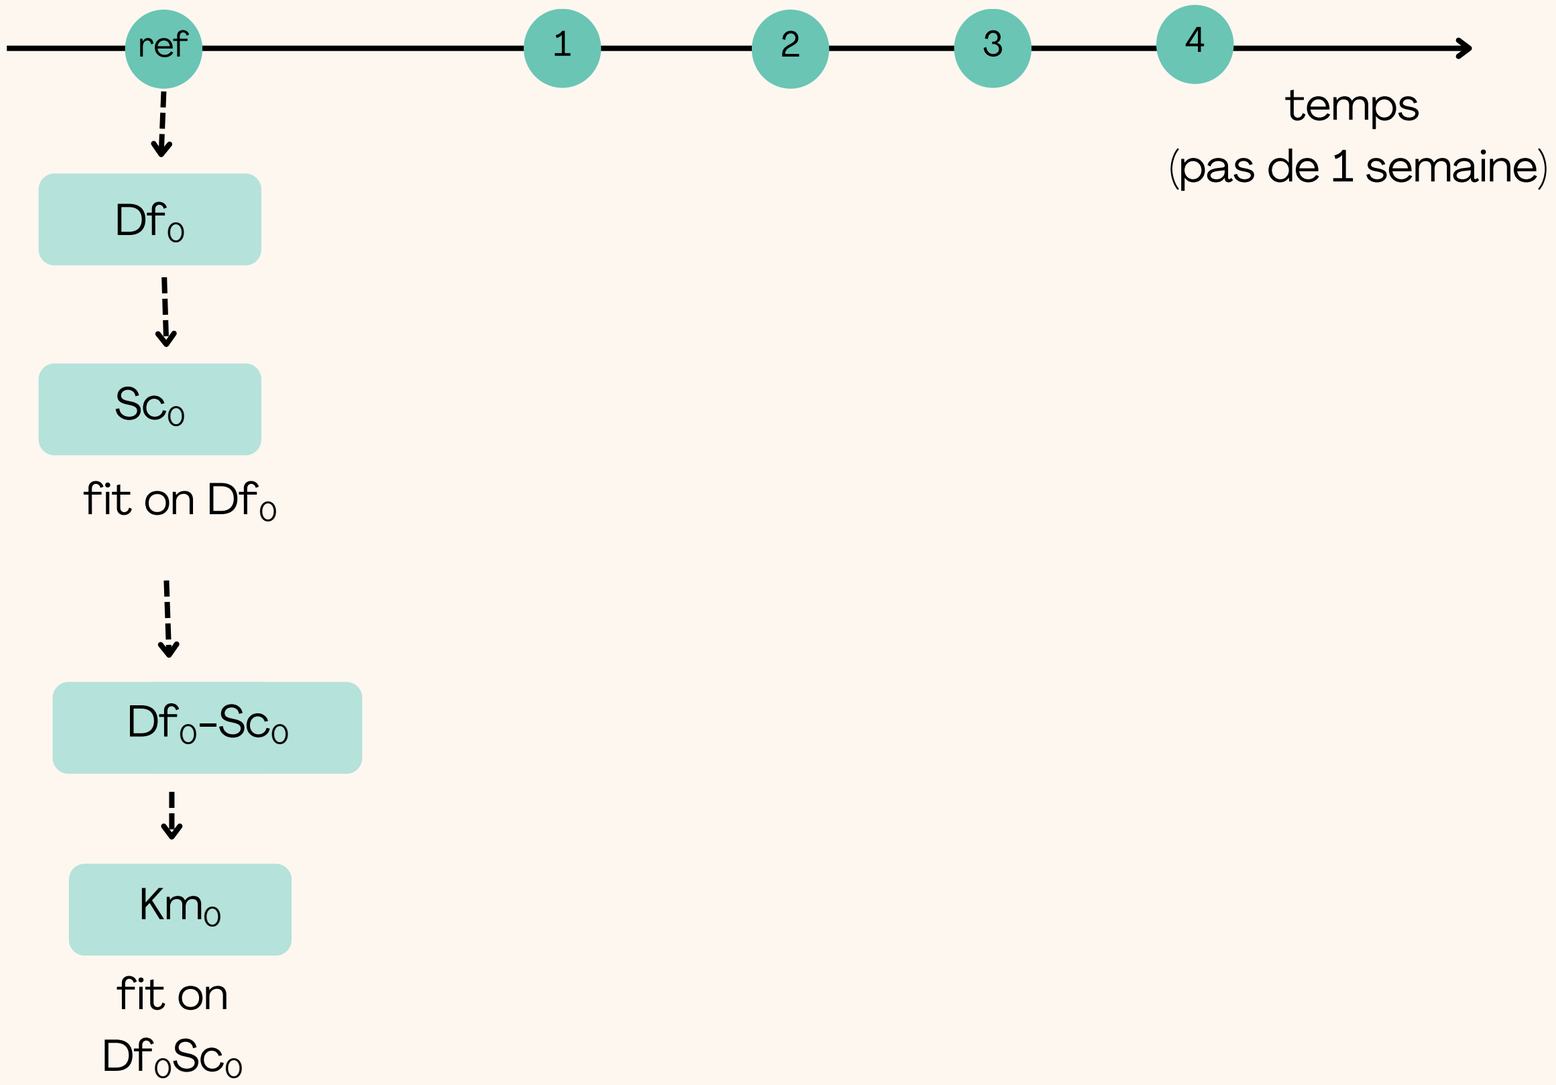
Segmentation



Contrat de maintenance

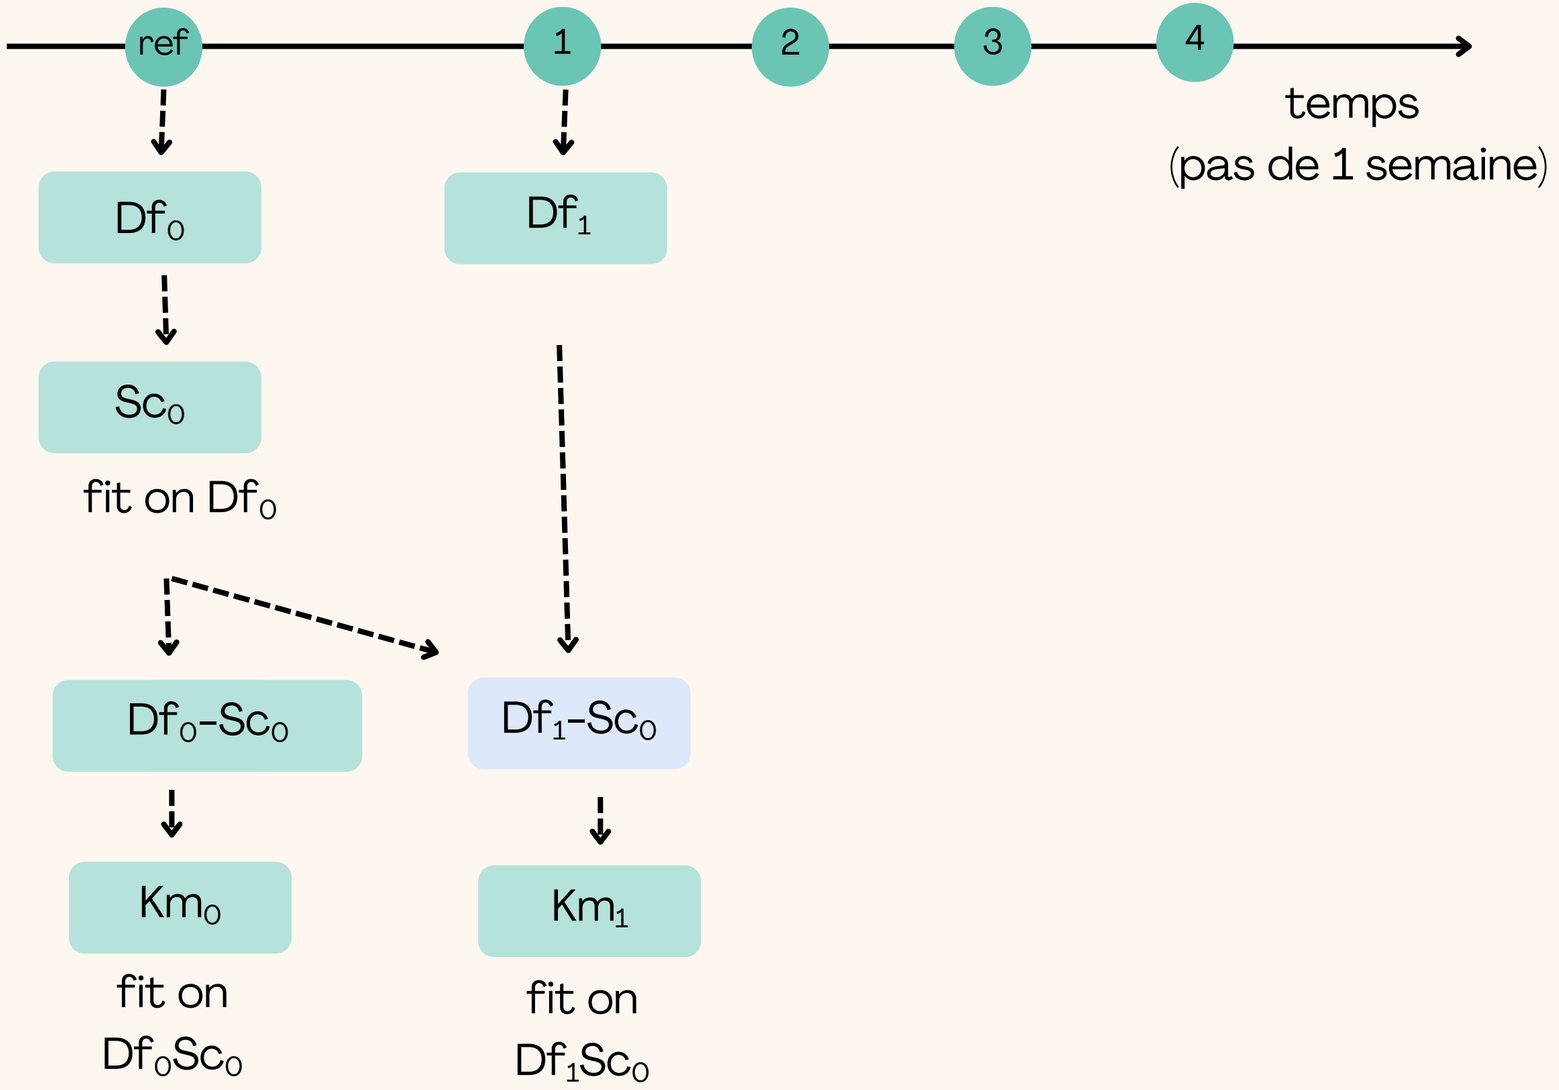
Evaluation de la stabilité temporelle

Schéma de l'approche



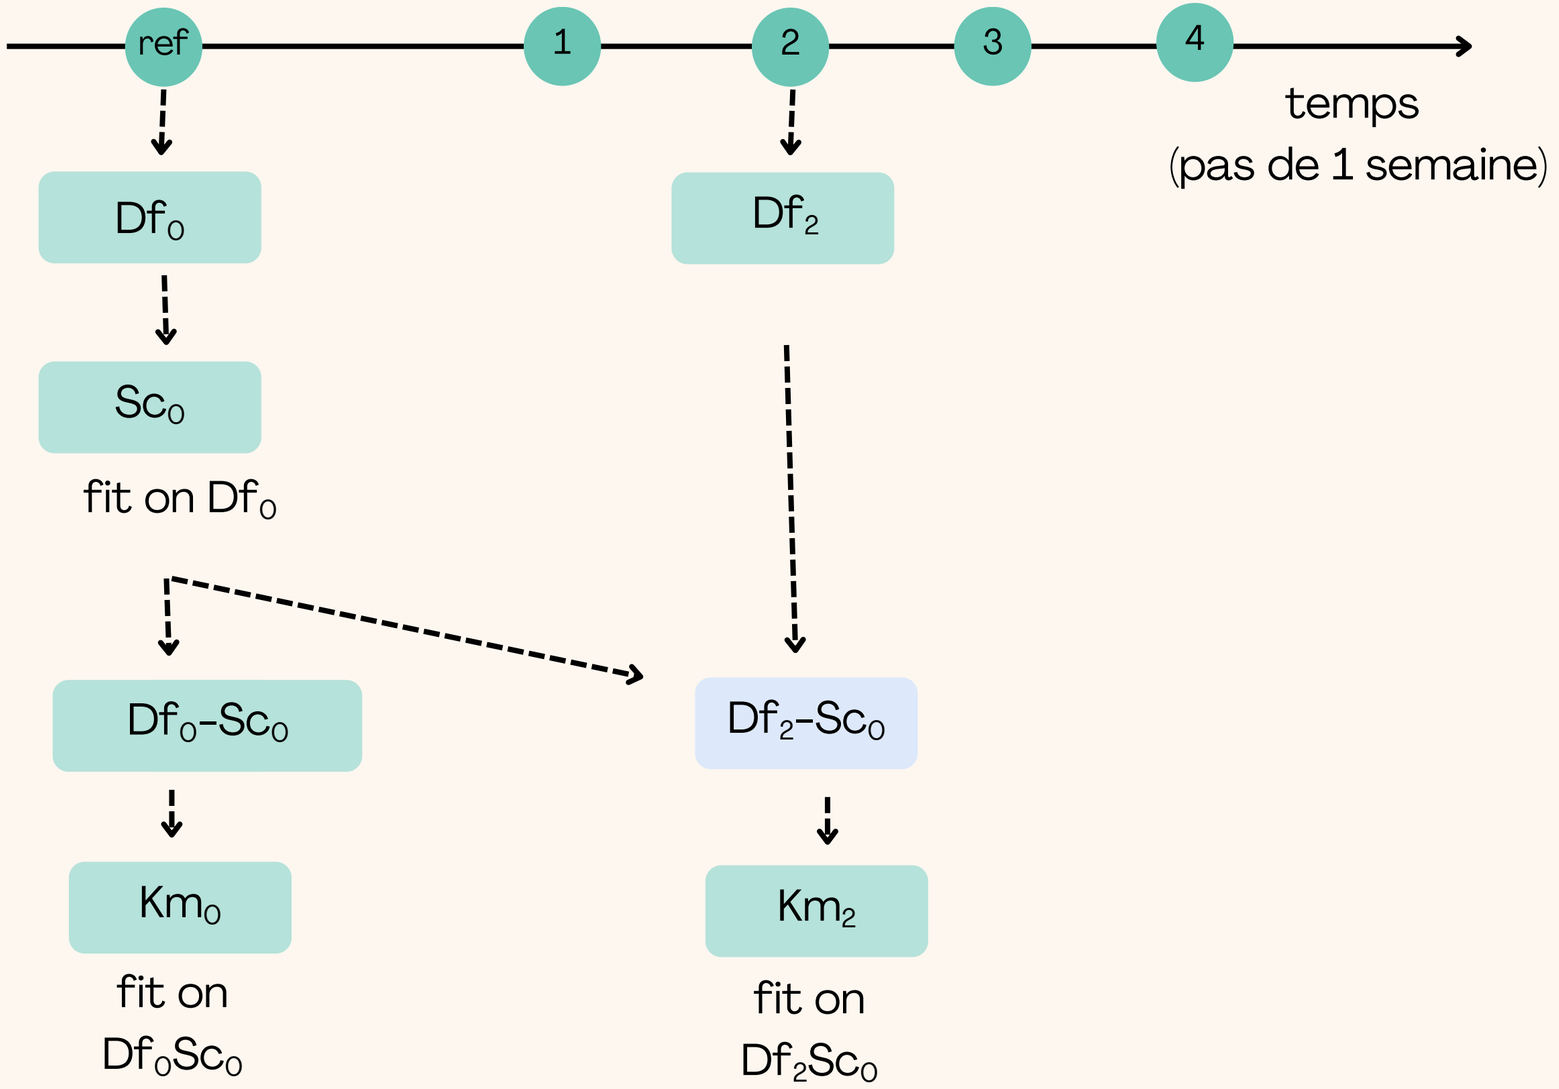
Evaluation de la stabilité temporelle

Schéma de l'approche



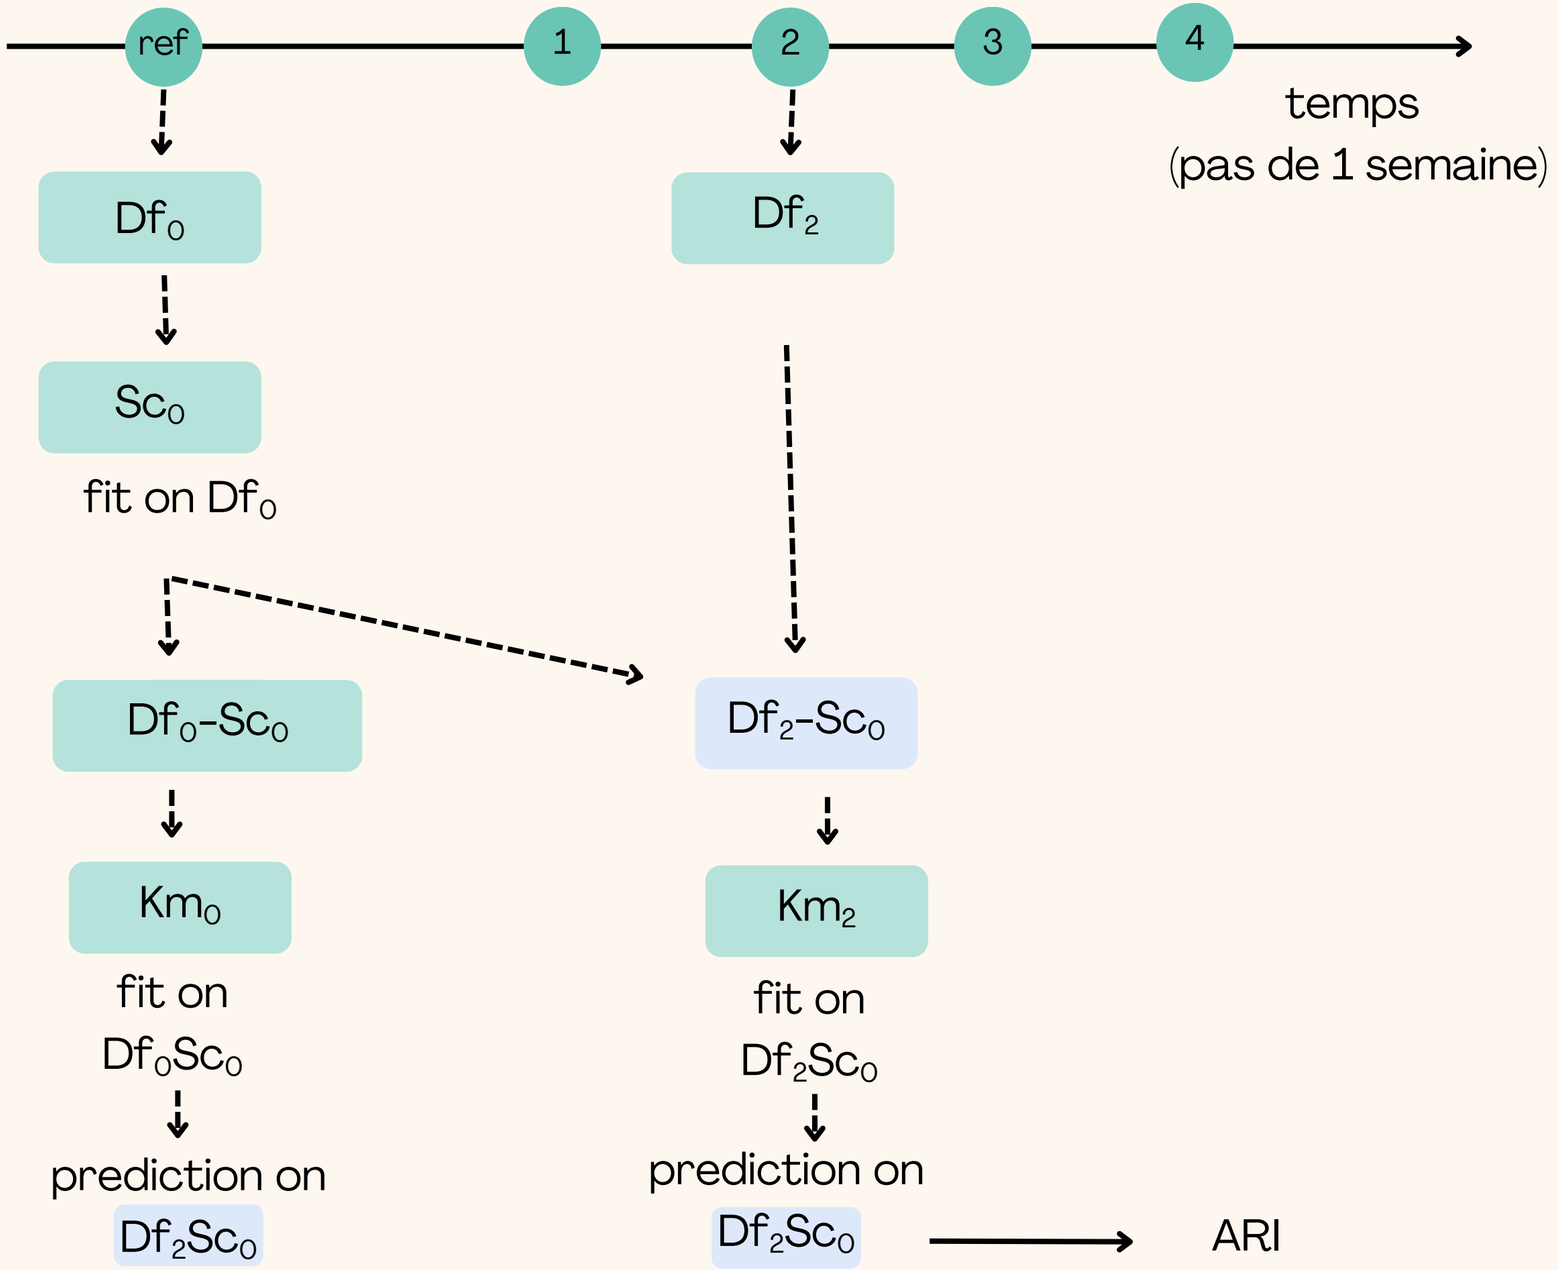
Evaluation de la stabilité temporelle

Schéma de l'approche

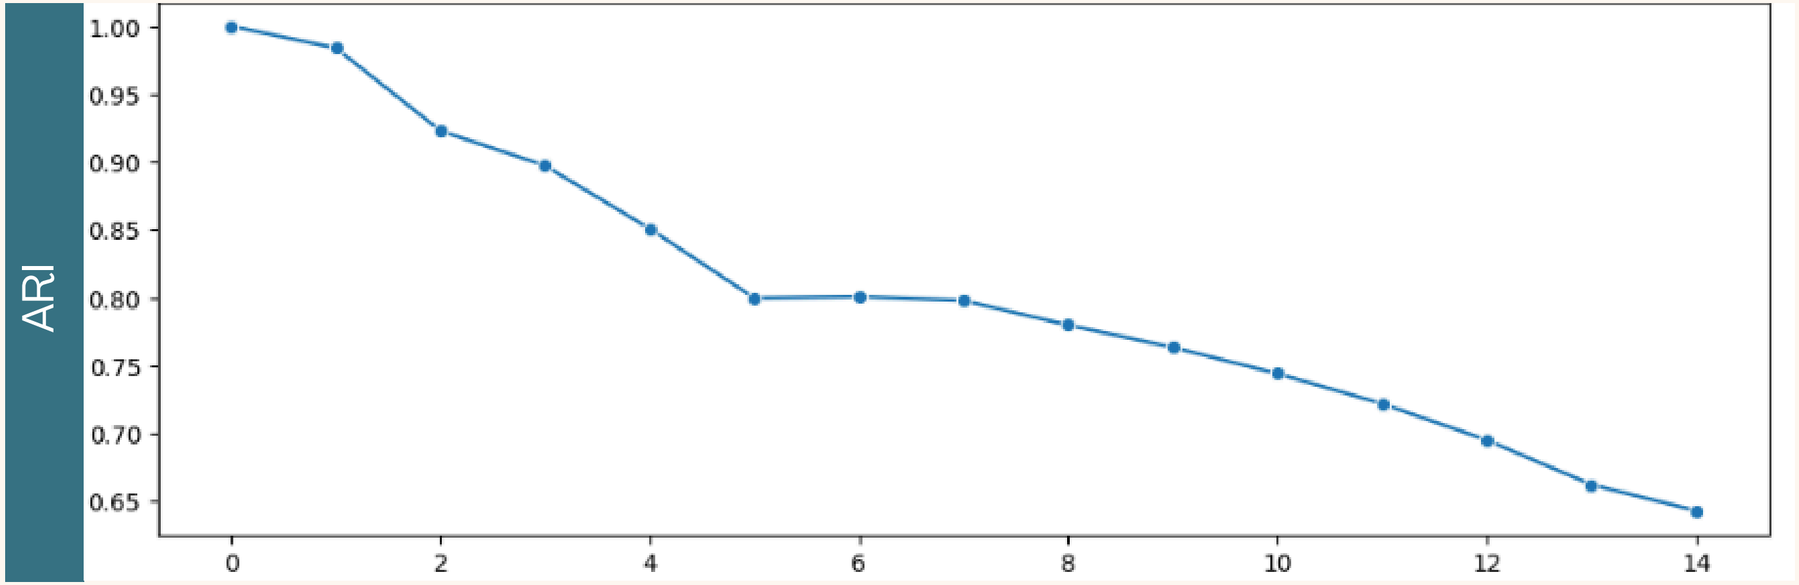


Evaluation de la stabilité temporelle

Schéma de l'approche

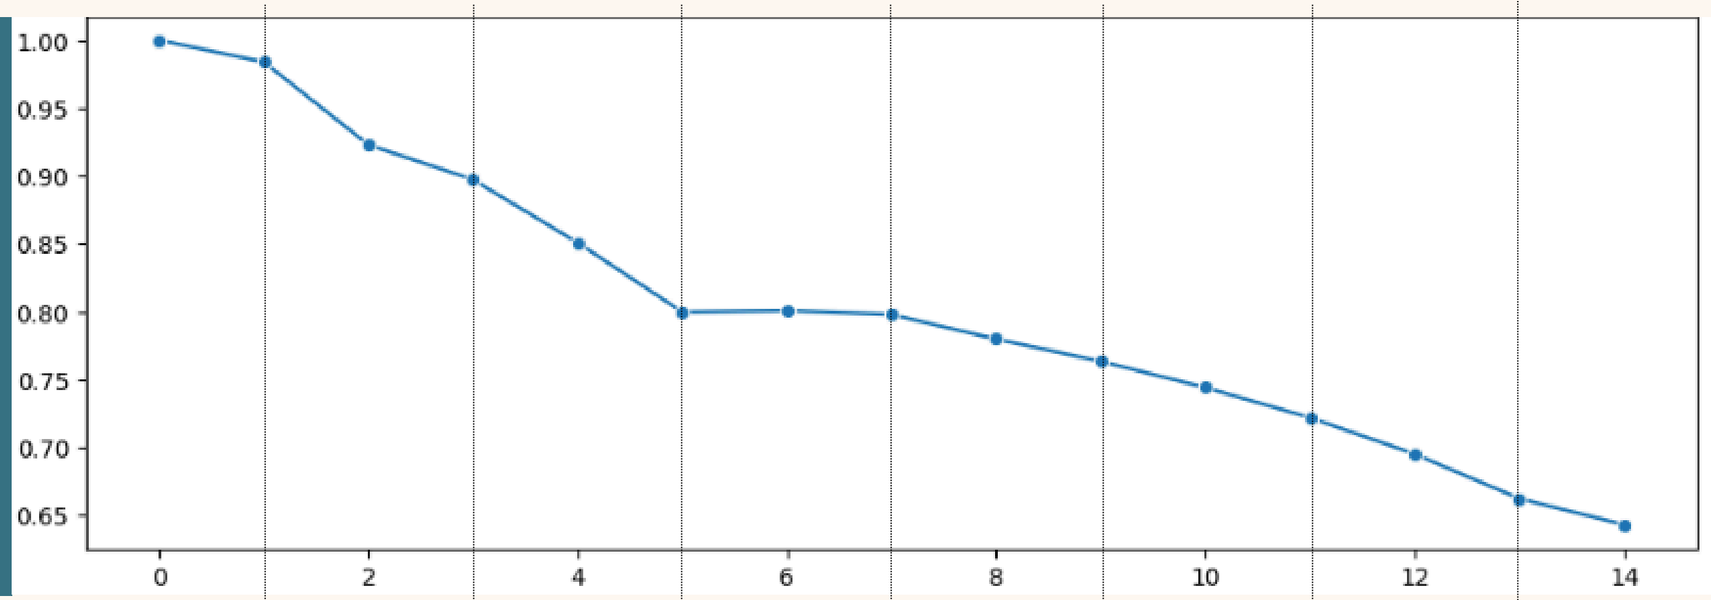


Evaluation de la stabilité temporelle

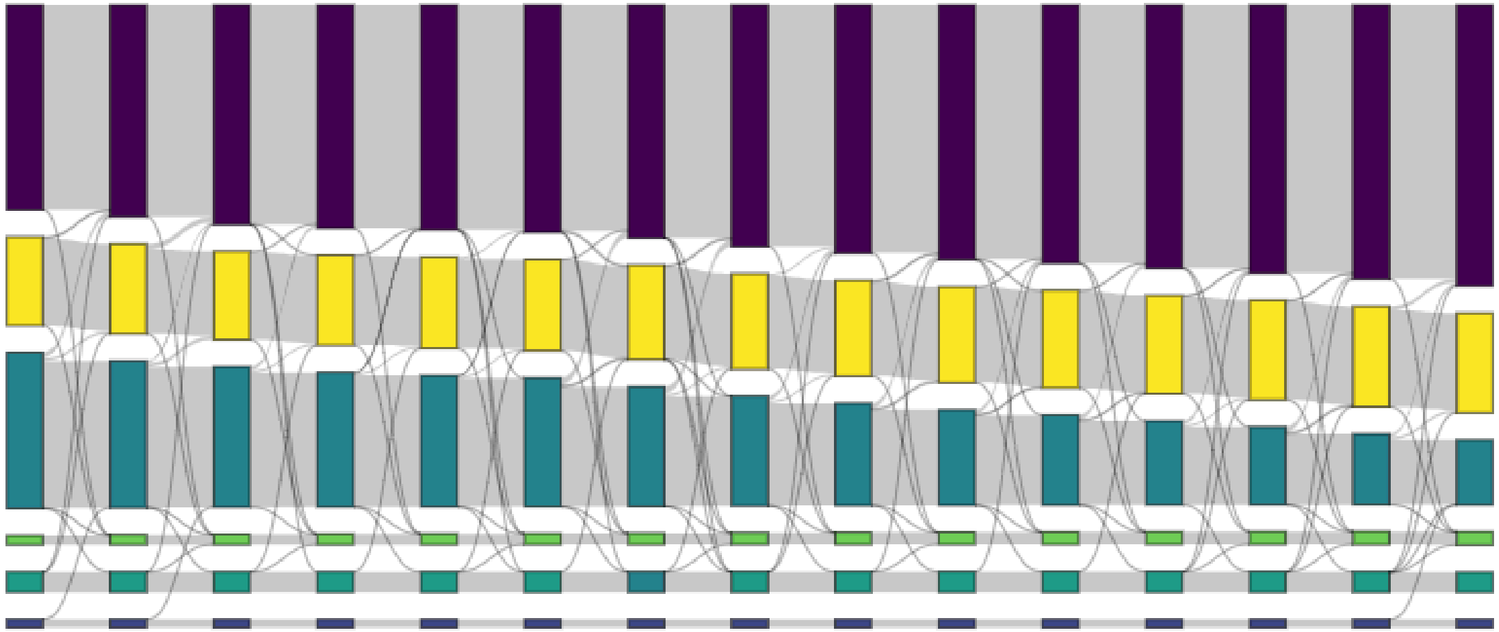


Evaluation de la stabilité temporelle

ARI



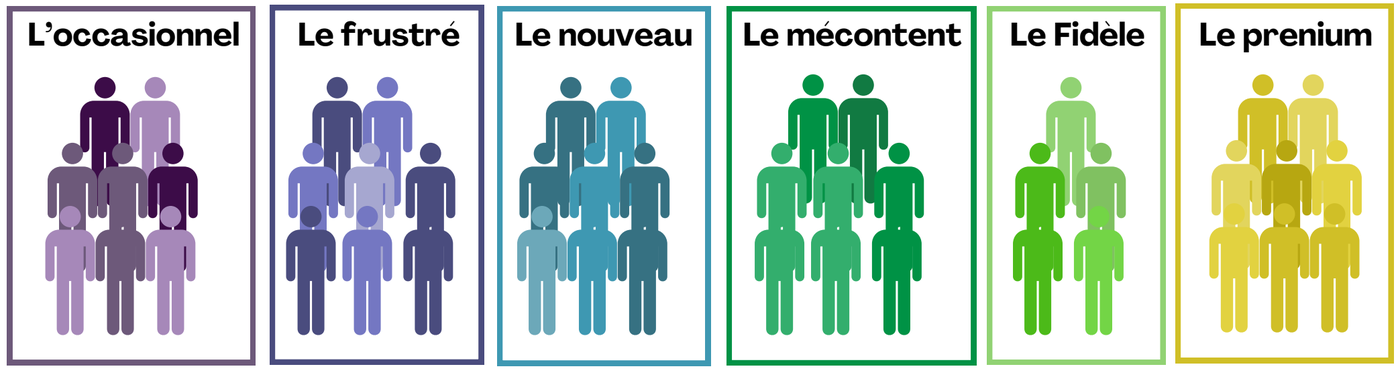
FLUX DES CLEINTS



Conclusions

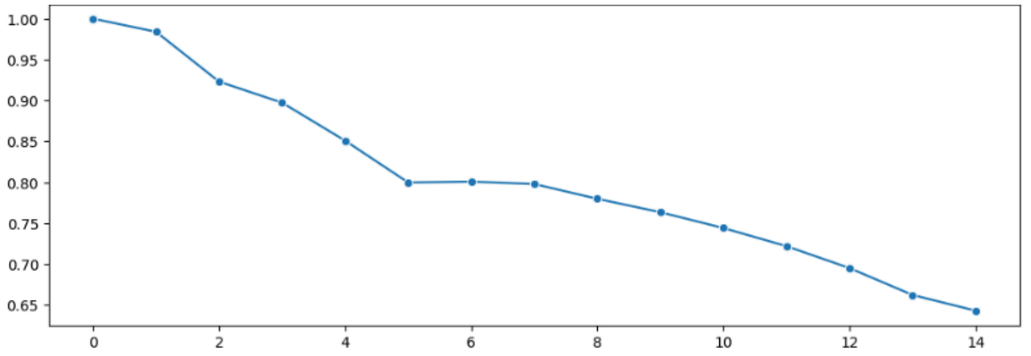
Segmenter la base client

KMeans appliqué à 6 variables
Score de silhouette modéré
Identification de 6 profils clients cohérents et actionnables



Fournir un contrat de maintenance

Globalement stable
Réentrainement tous les 2 mois



Merci pour votre attention

KMEANS

Diapos Supp

PLACEMENT DES PREMIERS CENTROIDES

Kmeans ++

CHOIX DU 1ER CENTROÏDE ALÉATOIREMENT PARMI LES POINTS DU JEU DE DONNÉES

AFFECTATION DES POINTS AU CENTROIDE LE PLUS PROCHE

POUR CHAQUE POINT RESTANT, CALCUL DE SA DISTANCE AU CENTROÏDE LE PLUS PROCHE DÉJÀ CHOISI.

CALCUL DES NOUVEAUX CENTROIDES

LE PROCHAIN CENTROÏDE EST CHOISI PARMI LES POINTS RESTANTS, AVEC UNE PROBABILITÉ PROPORTIONNELLE AU CARRÉ DE LA DISTANCE CALCULÉE À L'ÉTAPE PRÉCÉDENTE

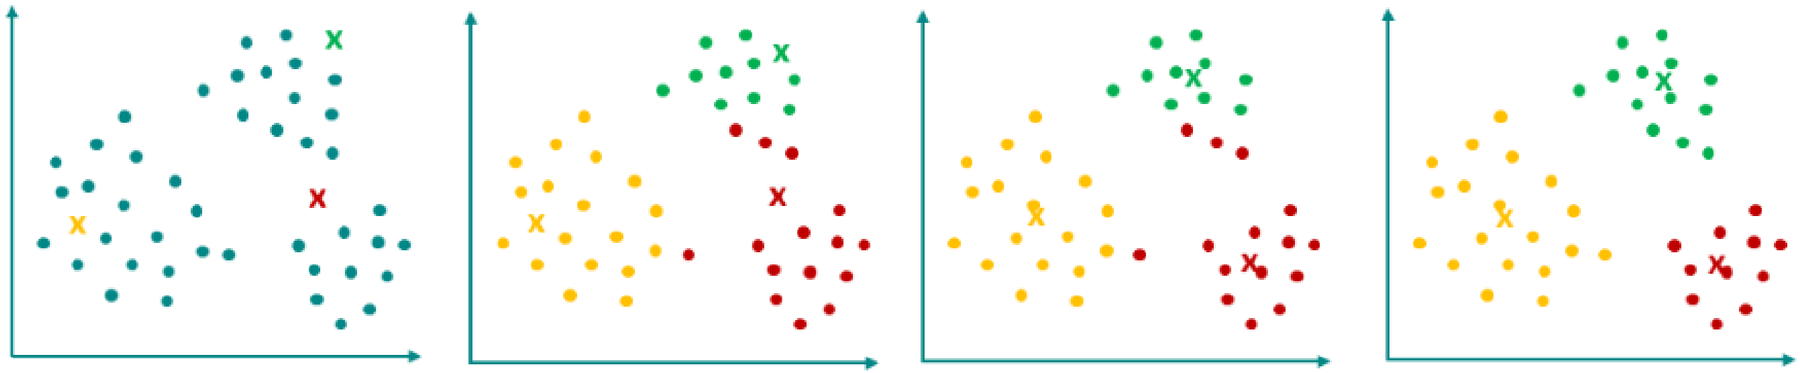


image: datatab.fr

AgglomerativeClustering

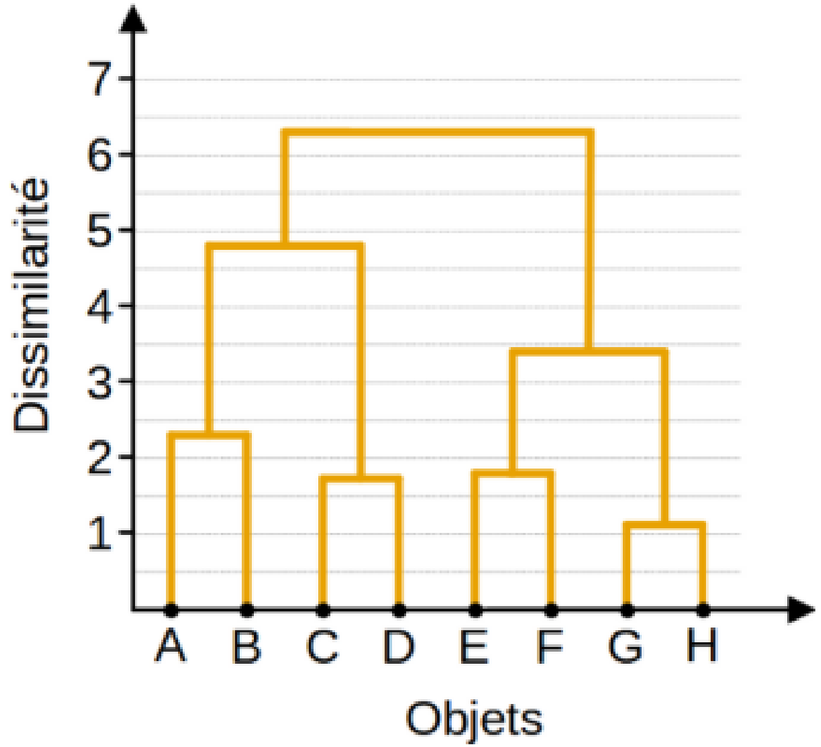
Diapos Supp

CHAQUE OBSERVATION EST CONSIDEREE COMME UN CLUSTER

CALCUL DES DISTANCES ENTRE CHAQUE PAIRE DE CLUSTERS

CALCUL DES DISTANCE INTRA CLUSTER

FUSION DES CLUSTERS LES PLUS PROCHES



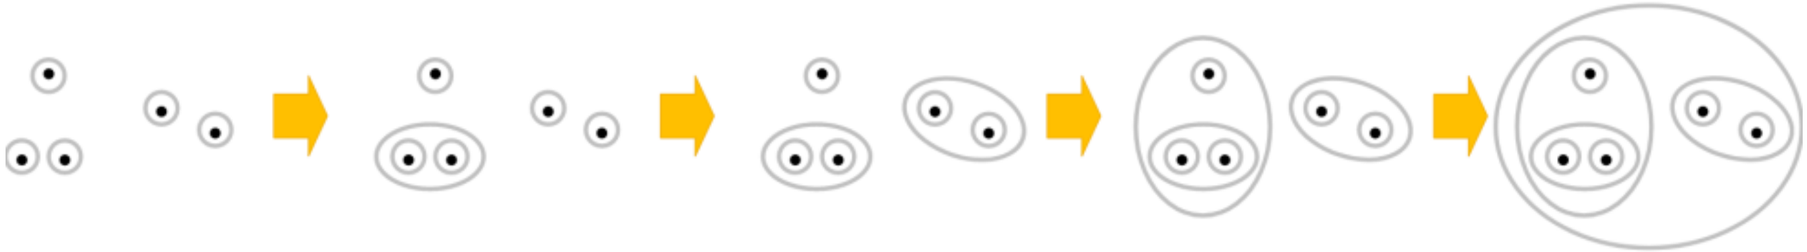


image: bioinfo-fr.net

Diapos Supp

DBSCAN

Pour chaque observation

CALCUL DU NOMBRE DE VOISIN DANS UN RAYON DE EPS

n voisins ≥ min sample ?

point coeur

voisins d'un point coeur ?

point de bordure

Bruit

Paramètres à optimiser

- EPS
- min sample

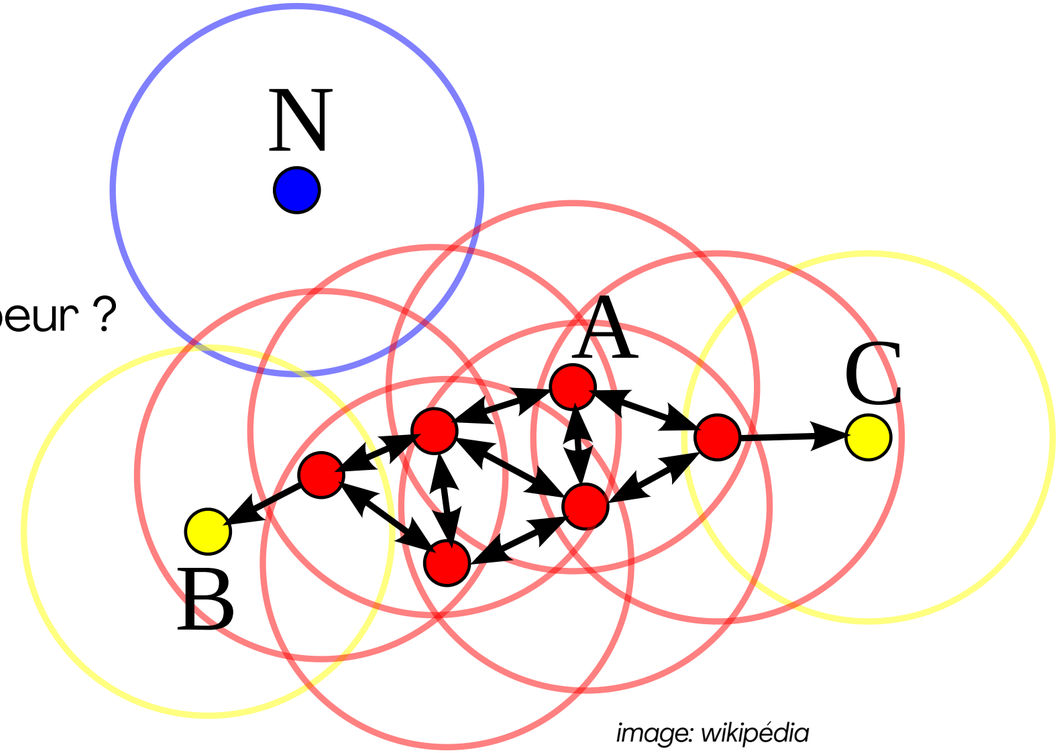


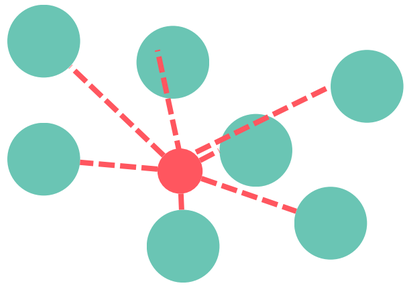
image: wikipédia

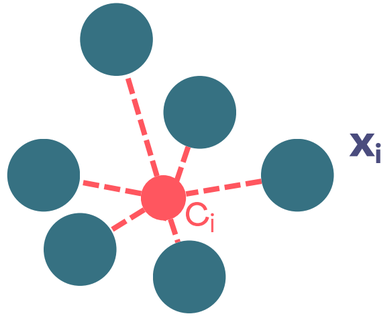
Diapos Supp

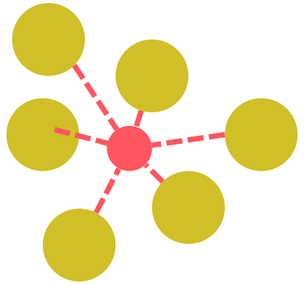
Score de distorsion

SOMME DES DISTANCES ENTRE CHAQUE POINT ET SON CENTROÏDE DE CLUSTER

$$\text{Distorsion} = \sum_{i=1}^{k} \sum_{x \in C_i} \|x - \mu_i\|^2$$







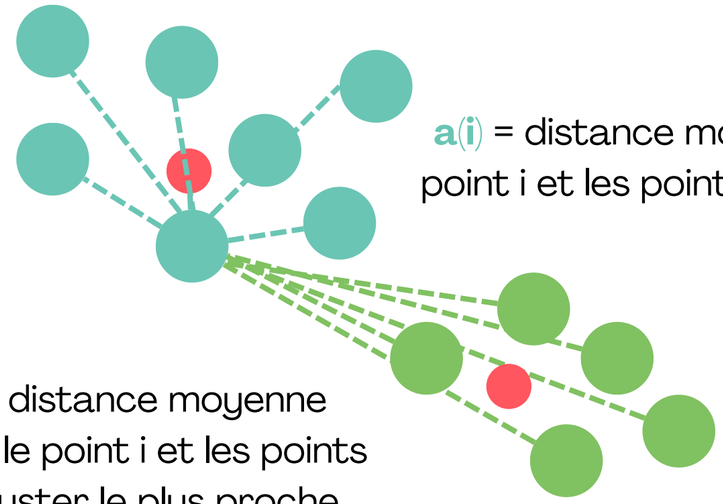
Meilleure qualité quand la distorsion est faible

Score de silhouette

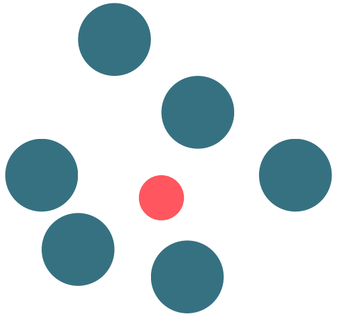
Diapos Supp

MESURE À QUEL POINT LES POINTS SONT BIEN REGROUPÉS DANS LEURS CLUSTERS (COHÉSION) ET BIEN SÉPARÉS DES AUTRES CLUSTERS (SÉPARATION).

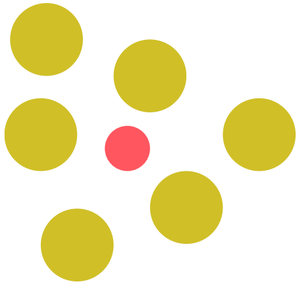
$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$



a(i) = distance moyenne entre le point i et les points de son cluster



b(i)= distance moyenne entre le point i et les points du cluster le plus proche



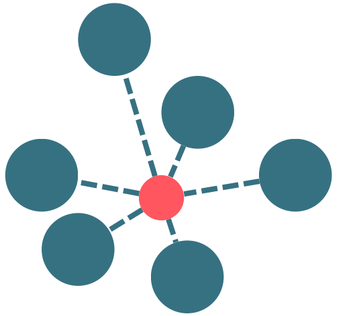
Meilleure qualité quand le score de silhouette se rapproche de 1

Score de Davies-Bouldin

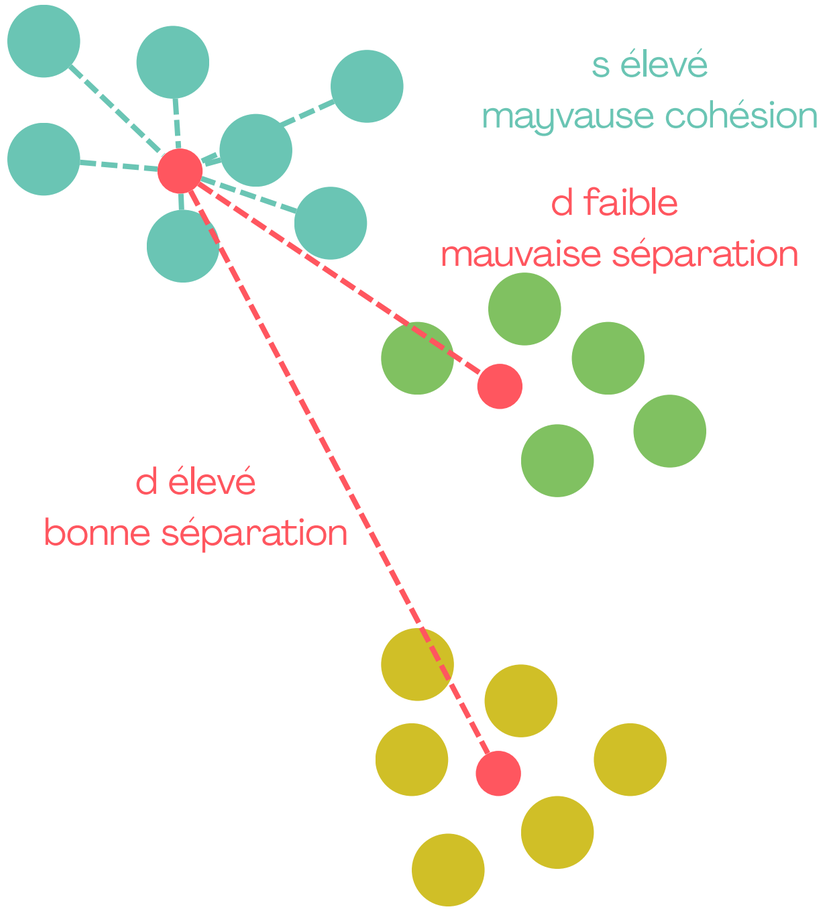
Diapos Supp

MESURERLA SIMILARITÉ ENTRE LES CLUSTERS EN COMPARANT LEUR DISPERSION INTERNE ET LEUR DISTANCE MUTUELLE

$$DBI = \frac{1}{k}\sum_{i=1}^{k}\max_{j\neq i}\left(\frac{s_i + s_j}{d_{ij}}\right)$$



s faible
bonne cohésion



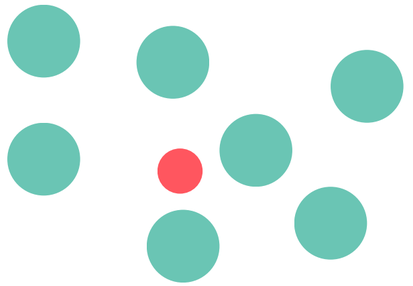
Meilleure qualité quand DBI est faible

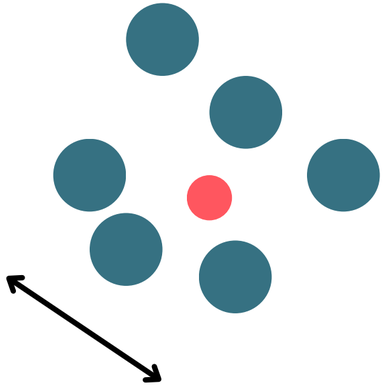
Diapos Supp

Score de Calinski-Harabasz

COMPARE LA DISPERSION ENTRE LES CLUSTERS À LA DISPERSION À L'INTÉRIEUR DES CLUSTERS.

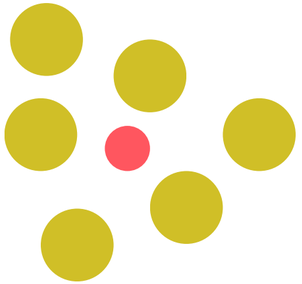
$$CH = \frac{\mathrm{Tr}(B_k)}{\mathrm{Tr}(W_k)} \cdot \frac{n-k}{k-1}$$





Tr(**Bk**) variance
itercluster à maximiser

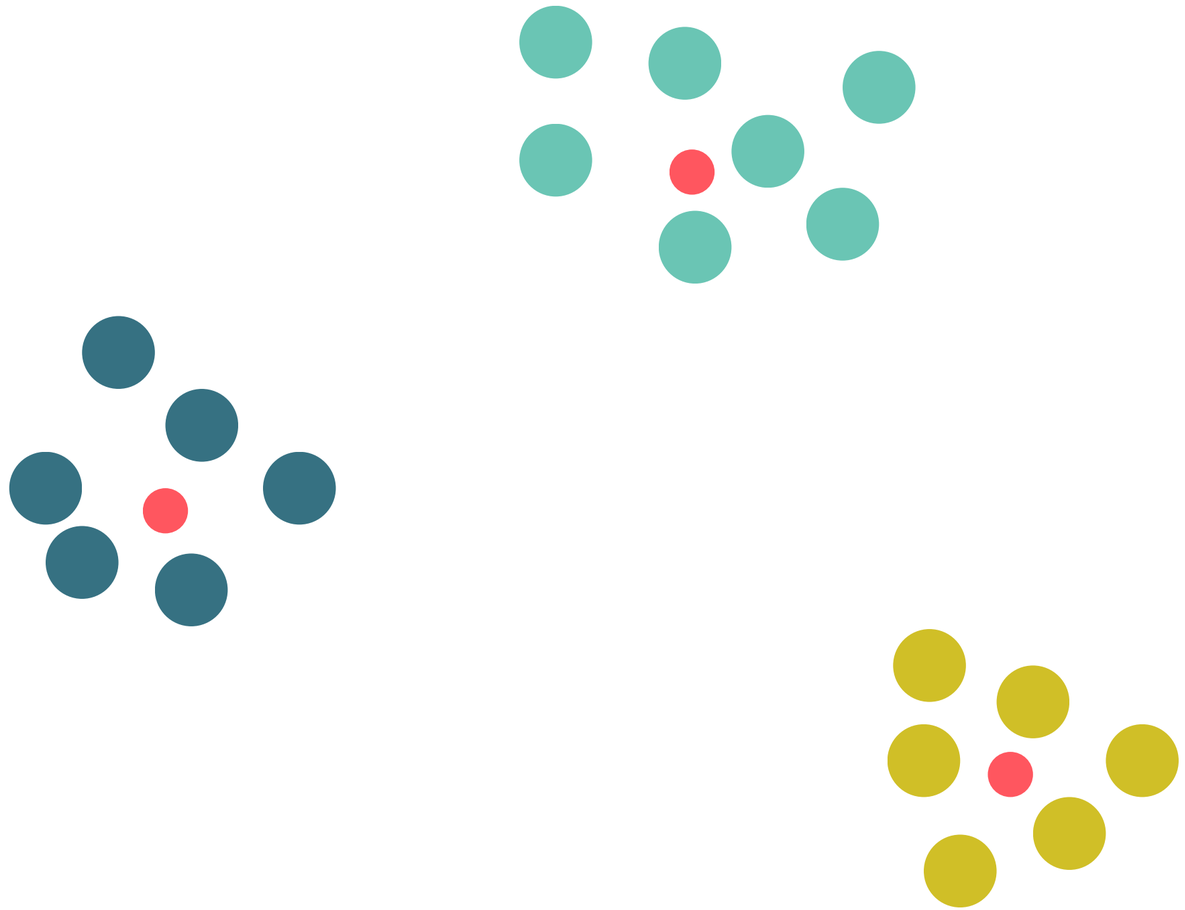
Tr(**Wk**) variance
intracluster à minimiser



Meilleure qualité quand CH est élevé

Diapos Supp

Exemple de clustering



PLAN

CHOIX FINAL

1

2

a

b

c

3

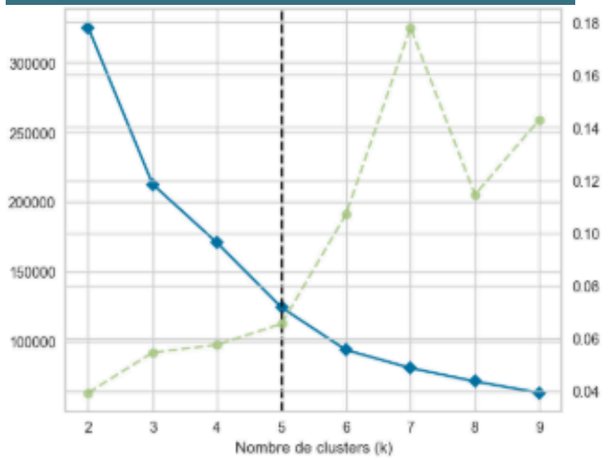
4

SEGMENTATION

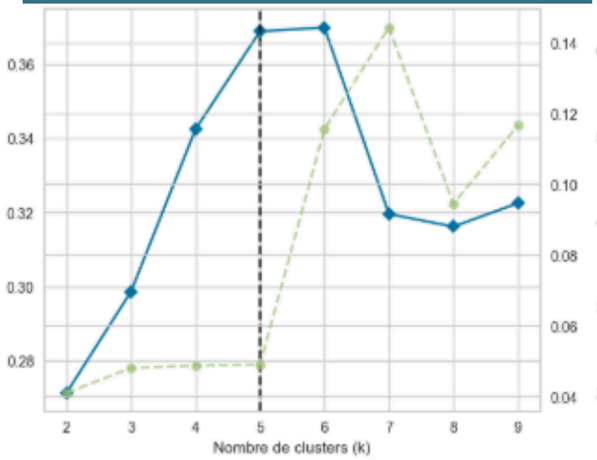
SYNTHÈSE

Segmentation

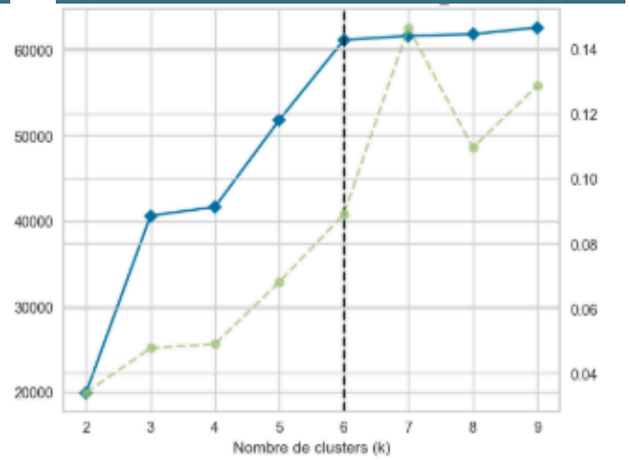
Distorsion



Silhouette



Calinski-Harabasz



PLAN

CHOIX FINAL

1

2

a

b

c

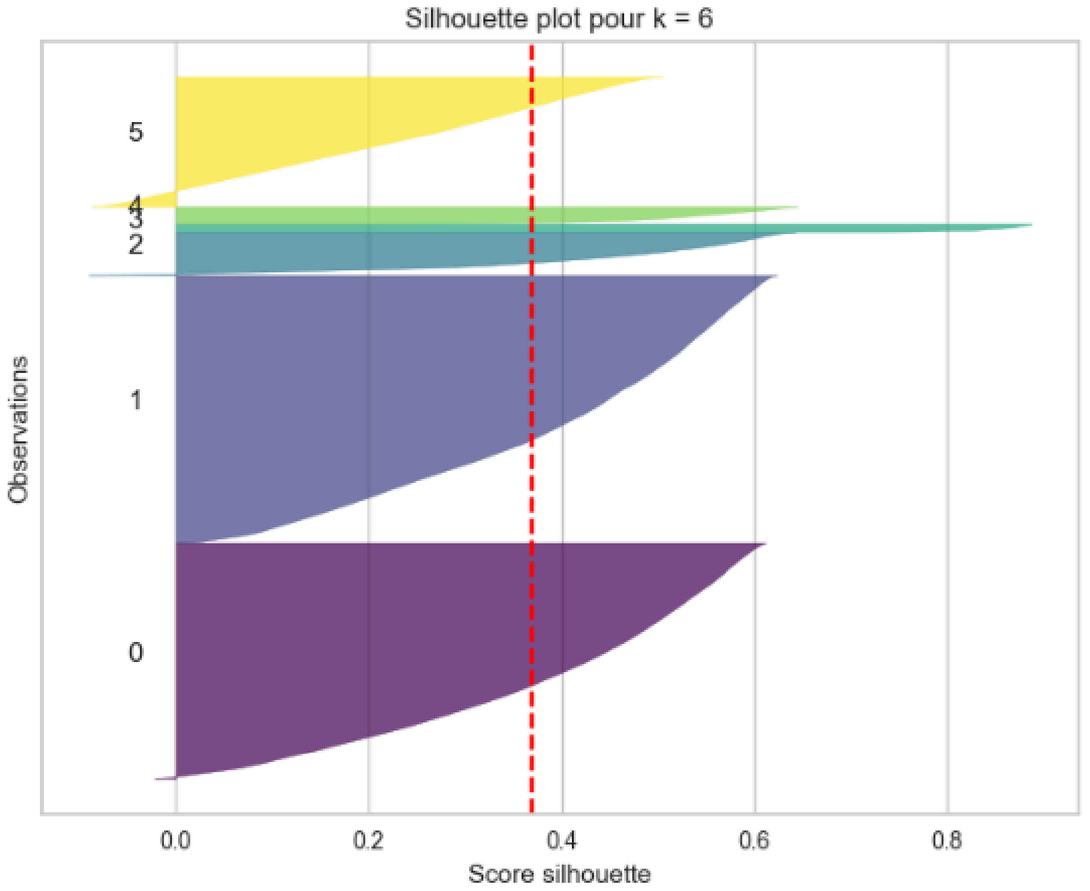
3

4

SEGMENTATION

SYNTHÈSE

Segmentation



PLAN

CHOIX FINAL

1

2

a

b

c

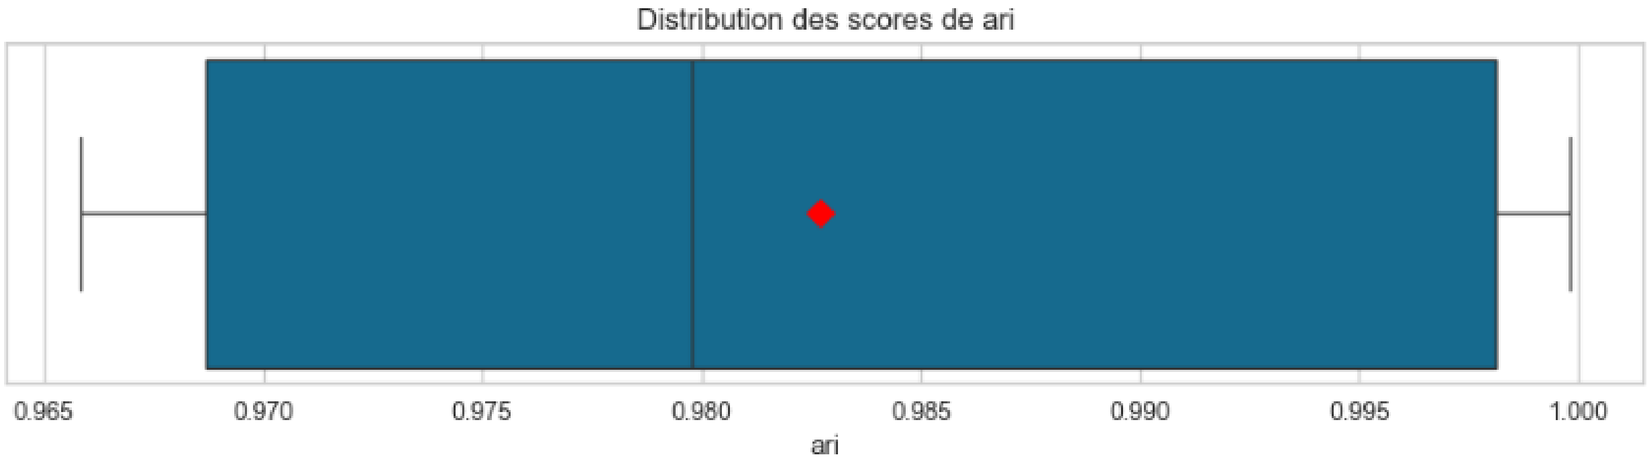
3

4

SEGMENTATION

SYNTHÈSE

Segmentation



Evaluation de la stabilité temporelle

Evolution des centroïdes au cours du temps

