

Réaliser un environnement BigData dans le cloud

Objectifs du projet

Fruits
Startup

Préservation de la biodiversité fruitière

Application

Sensibilisation
Moteur de classification

Chaine de traitements

Preprocessing

Extraction de caractéristique par transfert d'apprentissage

Reduction de dimensionalité

Gestion de l'évolution des données

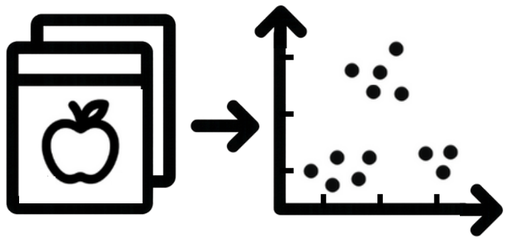
Comment anticiper une future augmentation du volume de données

Test d'une solution en local → Test de la solution sur le cloud

↓

Configuration d'un environnement BigData









Présentation des données

Présentation des stratégies de traitement des données

Présentation de la solution et test local

Présentation de l'environnement BigData

SÉLECTION D'ENSEMBLES D'IMAGES DE FRUITS SEGMENTÉES POUR TESTER LE CALCUL DISTRIBUÉ LOCAL ET CLOUD

kaggle

22 688 images

131 espèces de fruits

Films de 20 sec

Fruits isolés du fond

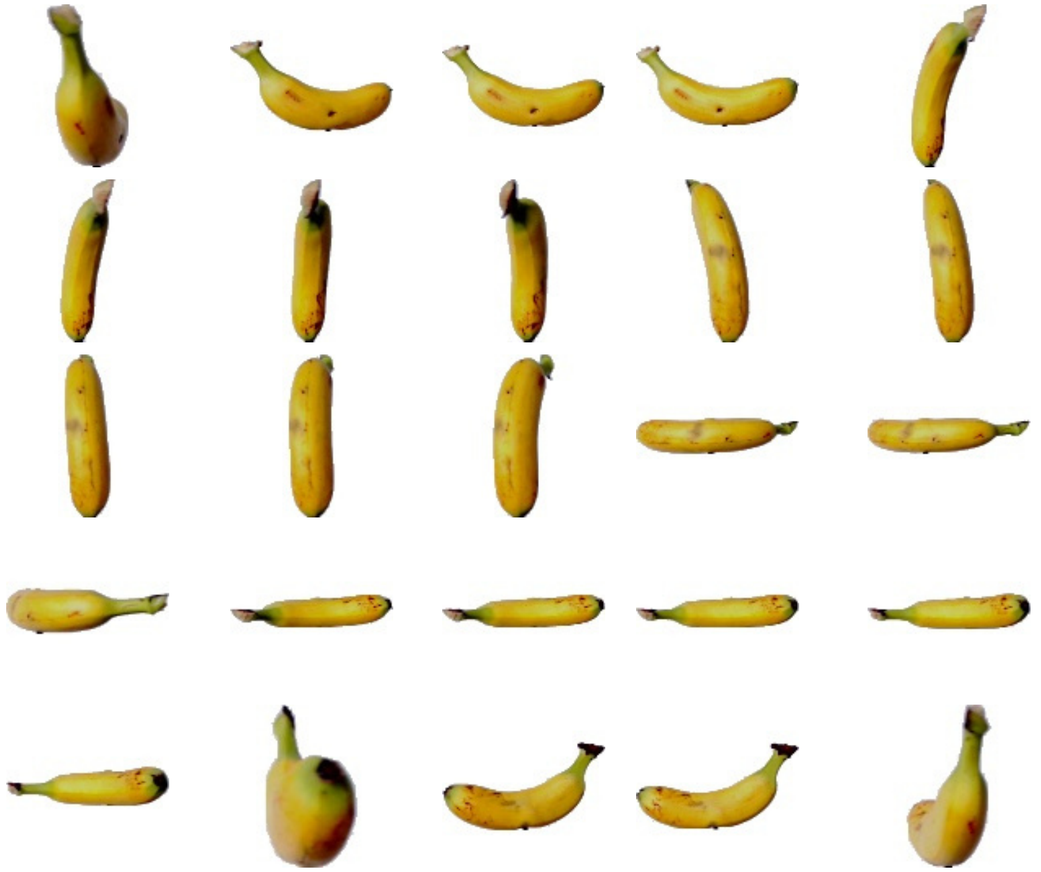
Data test Local

300 images
répartis dans 6 catégories

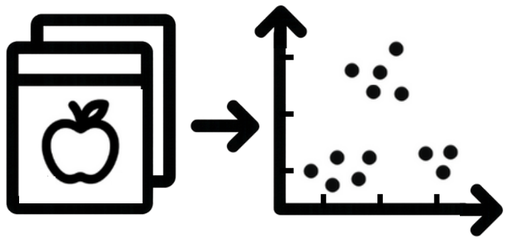
Data test Cloud

4929 images
répartis dans 30 catégories

Exemples (25/152 images)











Présentation des données

Présentation des stratégies de traitement des données

Présentation de la solution et test local

Présentation de l'environnement BigData

EXTRACTION ET VISUALISATION DES CARACTÉRISTIQUES D'IMAGES DE FRUITS POUR ÉVALUER LE POTENTIEL D'UN FUTUR MOTEUR DE CLASSIFICATION

Chargement et Preprocessing des images



Image 100x100

Image 224x224

Conversion en tableau numérique

Normalisation

0,65	0,12	...	0,82	0,65
0,27	2,64	...	0,14	0,52
...	...	...	...	...
-0,23	-0,27	...	-0,27	-0,41
-0,23	-0,48	....	-0,55	-0,23
-0,23	-0,27	...	-0,27	-0,41

Extraction de caractéristiques par transfert d'apprentissage

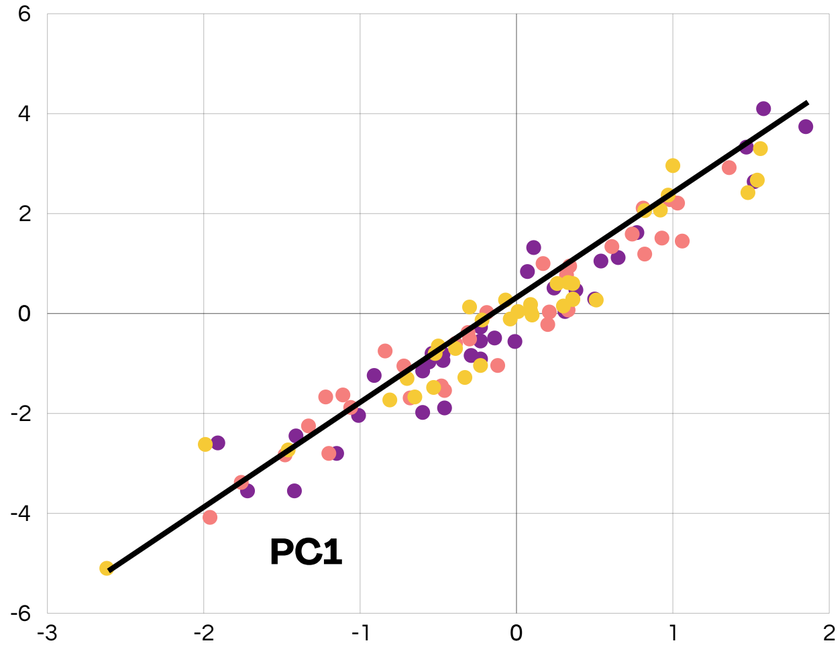
MobileNetV2

....

Réduction de dimensionalité

Analyse en composantes principales

1ère composante → capture d'un max de variance



EXTRACTION ET VISUALISATION DES CARACTÉRISTIQUES D'IMAGES DE FRUITS POUR ÉVALUER LE POTENTIEL D'UN FUTUR MOTEUR DE CLASSIFICATION

Chargement et Preprocessing des images



Image 100x100

Image 224x224

Conversion en tableau numérique

Normalisation

0,65	0,12	...	0,82	0,65
0,27	2,64	...	0,14	0,52
...	...	...	...	...
-0,23	-0,27	...	-0,27	-0,41
-0,23	-0,48	....	-0,55	-0,23
-0,23	-0,27	...	-0,27	-0,41

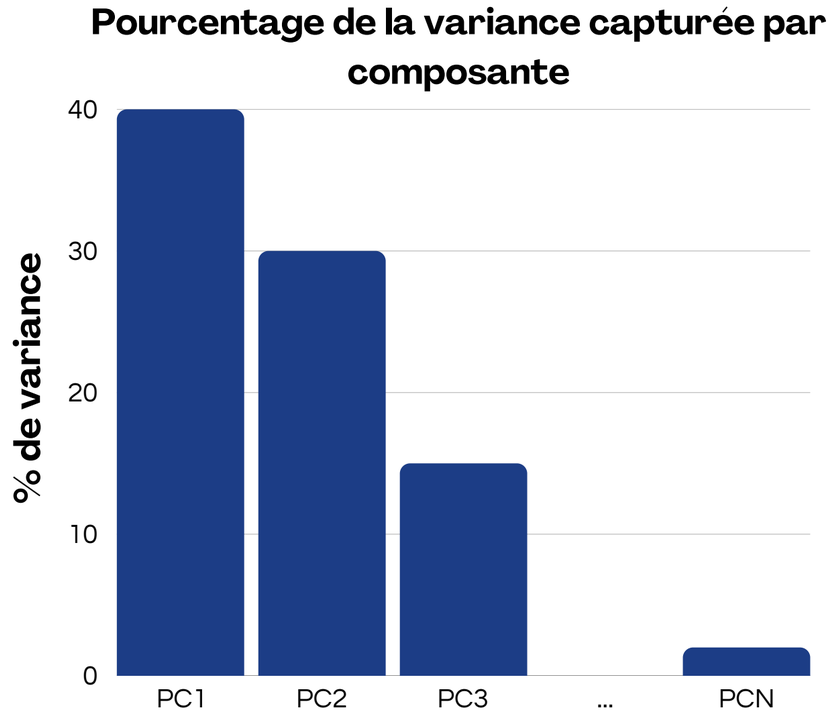
Extraction de caractéristiques par transfert d'apprentissage

MobileNetV2

....

Réduction de dimensionalité

Analyse en composantes principales



EXTRACTION ET VISUALISATION DES CARACTÉRISTIQUES D'IMAGES DE FRUITS POUR ÉVALUER LE POTENTIEL D'UN FUTUR MOTEUR DE CLASSIFICATION

Chargement et Preprocessing des images



Image 100x100

Image 224x224

Conversion en tableau numérique

Normalisation

0,65	0,12	...	0,82	0,65
0,27	2,64	...	0,14	0,52
...	...	...	...	...
-0,23	-0,27	...	-0,27	-0,41
-0,23	-0,48	....	-0,55	-0,23
-0,23	-0,27	...	-0,27	-0,41

Extraction de caractéristiques par transfert d'apprentissage

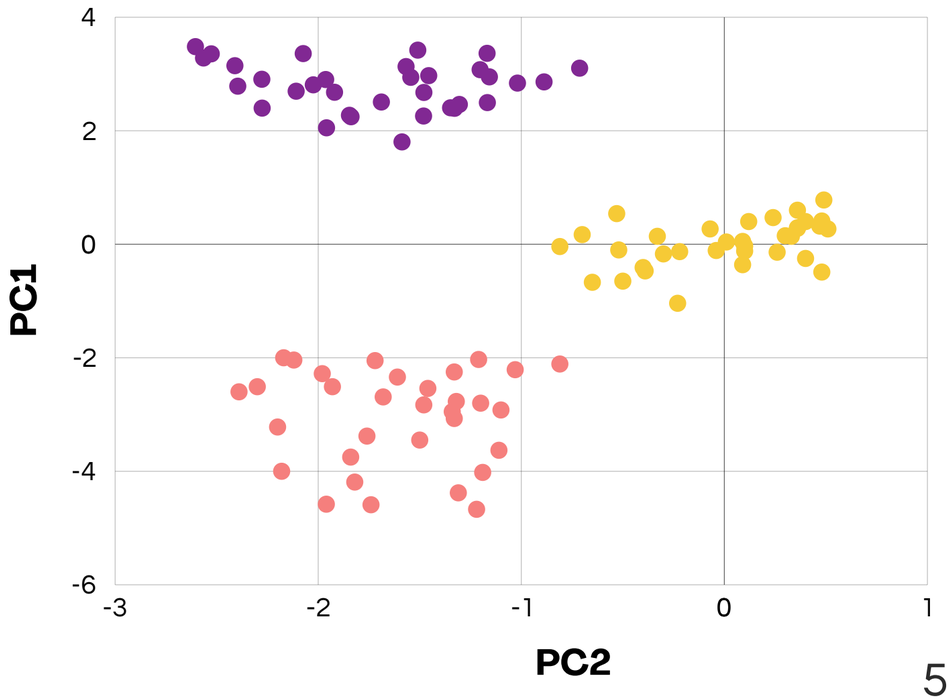
MobileNetV2

....

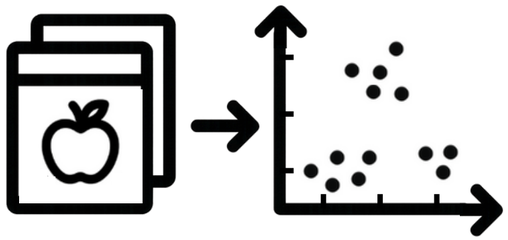
Réduction de dimensionalité

Analyse en composantes principales

Distribution des fruits en fonction des deux premières composantes principales











Présentation des données

Présentation des stratégies de traitement des données

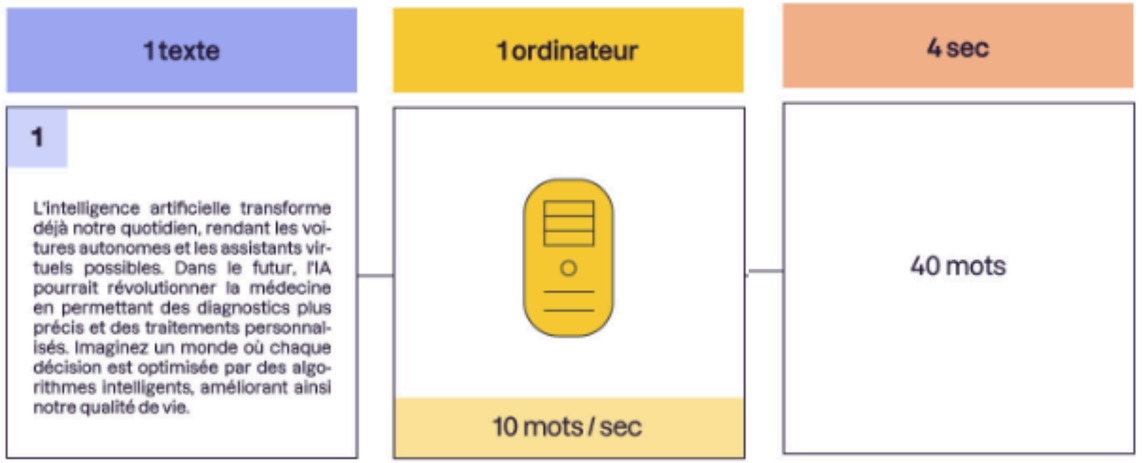
Présentation de la solution et test local

Présentation de l'environnement BigData

MISE EN PLACE D'UNE ARCHITECTURE DISTRIBUÉE ET SCALABLE POUR ANTICIPER LE TRAITEMENT DE VOLUMES DE DONNÉES MASSIFS.

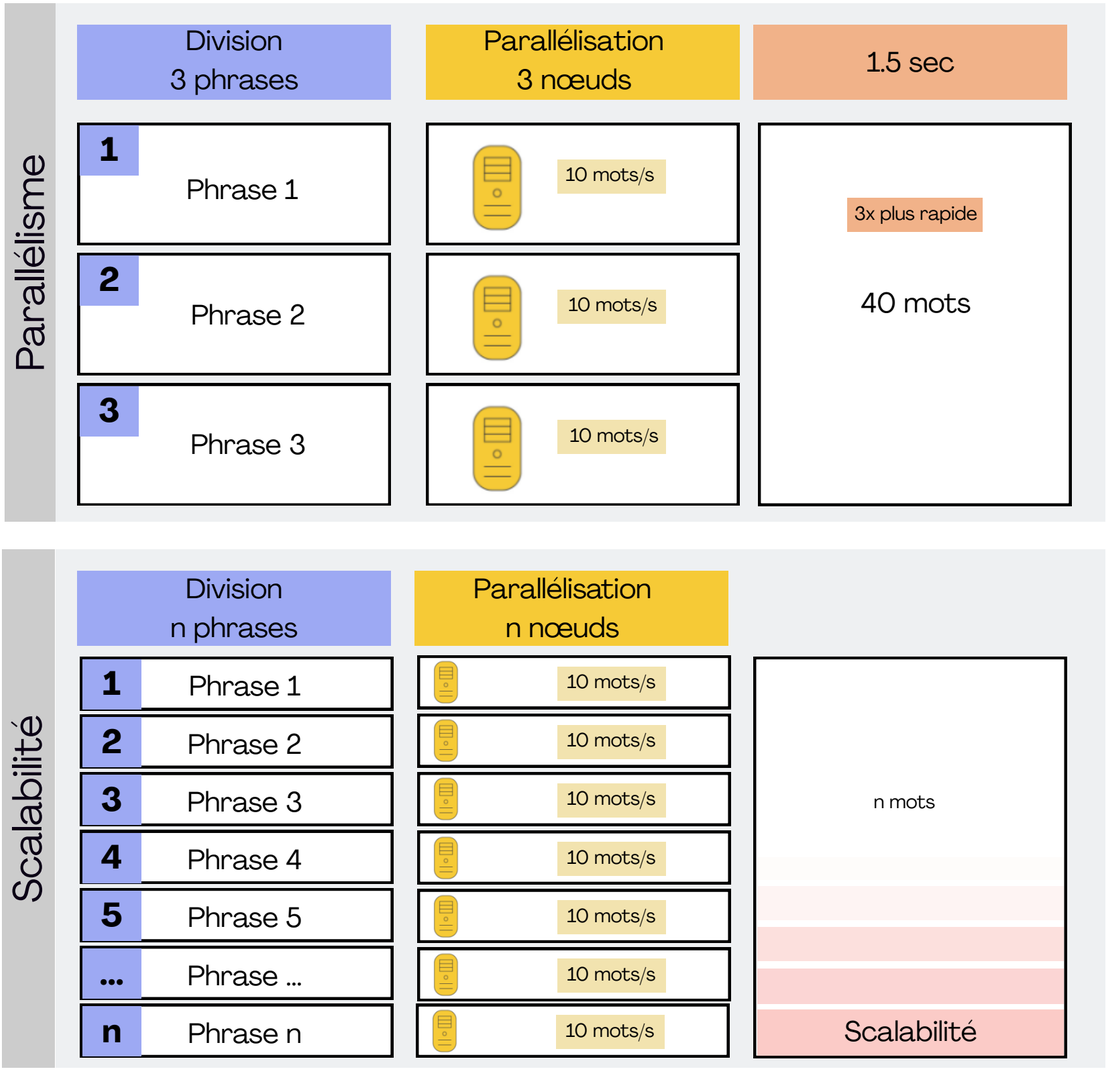
BigData

Comment accélérer la vitesse de calcul ?
Comment gérer l'augmentation futur du volume de données ?



Parallélisme	Scalabilité
exécuter plusieurs tâches simultanément pour accélérer le traitement.	'augmenter la puissance de calcul en ajoutant des machines supplémentaires

Image reprises du cours d'Openclassrooms (Réalisez des calculs distribués avec Spark)



PYSPARK : UN ÉCOSYSTÈME COMPLET ASSURANT LE PARALLÉLISME ET LA SCALABILITÉ DU TRAITEMENT DES DONNÉES.

Apache Spark + Python = PySpark

Driver Programme

Analyse le code
Découpe le code en jobs, stage et tasks
Planifie l'exécution des tasks

Cluster Manager

Alloue les ressources entre Driver et Worker

- Worker node
- Worker node
- Worker node
- Worker node

exécutent les tâches concrètes sur les données.

VALIDATION LOCALE DE LA CHAÎNE DE PRÉTRAITEMENT ET D'EXTRACTION DE CARACTÉRISTIQUES AVEC PYSPARK.

PySpark

Chargement des images

Prétraitement des images

Chargement du modèle

worker1

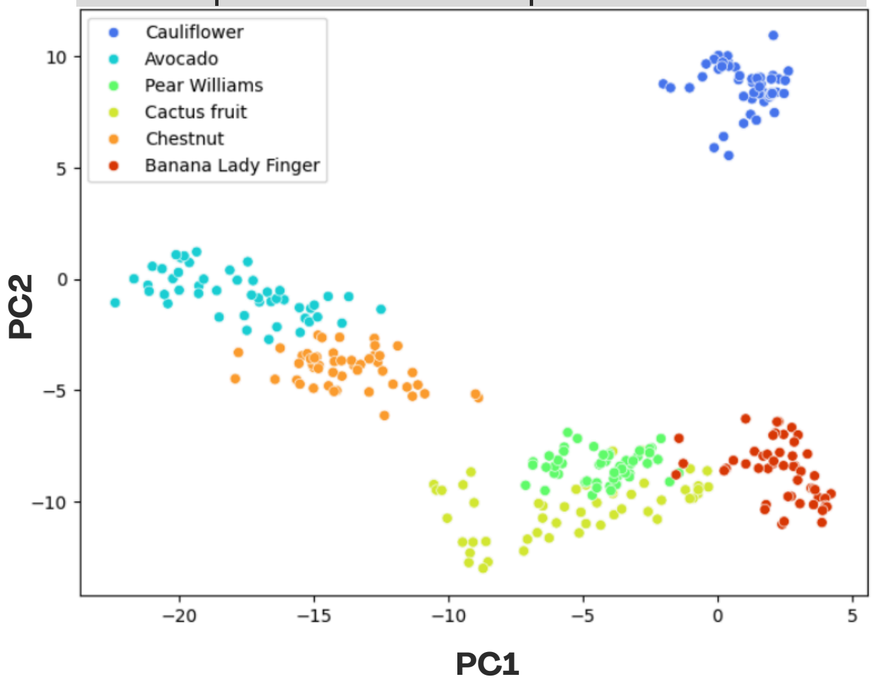
worker2

Diffusion des poids aux workers

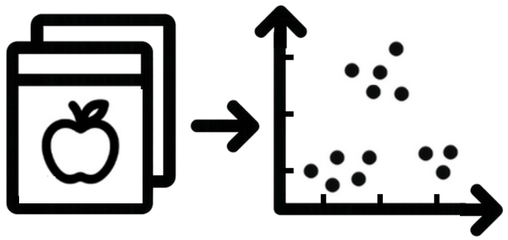
Extraction de features
dim 1280

PCA
dim 100

Projection des images sur les deux premières composantes











Présentation des données

Présentation des stratégies de traitement des données

Présentation de la solution et test local

Présentation de l'environnement BigData

CONFIGURATION D'UN ENVIRONNEMENT BIG DATA OPTIMISÉ ALLIANT SCALABILITÉ, PERFORMANCE ET SÉCURITÉ

EC2
Elastic Compute Cloud

Primaire
m5.xlarge
4 vCore, 16 Gio RAM, Storage :64 Gio

Principal
m5.xlarge
4 vCore, 16 Gio RAM, Storage :64 Gio

Principal
m5.xlarge
4 vCore, 16 Gio RAM, Storage :64 Gio

EMR
Elastic MapReduce

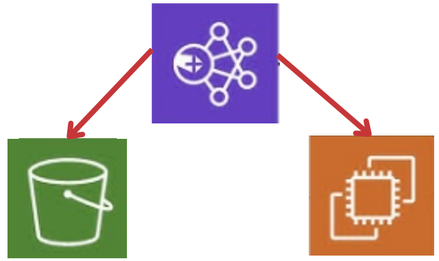
Applications
Spark
Hadoop
Tensorflow
JupyterHub

Bootstrap
wheel, pillow, numpy, pandas, pyarrow, matplotlib, seaborn, fsspec, s3fs, botocore, boto3

```
[
  {
    "Classification": "jupyter-s3-conf",
    "Properties": {
      "s3.persistence.bucket": "mon-bucket-oc-p9",
      "s3.persistence.enabled": "true"
    }
  }
]
```

IAM identity and Acces Management

Définition des rôles

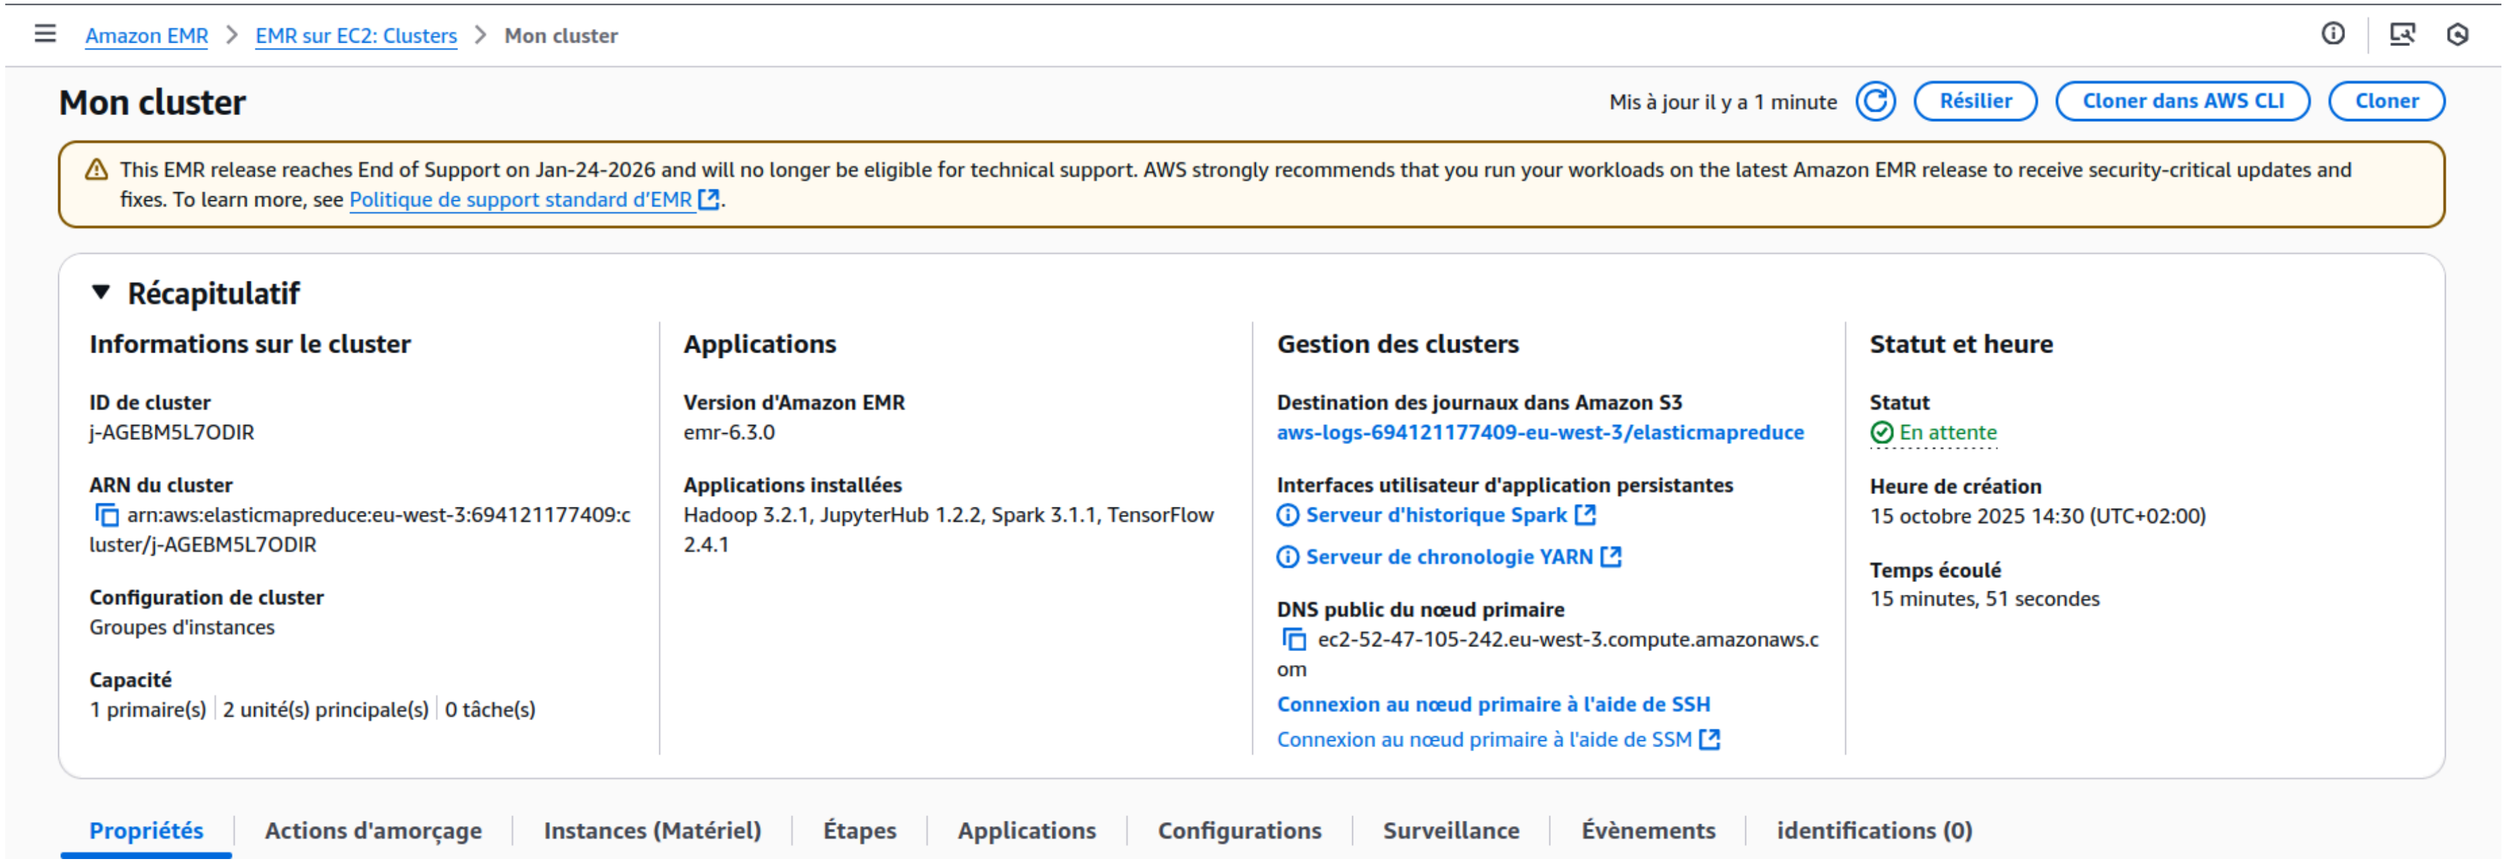


Full access

S3 simple storage service

- Bootstrap
- Config
- Data
- Jupyter
- Plots
- Results

ACCES AUX PARAMÈTRES CONFIGURÉS DE L'EMR ET AUX LIENS VERS LES APPLICATIONS DEPUIS L'INTERFACE D'AWS





ACCES AUX PARAMÈTRES CONFIGURÉS DE L'EMR ET AUX LIENS VERS LES APPLICATIONS DEPUIS L'INTERFACE D'AWS

Propriétés | Actions d'amorçage | Instances (Matériel) | Étapes | **Applications** | Configurations | Surveillance | Évènements | identifications (0)

Interfaces utilisateur d'application Infos

Les applications installées sur votre cluster Amazon EMR publient des interfaces utilisateur en tant que sites web. Vous pouvez les utiliser pour surveiller l'activité du cluster.

- (●) **Interfaces utilisateur d'application sur le cluster**
  Les interfaces utilisateur sur le cluster sont disponibles uniquement pendant l'exécution de votre cluster. Utilisez les liens suivants pour démarrer. Pour accéder à toutes les interfaces utilisateur d'application, configurez le tunneling SSH.
- ( ) **Interfaces utilisateur d'application persistantes**
  Les interfaces utilisateur persistantes ne nécessitent pas de tunneling SSH. Elles sont hébergées hors du cluster et sont disponibles pendant 30 jours après la fin d'une application.

Interfaces utilisateur d'application en direct

Ces interfaces utilisateur d'application sur cluster sont disponibles sans tunneling SSH.

Interfaces utilisateur d'application
Gestionnaire de ressources YARN
Serveur d'historique de tâches
Serveur d'historique Spark
Serveur de chronologie YARN

Interfaces utilisateur d'application sur le nœud primaire

Activer une connexion SSH

Celles-ci nécessitent l'activation du tunneling SSH.

Application	URL de l'interface utilisateur
Gestionnaire de ressources	http://ec2-52-47-105-242.eu-west-3.compute.amazonaws.com:8088/
JupyterHub	https://ec2-52-47-105-242.eu-west-3.compute.amazonaws.com:9443/
Nom du nœud HDFS	http://ec2-52-47-105-242.eu-west-3.compute.amazonaws.com:9870/
Serveur d'historique Spark	http://ec2-52-47-105-242.eu-west-3.compute.amazonaws.com:18080/

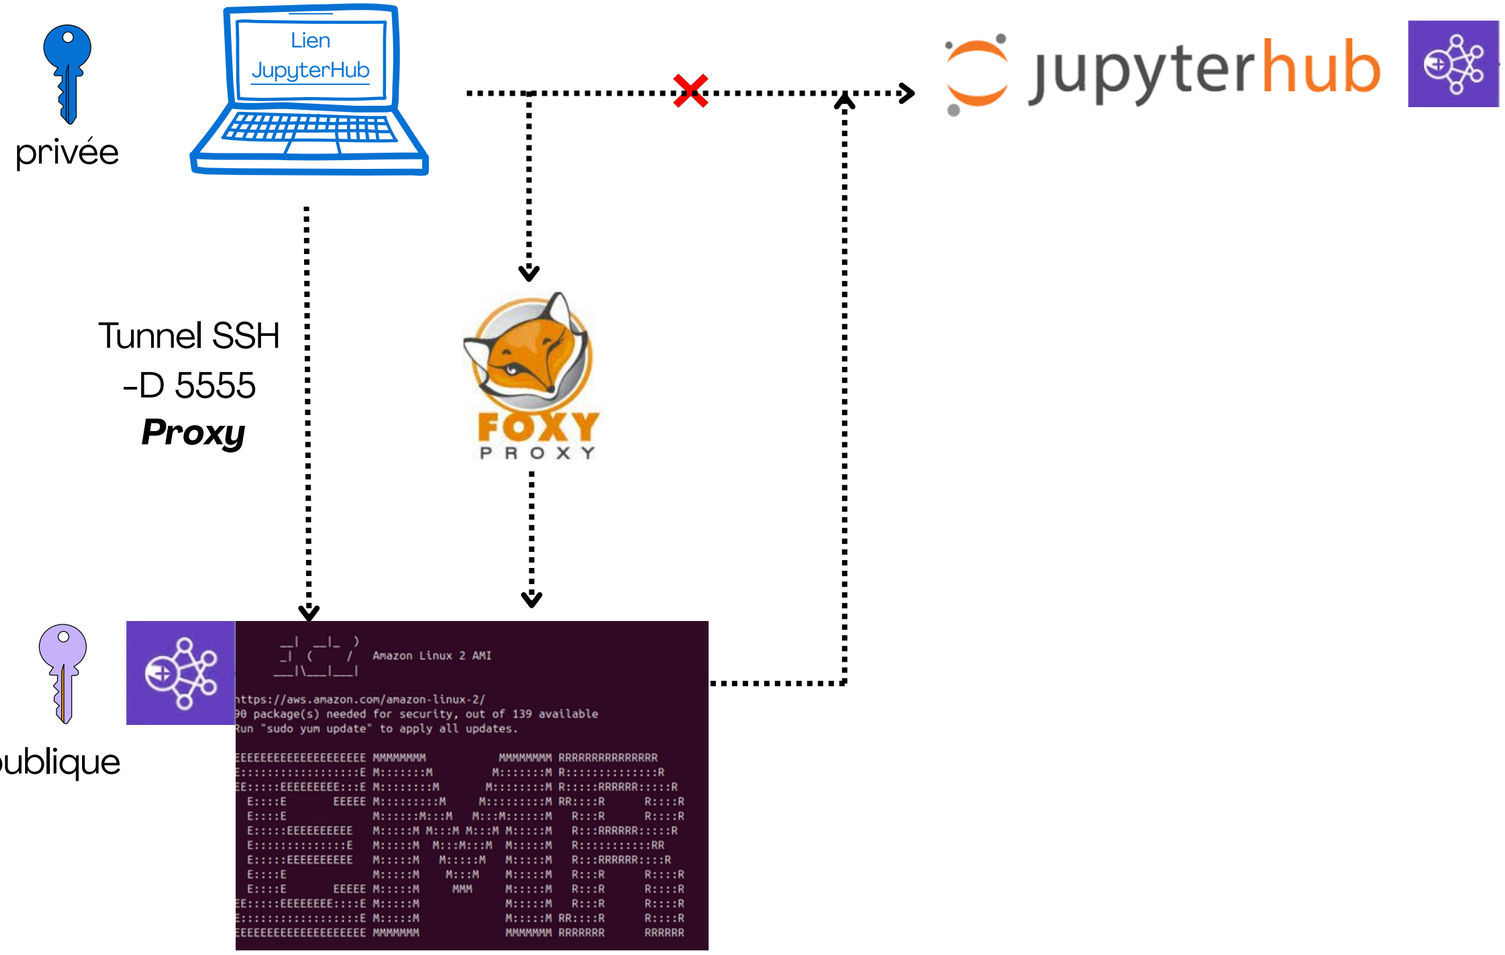
GESTION DES ACCÈS ET CONNEXIONS SÉCURISÉES AU CLUSTER EMR ET AUX APPLICATIONS DU CLUSTER

Mécanismes de sécurité supplémentaires

Utilisation d'une paire de clé EC2

Configuration d'un Proxy

Connexion via un tunnel SSH

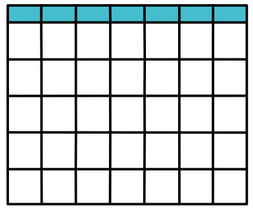


TRANSPOSITION DES TRAITEMENTS ET DE LA SOLUTION VALIDÉS EN LOCAL VERS L'ENVIRONNEMENT BIGDATA D'AWS





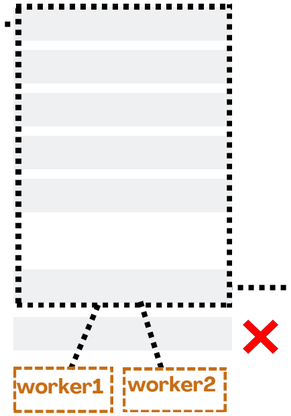
PySpark
jupyterhub



Chargement des images

Prétraitement des images

Chargement du modèle

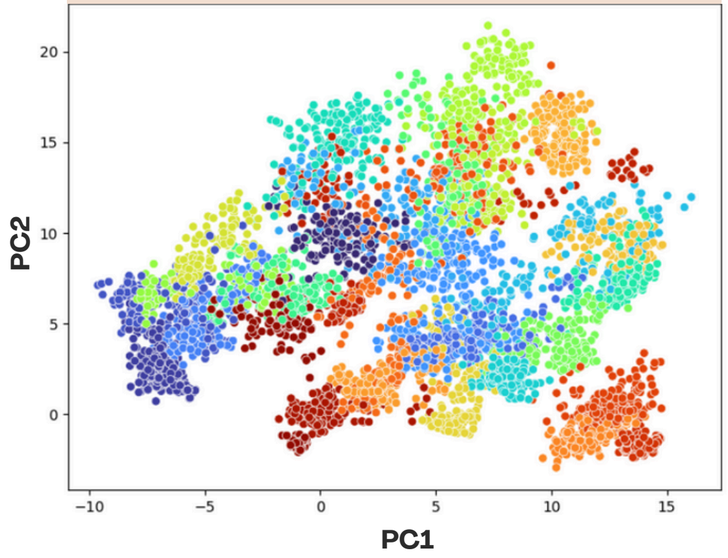


Diffusion des poids aux workers

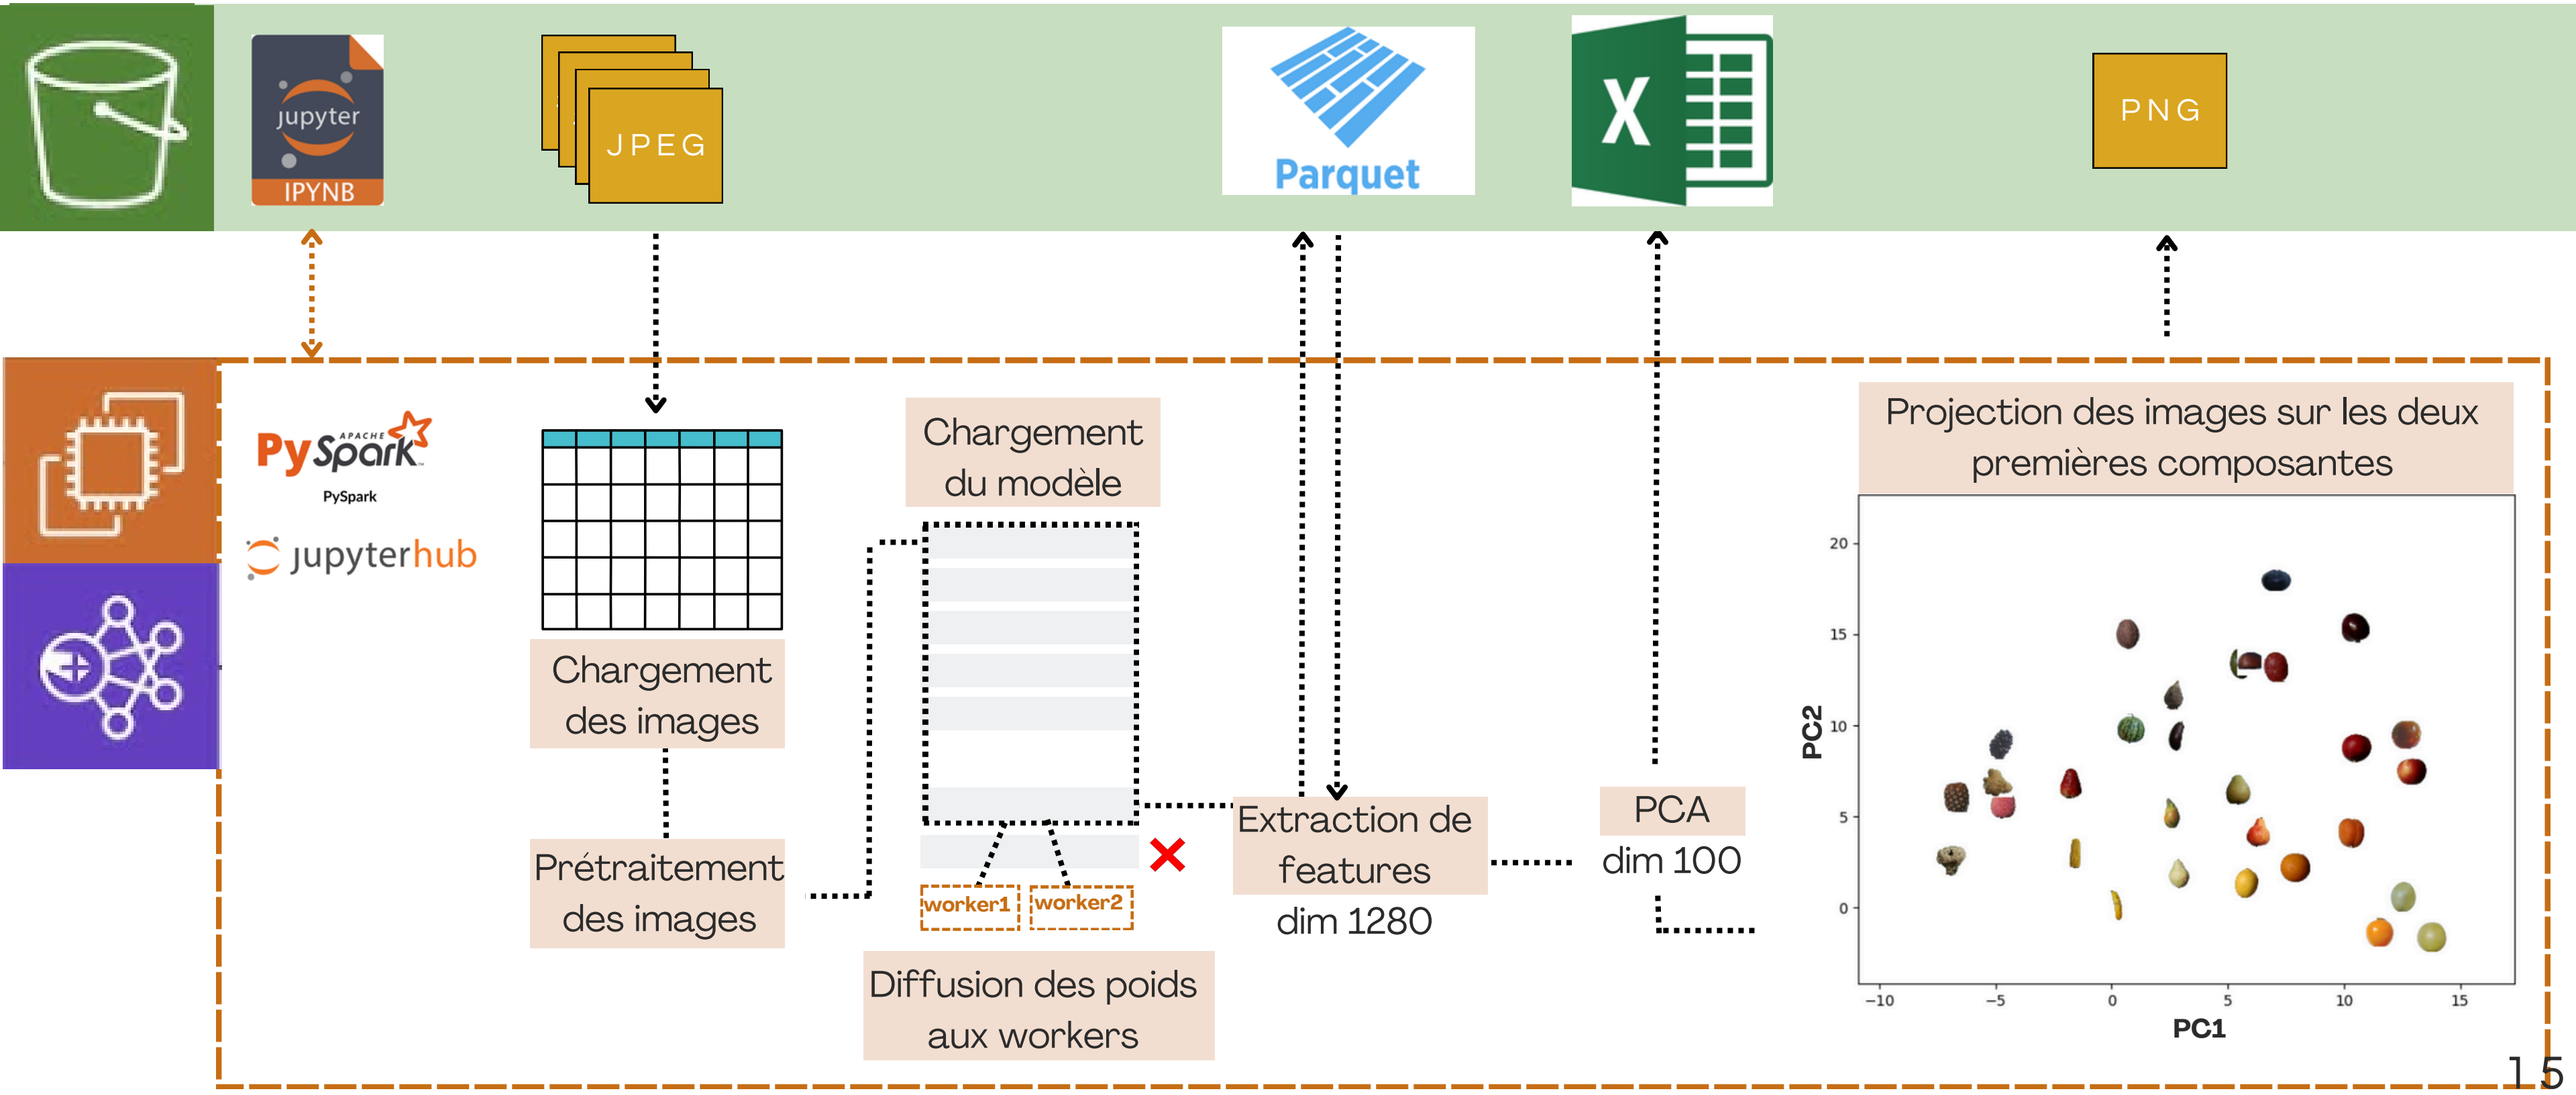
Extraction de features dim 1280

PCA dim 100

Projection des images sur les deux premières composantes



TRANSPOSITION DES TRAITEMENTS ET DE LA SOLUTION VALIDÉS EN LOCAL VERS L'ENVIRONNEMENT BIGDATA D'AWS

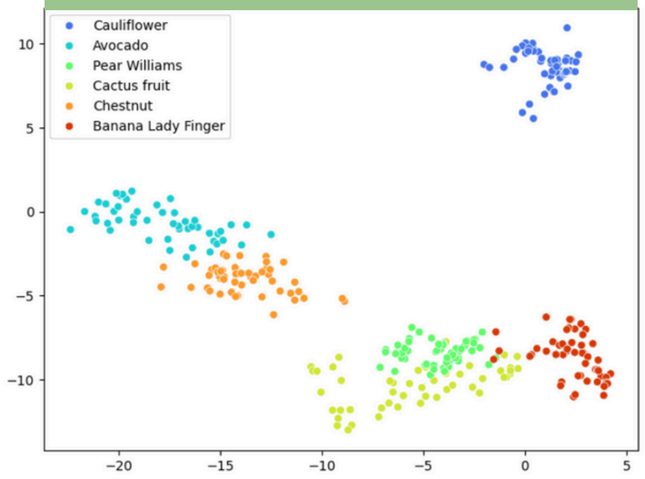


Conclusions

Chaine de traitements

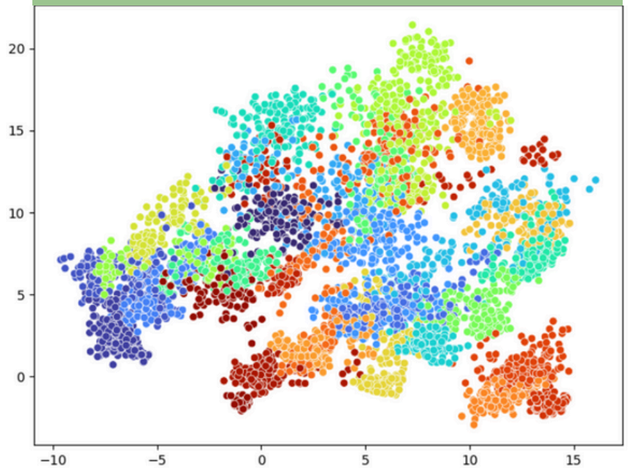
Prétraitement
Extraction des caractéristiques
PCA

Traitements testés en locale



300 images (6 espèces)

Traitements réalisés sur le cloud



4929 images (30 espèces)

Gestion de l'évolution des données

Traitement données massives + évolutives

